

天启（Apocalypse）项目全解

从 LLM 小白到 Post-Train / Agent 面试官

一份边看代码、边学大模型与强化学习工程、边准备面试的完整教材

覆盖：FastAPI 全栈架构 · 自研 Harness Agent Runtime · Deep Research Agentic RL 环境 · 大厂面试真题对照

2026 年 9 月

目录

天启 (Apocalypse) 项目全解

从 LLM 小白到 Post-Train / Agent 面试官

前言：这份教材是给谁看的、怎么用

这份教材和 `course/` 目录下已有的 22 篇文章是什么关系

这份教材是为求职准备的，所以额外做了一件事：对齐真实招聘市场

阅读方式：定义 + 大白话 + 面试提示

代码引用规范

第一部分 · LLM 基础知识速成

- 1.1 大模型是怎么“说话”的：自回归生成与 Token
- 1.2 上下文窗口：模型的“短期记忆”
- 1.3 三种角色：System / User / Assistant / Tool
- 1.4 采样参数：温度、Top-p，以及为什么“确定性”任务要调低它们
- 1.5 Function Calling（工具调用）：模型怎么“使唤”外部世界
- 1.6 流式输出与 SSE
- 1.7 RAG 与检索：为什么模型“看过互联网”还是会答错
- 1.8 从预训练到能对话：SFT 与 RLHF
- 1.9 强化学习基础：奖励、策略、优势函数
- 1.10 KV Cache 与 Prompt 前缀缓存：为什么“顺序”和“要不要带秒级时间戳”很重要

第二部分 · 项目全景导览

2.1 项目是什么，为什么这么选技术栈

后端技术栈一览

前端技术栈

数据存储与部署

2.2 后端分层架构：谁能依赖谁

各层职责一览

`core/` 各模块速览

2.3 `models/` 与迁移策略

2.4 `main.py`：应用装配

2.5 知识空间的业务功能一览

2.6 精灵聊天：非 Harness 的对照组

2.7 前端：没有框架，靠约定维持可维护性

2.8 Harness 是什么：全书真正的核心

2.9 设计原则一：可替换的能力接缝（Replaceable Seams）

2.10 设计原则二：全链路可追溯（Everything the Model Sees Is Logged First）

2.11 `SessionEvent`：一切的最小单位

2.12 存储层：`SessionStore` 协议与 SQLite 实现

2.13 投影函数：`derive_messages()`

2.14 会话状态管理：`SessionManager`

2.15 主循环：`_drive()` 一步步拆解

2.16 `_request_model()`：流式分片的批量落盘

2.17 工具调用的执行链路与“状态完全从日志重建”

2.18 钩子系统与中断机制

- 2.19 数据与代码分离：工具的“契约”和“实现”是两个文件
- 2.20 审批策略：三档判定
- 2.21 沙箱与安全边界
- 2.22 技能系统（Skills）：过程性知识按需注入
- 2.23 子代理与多智能体协作
- 2.24 成本、上下文压缩与一批“血泪教训”级工程细节
- 2.25 HTTP 接口与前端联调
- 2.26 部署与质量保障

第三部分 · RL 工作台导览

- 3.1 为什么 Agent 运行时不等于 RL 环境
- 3.2 环境设计的第一版，以及它是怎么被自己的实测推翻的
- 3.3 环境的最终形态与 rollout 期装配
- 3.4 任务集与泄漏过滤：题目本身可能是假的
- 3.5 奖励与验证器：怎么把“做得好不好”变成一个不会被刷的数
- 3.6 分词对齐与 Loss Mask：多轮 RL 最难发现的一类 bug
- 3.7 GRPO 与训练循环
- 3.8 Rollout 引擎与系统指标
- 3.9 这一部分的整体产出（给面试用）

第四部分 · 面试官视角 QA

- 4.1 开场：项目介绍与整体设计
- 4.2 Function Calling 与流式解析
- 4.3 安全与沙箱
- 4.4 可靠性与状态管理
- 4.5 上下文管理
- 4.6 Harness 设计原则（可替换接缝 / 全链路可追溯）
- 4.7 技能系统与多智能体委派
- 4.8 这个项目里最值得讲的一条工程原则
- 4.9 质量保障与工程判断力
- 4.10 RL 方向的追问：环境有效性
- 4.11 怎么保证模型是在学检索，而不是在背答案
- 4.12 奖励函数设计
- 4.13 分词对齐与 loss mask
- 4.14 GRPO 与归一化
- 4.15 Rollout 系统工程
- 4.16 项目的诚实边界
- 4.17 可以反问面试官的问题
- 4.18 最后的建议

附录

- A.1 术语速查表
- A.2 章节索引对照表
- A.3 命令速查
- A.4 一句话读完全书

前言：这份教材是给谁看的、怎么用

如果你符合下面这些描述，这份教材就是为你写的：

- 会写 Python / JavaScript，但没有系统做过一个完整的 Web 全栈项目；
- 听说过“Agent”“Function Calling”“RAG”“RLHF”“GRPO”这些词，但没有亲手实现过一套完整、可运行、可训练的 Agent / RL 系统；
- 正在准备大模型 **Post-Train 算法工程师**或**Agent / Harness 开发工程师**方向的实习 或校招/社招面试，希望把一个真实项目讲清楚、讲深、经得起面试官一层一层往下追问。

天启 (Apocalypse) 是一个部署在个人网站上的“知识空间”：博客 + 社交笔记 + AI 助手 + **Agent 工作台 (Harness)** + **Deep Research 的 Agentic RL 环境 (rl/)**。对求职这个方向而言，**Harness 子系统和 rl/ 工作台是全项目含金量最高的部分**——它们不是调用一次 `openai.chat.completions.create()` 就完事的“套壳”，而是自己实现的、具备事件溯源 (Event Sourcing)、工具调用循环、人工审批、沙箱执行、上下文压缩、多智能体委派的最小可用 **Agent Runtime**，以及在这个 Runtime 之上搭建起来的、真正跑通了从环境设计到 GRPO 训练循环的强化学习工作台。这正是 Claude Code、Cursor Agent、AutoGPT 这类产品背后的核心机制，以及 DeepSeek、字节 Seed、阿里通义、腾讯混元这些团队 Post-Train 团队每天在做的事情的一个“教学级但工程完整”的实现。

这份教材和 `course/` 目录下已有的 22 篇文章是什么关系

`course/` 目录下已经有 00 ~ 21 共 22 篇分模块深挖的教程，本教材**不是它们的简单压缩或转述**，而是反过来——把 21 章“全景导览”里因为篇幅限制被压缩成一两段话的内容，全部按照 01 ~ 20 章的原始深度重新展开、补齐，再叠加成书时新核实的代码细节，目标是让你**只看这一份 PDF、不需要来回跳转到其他章节，就能完整地建立起对整个项目的理解**。如果你想找某个知识点最原始的出处，可以在本书末尾附录的“章节索引对照表”里查到它对应 `course/` 目录下的哪一篇。

这份教材是为求职准备的，所以额外做了一件事：对齐真实招聘市场

写这本书之前，先调研了 2026 年市面上“大模型 Post-Train 算法工程师”和“Agent / Harness 开发工程师”这两类岗位的真实招聘要求 (JD) 和面经，结论会穿插在正文里、并集中体现在第四部分的面试 QA 设计上：

- **Post-Train 算法岗**普遍要求 Transformer/MoE/长上下文原理扎实、SFT/DPO/ RLHF/GRPO 等对齐技术“有落地经验”、PyTorch + HuggingFace 生态工程栈熟练、懂数据清洗和指令数据集构建、会做模型评测。字节 Seed 2026 校招 JD 明确把“独立 AI Agent 开发经验”“前沿 RL 算法对模型性能有实际提升”列为强加分项——这正是本书第三部分 `rl/` 工作台的价值所在。
- 真实面经里能看到两种典型风格：一种“全程问项目”（不问八股，围绕候选人项目的每个设计决策深挖），另一种“八股 + 项目混合”。本书第四部分沿用“多层追问 + 三档回答（及格线/加分/踩坑）”的写法，就是为了让在这两种风格下都能接得住。
- **Agent / Harness 开发岗**在 2026 年被多篇招聘解读文章明确列为新增考点，定义为“Agent = Model (大脑) + Harness (操作系统/车身)”，考察的六大模块——结构化 Prompt/Function Calling、工具与技能、记忆系统、编排与调度、**沙箱与安全**、运行时与监控——与本项目 Harness 子系统的设计几乎一一对应。
- Agent 面试高频真题——Function Calling 底层实现、流式工具调用解析、ReAct 死循环怎么防、Multi-Agent 协调机制、Prompt Injection 防御、最小权限 + 人工审批、审计日志——本书会在讲对应机制时明确点出“这是哪类岗位的高频考点”，并在第四部分把每个真题和项目里的具体实现对应上。

阅读方式：定义 + 大白话 + 面试提示

延续 `course/` 目录教程一贯的写法，每一个新概念先给一个**严谨定义**（面试时可以 直接照着说），再给一段**大白话解释**（帮你真正理解、能举一反三）。涉及到面试 高频考点的地方，会用“面试提示”专门标出来。

代码引用规范

书中出现的 `文件路径:行号` 都是撰写本书时（2026 年 9 月）该文件的实际位置，方便你对照源码阅读。代码会随项目迭代变化，行号仅供定位参考，请以你本地仓库的 最新代码为准。

第一部分 · LLM 基础知识速成

这一部分把后面通篇会反复用到的概念——token、上下文窗口、System/User/Assistant、采样参数、Function Calling、流式输出、RAG、SFT/RLHF、强化学习基础、KV Cache——用“严谨定义 + 大白话”讲一遍。讲完你就有了读懂这个项目全部代码所需要的预备知识。如果你已经很熟悉这些概念，可以直接跳到第二部分，这里留着按需回查。

1.1 大模型是怎么“说话”的：自回归生成与 Token

严谨定义：当前主流的大语言模型（LLM）本质上是一个**自回归（Autoregressive）**语言模型——给定前面已经出现的一串 token，模型输出“下一个 token 是什么”的概率分布，采样出一个 token 拼到序列末尾，再重复这个过程，直到生成一个表示“结束”的特殊 token 或达到长度上限。

大白话：模型不是“一次性想好整句话再说出来”，而是像你手机输入法的联想候选，但是**逐字地**不断“猜下一个字最可能是什么”，猜一个吐一个，吐出来的字又变成下一次猜测的输入。ChatGPT 网页版那种“一个字一个字蹦出来”的效果，就是这个过程被实时展示出来的样子——不是打字机特效，是它真的在一个字一个字地算。

Token 不等于“字”：中文大致 1 个字 $\approx$ 1 个 token，英文常见词也是 1 个 token，但长的英文单词会被拆成好几个 token（比如“internationalization”可能拆成“international”+“ization”）。这也是为什么本项目

`harness/session/projection.py:: estimate_tokens()` 用“总字符数 / 2.5”来粗估 token 数——中文大约 1 字对应 1 token，英文大约 4 字符对应 1 token，两者各占一半时取的经验折中值。这个估算只用来做“要不要触发压缩”这个决策，不用于真实计费——真实计费永远用 provider 返回的 `prompt_tokens / completion_tokens`（第二部分 2.11 节会展开这个区别为什么重要）。

1.2 上下文窗口：模型的“短期记忆”

严谨定义：上下文窗口（Context Window）指模型单次推理能接收的最大 token 数——包括你发送的所有输入（系统提示词、历史对话、工具定义）加上模型将要生成的输出，总和不能超过这个上限。

大白话：模型没有“记住之前聊过什么”的能力，它每次回答问题，都是把**从头到现在的全部对话文本**当作一次全新的输入重新读一遍。所以“上下文窗口”越大，模型能“记住”的历史就越长；但窗口是有限的，聊得越久，这些文本占的空间就越大，直到有一天必须“扔掉”或“压缩”一部分早期内容——这正是本项目“上下文压缩”功能存在的原因（第二部分 2.20 节）。

多轮对话为什么能“记住”上文？**不是模型有记忆**，而是每次请求都把完整的历史消息列表（`[{"role": "system", ...}, {"role": "user", ...}, {"role": "assistant", ...}, ...]`）重新发一遍给模型。这也是这个项目“事件溯源式会话存储”存在的直接原因——既然每次都要重新拼出这份历史，就必须有一个可靠的地方能把它准确地拼出来，而不是靠内存里一个容易和“真实发生过的事”悄悄脱节的变量。

1.3 三种角色：System / User / Assistant / Tool

OpenAI 定义的 Chat Completions 协议里，每条消息都带一个 `role` 字段：

角色	作用
system	定义模型的“人设”和行为规则，通常放在消息列表最前面，一次对话通常只有一条（或没有）
user	用户说的话
assistant	模型自己说的话（包括之前几轮的回复）
tool	工具调用的执行结果（也叫 function，取决于协议版本），喂回给模型

大白话：把这想象成一部剧本——system 是“人物小传”（这个角色是谁、说话风格是什么），user / assistant 是对话台词，tool 是“旁白：他打开了那份文件，看到了……”。模型每次“发言”，都是先把整个剧本从头读一遍，再决定自己这句台词该说什么。

本项目里，“天启精灵”的人设写在 backend/data/prompts/sprite.md，Harness 的系统提示词由 system.md + 运行时信息（日期、工具目录）拼成——都对应这里的 system 角色。两者是两套完全独立的系统提示词，服务于两条完全独立的对话链路（第二部分 2.3 节会讲清楚这两条链路的区别）。

1.4 采样参数：温度、Top-p，以及为什么“确定性”任务要调低它们

模型在每一步“猜下一个 token”时，并不是永远选“概率最高的那个”，而是按概率分布 **采样**。两个常见的调节旋钮：

严谨定义：温度（Temperature）是对概率分布做的一次缩放——温度越低，概率分布越“尖锐”（高概率的 token 更容易被选中，模型更“确定”）；温度越高，分布越“平坦”（低概率的 token 也有更大机会被选中，输出更“有创意”、也更容易“胡说”）。Top-p（Nucleus Sampling）只在“累积概率达到 p 的最小 token 集合”里采样，把极小概率的候选直接排除掉。

大白话：温度调低 = 让模型“少来点花样，按最靠谱的说”；温度调高 = 让模型“天马行空一点”。写诗、头脑风暴适合调高，写代码、回答事实性问题、Function Calling 这种“格式必须精确”的场景，温度通常要调低甚至设成 0。

本项目 Harness 的模型适配器 OpenAICompatibleAdapter._payload() 把 temperature 固定设成 0.3——比精灵聊天场景更低，原因写在注释里：“tool arguments must be exact”（工具调用的参数必须精确，不能有创意发挥的空间）。而 rl/env/adapter.py 里训练/评估用的 EvalAdapter / PolicyAdapter 要自己独立控制温度，不能复用聊天场景那套默认参数——RL 训练需要在“探索（温度高一点，见到更多样的轨迹）”和“复现性（同样的 prompt 应该得到可预期的分布）”之间做取舍，这和网页聊天场景、Harness 工具调用场景的默认设置目标完全不同（第三部分会展开这一点）。

1.5 Function Calling（工具调用）：模型怎么“使唤”外部世界

这是整个 Harness 子系统的根基，也是最容易被误解的一个概念，也是 Agent 开发岗 面试里被问到频率最高的一个话题。

严谨定义：Function Calling 指 LLM 服务在请求里额外接收一份“函数目录”（每个函数的名字、描述、参数的 JSON Schema），模型在生成回复时，可以选择输出一个结构化的“我要调用某个函数、参数是这些”的请求，而不是直接输出自然语言。**模型本身不会真正执行这个函数**——它只是“请求”，真正的执行、以及把执行结果重新喂回给模型，都是调用方（你的服务端代码）的责任。

大白话：很多人第一次听到“模型能调用工具”，会以为模型内部真的跑了一段代码。实际上模型做的事情，更像是填一张申请表：“我想用‘查天气’这个功能，参数是‘北京’”，然后把这张表交给你。你（服务端）拿着这张表，真的去调一次天气 API，把结果拿回来，写成一条新的消息（role: "tool"）追加进对话历史，再把整个对话重新发给模型一次，模型才能“看到”刚才那次调用的结果，继续往下说。**一次工具调用，背后是两次完整的 HTTP 请求，不是一次。**

一次带工具调用的对话轮，在协议层面长这样（简化版）：




图 1.1：Function Calling 两轮请求时序图——一次工具调用背后是两次完整的 HTTP 往返，模型自己从不真正执行任何代码。

这正是本项目 `harness/loop/agent.py::_drive()` 那个循环在做的事——每一步都是“发一次请求 → 看模型要不要调工具 → 调完再发一次请求”，直到模型某一步的响应不再带 `tool_calls` 为止（详见第二部分 2.7 ~ 2.8 节）。“Agent”这个词，工程上很大程度上就是这个循环 + 一组可调用的工具”。

流式场景下工具调用是分片返回的——这是几乎每个自己写过适配层的人都会踩的坑，provider 保证每个分片都带一个稳定的 `index`，但 `function.name` 往往只在这个调用的第一个分片里出现一次，`arguments` 则是一个字一个字地拆成 JSON 字符串片段吐出来的。本项目 `harness/llm/openai_compatible.py` 里专门有一个 `_ToolCallAccumulator`，以 `index` 为 key 把同一个调用的所有分片参数字符串拼接起来；如果 provider 没给 `id`，就自己生成一个 `call_{n}` 的兜底 id；如果收完所有分片后名字始终是空的，就丢弃这个调用（详见第二部分 2.19 节）。

面试提示（Agent 岗高频题）：“Function Call 底层怎么实现？”“流式场景下工具调用怎么解析？”“各厂商的 Function Call 格式有什么区别？”——这几乎是 Agent 面试的开场必考题。只会说“我用官方 SDK，它帮我处理好了”，在这类面试里约等于交白卷，因为它证明候选人从未真正深入过这一层。能画出图 1.1 的两轮时序、能讲清楚

`_ToolCallAccumulator` 按 `index` 聚合分片、能讲清楚“参数解析失败要当成工具执行失败处理、把错误信息作为文本喂回模型而不是让整个请求崩掉”（工具失败是值，不是异常，详见第二部分 2.8 节），是这道题的加分线。

1.6 流式输出与 SSE

严谨定义：Server-Sent Events (SSE) 是一种基于 HTTP 长连接、服务端可以持续向客户端推送文本事件的协议——本质是一个一直不关闭的 HTTP 响应，服务端每准备好一点数据就往这个连接里写一段，格式是 `data: <内容>\n\n`。相比 WebSocket，SSE 是单向的（只能服务端推客户端）、天然基于 HTTP（不需要单独的协议升级），浏览器原生支持自动重连。

大白话：如果不用流式，你发一个问题给模型，要等模型把整句话全部生成完才能看到任何文字——对一段几百字的回复，这可能要等好几秒，体验很差。流式输出让服务端“模型每吐出一个字，就立刻转发一个字给你”，你看到的就是逐字蹦出来的效果，虽然总耗时没变，但“第一个字出现的时间”大大缩短了，体验好很多。

本项目 SSE 帧的格式在 `backend/core/sse.py`：`f"data: {json.dumps(payload, ensure_ascii=False)}\n\n"`——注意 `data:` 后面那个空格，前端用 `line.slice(6)` 精确按 6 个字符切片，这是一个“看起来可以优化、实际上有跨文件契约”的典型例子（详见第二部分 2.4 节）。`SSE_HEADERS` 里还设置了 `X-Accel-Buffering: no`，专门用来关闭 nginx 的代理缓冲，配合 `deploy/nginx.conf` 里的 `proxy_buffering off`，双重保证流式响应不会被中间层攒批延迟（详见第二部分 2.22 节的部署章节）。

1.7 RAG 与检索：为什么模型“看过互联网”还是会答错

严谨定义：检索增强生成 (Retrieval-Augmented Generation, RAG) 指在模型生成回答之前，先从一个外部知识库里检索出和问题相关的文档片段，把这些片段作为上下文一起交给模型，让模型“参考资料作答”，而不是完全依赖训练时记住的知识。

大白话：模型的知识来自训练数据，训练数据有截止日期，也不可能覆盖每一个私有/小众的事实。RAG 相当于“开卷考试”——考试之前先给它发一份相关的参考资料，让它照着资料回答，而不是全凭脑子里的记忆（“闭卷考试”）。检索质量直接决定回答质量：如果检索回来的资料是错的或者不相关的，模型大概率会被带偏——这也是为什么本项目 RL 环境的语料要专门设计“存在近似文档但答案唯一”这种难度（第三部分会详细展开这个设计过程被数据推翻又重新验证的完整故事）。

检索最基础的一种实现方式是 **BM25**（一种基于关键词的排序算法，本质是“词频 + 逆文档频率”的加权打分，不涉及任何神经网络）：

大白话：BM25 判断“这篇文档和这个查询有多相关”，核心直觉是——一个词在这篇文档里出现得越多、但在所有文档里出现得越少（越“生僻”），这个词就越能代表这篇文档的特色，匹配上这种词的文档应该排得更靠前。和“用向量做语义检索 (Embedding + 余弦相似度)”是两条不同的技术路线——BM25 不理解“同义词”（搜“汽车”匹配不到只写“轿车”的文档），但胜在**确定、可解释、不需要额外的模型**。本项目 `backend/harness/corpus/index.py` 手写了一个 BM25 索引（而不是用现成的 `bm25s` / `Pyserini` 库），因为“索引本身就是环境定义的一部分”——一次库升级悄悄改掉分词或打分方式，就会悄悄改掉整个任务的难度分布，让之前所有跑出来的实验数字全部失效。这是个很值得记住的工程决定：一百行代码钉在仓库里，换来的是“实验数字永远可复现”这个更贵的保证。

1.8 从预训练到能对话：SFT 与 RLHF

一个刚训练完“预测下一个词”的模型 (Base Model)，并不会乖乖地按你的指令做事——它只是“续写”，你给它一个问题，它可能续写出更多问题，而不是回答。要把它变成 ChatGPT 那种“听得懂指令、愿意配合”的助手，通常要经过：

严谨定义：监督微调（Supervised Fine-Tuning, SFT）指用一批“指令 → 期望回复”的标注数据，对预训练模型继续训练，让它学会“人类希望它怎么回应”这种 格式和风格。**基于人类反馈的强化学习（RLHF）**在 SFT 之后，用人类对多个候选 回复的偏好排序训练一个“奖励模型”，再用强化学习（早期主要是 PPO）让模型去 最大化这个奖励模型给出的分数，进一步对齐人类偏好。

大白话：预训练是“读遍全世界的文字，学会语言和知识”；SFT 是“手把手教它 照着示范格式回答问题”；RLHF 是“让它自己多次尝试回答，每次都有个评委（奖励模型）打分，它根据打分调整自己的行为，越打越像人类喜欢的样子”。三个阶段一个比一个“贵”（预训练最贵最耗资源，RLHF 相对最省但最考验 “怎么设计一个不会被投机取巧钻空子的评分标准”）。

本项目的 `rlv` 子系统做的正是“预训练/SFT 之后”的这一段——不是从零训练一个 大模型，而是拿一个现成的中小模型（`Qwen2.5-1.5B-Instruct`），先做一轮“拒绝 采样 SFT”打底，再用强化学习（GRPO）继续训练它“学会用检索工具做多跳问答”这件 具体的能力（第三部分会逐层展开）。

1.9 强化学习基础：奖励、策略、优势函数

严谨定义：强化学习（Reinforcement Learning, RL）里，**策略（Policy）**是“在某个状态下该采取什么行动”的决策函数（这里策略就是 LLM 本身：给定上文，输出下一步该生成什么）；**奖励（Reward）**是环境对一次行动/一整条轨迹给出的 标量反馈；**优势函数（Advantage）**衡量“这次行动比‘一般水平’好多少”，用它而 不是直接用奖励原始值来更新策略，能显著降低训练的方差。

大白话：策略就是“模型这一次会怎么答”，奖励就是“这次答得好不好、打几分”，优势是“这次答得比它平时的平均水平好还是差”。强化学习的核心就是不断用“优势”这个信号去调整模型，让它更倾向于做“优势为正”的事、更少做“优势为负”的事。

PPO（Proximal Policy Optimization）是过去几年 RLHF 里最常用的算法，但它 需要额外训练一个“价值网络（Value Network）”去预测“这个状态下大概能拿多少 奖励”，当作优势计算的基线，这个额外网络本身要占显存、要调参，还可能训不准。

GRPO（Group Relative Policy Optimization）是本项目 `rlv` 用的算法，思路是 不训练价值网络，而是对同一道题采样多条（比如 8 条）轨迹，用这 8 条轨迹 奖励的平均值当基线来算优势——详细展开见第三部分 3.5 节，这是面试 RL 岗位的高频考点。

1.10 KV Cache 与 Prompt 前缀缓存：为什么“顺序”和“要不要带秒级时间戳”很重要

严谨定义：Transformer 推理时，生成每一个新 token 都要用到“之前所有 token 在每一层算出来的 Key/Value 向量”；把这些向量缓存下来（KV Cache），生成下一个 token 时就不用把前面所有 token 重新算一遍，只需要计算新 token 的部分。如果两次请求的开头一段 token 完全相同，这段的 KV Cache 也可以 跨请求复用——这就是主流 LLM API 提供的“Prompt 前缀缓存（Prompt Prefix Caching）”，命中的部分通常按更低价格计费，也算得更快。

大白话：模型每次“思考”都要把输入从头到尾重新过一遍神经网络的计算，这个计算结果（KV Cache）如果两次请求开头一模一样，是可以“抄近道”复用的，不用重新算，还更便宜。但只要开头有哪怕一个字节差异（比如把系统提示词里的时间戳精确到秒、或者把工具在请求里的排列顺序换了一下），这份缓存就 整个失效，之前“抄近道”省下来的计算全部要重新算一遍。

这就是为什么本项目：

- `harness/tools/registry.py::load_specs()` 扫描工具契约文件时坚持用 `sorted()` ——保证工具在请求 `tools` 数组里的顺序稳定；
- 系统提示词只带**日期**、不带精确到秒的时间戳——README 给出的实测数字是 这项优化能省下约 8000 ~ 9900 个输入 token；
- `rl/rollout/engine.py::run_many` 把同一道题的 G 条 rollout **刻意排在 相邻的位置**——这 G 条轨迹共享从 system prompt 到第一个采样 token 之前的 全部前缀，排相邻能让 provider 命中前缀缓存的概率最大化，是一个“零成本”的吞吐优化。

面试提示：这条知识点在本项目里被反复应用了至少三次（工具排序、系统提示词只带日期、RL 分组相邻），如果面试官问“你在项目里有没有做过和成本/性能相关的优化”，KV Cache 前缀缓存是一个可以贯穿多个模块、用具体数字说话的好答案。

有了这十节的预备知识，下面进入项目本身。

第二部分 · 项目全景导览

这一部分带你把 `backend/` 整个走一遍，边看代码边把第一部分的概念在真实场景里对上号。从 2.7 节开始进入全书篇幅占比最大的 Harness 子系统，建议开着 `backend/harness/` 目录边看边对照代码。

2.1 项目是什么，为什么这么选技术栈

天启 (Apocalypse) 是一个**单体应用 (Monolith)**：一个 FastAPI 后端进程，既提供 REST/SSE API，也直接托管前端静态文件。默认数据库是 SQLite，也可以切到 MySQL / PostgreSQL。没有前端构建工具（不用 Webpack/Vite），前端是纯 HTML + 原生 JS + CSS，浏览器直接加载运行。

严谨定义：单体应用 (Monolith) 指所有功能模块打包进同一个可部署单元、共享同一个进程和数据库连接池的架构风格，与“微服务（每个功能拆成独立服务、独立部署）”相对。

大白话：不是所有项目都需要拆成十几个 Docker 容器互相用 gRPC 聊天。对于一个人维护的个人网站，“一个进程搞定一切”更简单、更好调试、部署成本更低。技术选型要匹配项目规模，不是越复杂越高级。

后端技术栈一览

技术	版本约束	用途	面试可以怎么说
FastAPI	≥0.115	Web 框架，基于 Starlette + Pydantic	用了依赖注入 (Depends) 做认证、异步原生支持 SSE 流式响应
Uvicorn	≥0.34	ASGI 服务器	生产环境跑在 Docker 里，前面挂 nginx 反代
SQLAlchemy	≥2.0	ORM	用的是 2.0 风格 (DeclarativeBase) ，不是旧的 declarative_base()
Pydantic / pydantic-settings	≥2.3	数据校验 + 配置管理	Settings(BaseSettings) 从 .env 读配置，@model_validator 做路径解析
python-jose	≥3.3	JWT 编解码	HS256 签名，HttpOnly Cookie 承载
passlib + bcrypt	固定 bcrypt==4.0.1	密码哈希	有一个真实的版本坑 (见下文)
httpx	≥0.27	异步 HTTP 客户端	手写调用 LLM 的 /chat/completions 接口，没有用官方 openai SDK
sse-starlette	≥2.1	声明了但项目自己手写了 SSE 帧格式，未实际使用	体现“依赖没删干净”是真实项目的常态
apscheduler	≥3.10	定时任务	定时抓取 GitHub Trending / HuggingFace 论文等
BeautifulSoup4	≥4.12	HTML 解析	爬虫模块、web_fetch / web_search 工具用它清洗网页正文
python-docx / python-pptx / pypandoc	固定版本	Harness 的 docx/pptx 技能	生成 Word/PPT ， py pandoc_binary 内置 pandoc 二进制，不需要额外装系统包
alembic / zai-sdk	—	声明在 requirements.txt 但未实际使用	见下文“未使用依赖”说明

一个真实的版本坑：bcrypt 固定版本。 requirements.txt 里 bcrypt==4.0.1 被死死钉住，还专门写了注释解释原因： passlib==1.7.4 在初始化时会读取 bcrypt.__about__.__version__ ，而 bcrypt>=4.1 移除了这个属性；同时新版 bcrypt 遇到超过 72 字节的密码会直接抛异常，而不是像旧版本那样自动截断。这是 依赖库之间“版本组合”导致的

真实故障，面试时如果被问“你在项目里遇到 过什么坑”，这是一个很好的、具体的、可验证的例子——比空泛地说“踩过很多坑” 有说服力得多。

未使用依赖也是信息。 `alembic`（数据库迁移工具）和 `zai-sdk`（智谱官方 SDK）在依赖清单里，但项目里没有真正用它们——数据库变更用的是 `models/migrations.py` 里手写的轻量补丁逻辑（2.6 节），调智谱 API 走的是 和其他 provider 一样的手写 `httpx` 请求。这提示你：**真实项目的依赖列表会有 历史遗留**，review 代码时要分清“声明了”和“真的在用”，这也是一种工程素养。

前端技术栈

没有框架——不用 React/Vue/Angular，不用打包工具。原因很朴素：这是一个 页面跳转式的多页应用（每个 `.html` 是独立入口），交互复杂度没有高到需要 虚拟 DOM 和组件化状态管理的程度。

技术	用途
原生 HTML/CSS/JS	无内联脚本/样式， <code><script src></code> 按固定顺序加载
<code>fetch</code> API	所有网络请求，封装出 <code>apiFetch()</code> （自动带 CSRF）和流式场景下的裸 <code>fetch</code>
SSE（Server-Sent Events）	用于 AI 精灵聊天和 Harness 流式对话，不是 WebSocket
CSS 变量 + 分层组织	<code>base.css</code> （设计变量）+ <code>components/</code> （可复用部件）+ <code>pages/</code> （页面专属）
Three.js（按需）	3D 精灵渲染，加载失败时有降级方案

数据存储与部署

- **SQLite**（默认）：单文件数据库，`var/db/myweb.db`。适合个人项目，零运维成本。
- 通过 `DB_TYPE` 环境变量可切换到 **MySQL / PostgreSQL**（`pymysql` / `psycopg2-binary` 已在依赖里备好）。
- 运行时所有可变数据（数据库文件、上传文件、音乐、抓取缓存、Agent 工作区）统一放在 `var/` 目录下，这是“单卷备份”设计——Docker 部署时只需要挂载 一个 `./var` 卷。
- **Docker + docker-compose**：两个服务，`backend`（FastAPI 应用）+ `nginx`（反向代理 + 静态文件托管）。`nginx` 负责托管前端静态文件、反代 `/api/` 到后端、**关闭代理层缓冲**（`proxy_buffering off`）以保证 SSE 流式响应不被 `nginx` 攒批延迟。容器安全加固：`cap_drop: [ALL]`、`no-new-privileges`、`pids_limit`、非 root 用户（uid 10001）运行——这是因为 Harness 会让 Agent 在容器内执行 shell 命令，容器本身的权限面必须 收到最小（部署细节见 2.22 节）。

面试话术：这个项目体现了“配置驱动而非代码驱动”的可移植性设计——数据库 类型、AI 供应商、Harness 是否开启 shell 权限，全部是环境变量，不需要改代码、 不需要重新构建镜像就能切换部署形态。这个项目不是“调一个 API 拼一个 Demo”，而是从底层自己实现了事件溯源的会话存储、手写的面向 Function Calling 的流式 LLM 客户端、进程内的 `execve` 沙箱、数据与代码分离的插件式 工具/技能/子代理系统——这些都是 Agent Infra 岗位面试官真正想看到的东西。




图 2.1：项目整体分层与依赖方向——`routers` → `services` | `harness` → `models` → `core`，`rl/` 从外部单向依赖 `harness/`，`backend/` 内部代码永远不会反过来 import `rl/`。

2.2 后端分层架构：谁能依赖谁

严谨定义：分层架构（Layered Architecture）要求每一层只能依赖“更底层”的模块，禁止反向依赖或跨层跳跃；这里额外约定“单向依赖 + 同层高内聚低耦合”，并且**靠约定而非工具强制**（没有用 `import-linter` 之类的静态检查工具去卡这条规则，纯靠代码 review 和团队纪律维护）。

大白话：`core` 是地基，谁都能踩它，它不认识任何人；`routers`（HTTP 接口层）站在最上面，只管“收请求、调服务、吐响应”，业务逻辑不该写在这一层；`services` / `harness` 是业务逻辑层，能用数据库模型，但绝对不能直接碰 `Request` / `HTTPException` ——这是为了让业务逻辑能脱离 Web 框架独立测试、甚至未来换框架时业务代码不用大改。

各层职责一览

层	目录	能依赖谁	不能做什么
core/	backend/core/	谁都不依赖	不 import 任何业务模块
models/	backend/models/	core	只描述表结构和关系，不写业务逻辑
schemas/	backend/schemas/	core / models	Pydantic 出入参契约，跨路由共享
services/ harness/	backend/services/ 、 backend/harness/	models / core	不 import routers ，不碰 Request / HTTPException ，报错要抛 core/errors.py 里的领域异常
routers/	backend/routers/	services / harness / schemas	不写业务逻辑，只做“解析请求 → 调 service → 返回 schema”

core/deps.py 是这条规则里**唯一的例外**——它虽然在 core/ 目录下，但它就是 HTTP 层的一部分（FastAPI 的 Depends() 依赖注入函数必然要碰 Request ）。项目里专门有一条注释解释了为什么要有这个例外：以前 routers/auth.py 里的 require_user 被别的 router 直接 import，导致“router 依赖 router”的耦合；抽出来放进 core/deps.py 后，所有 router 只依赖 core，不再互相依赖。

core/ 各模块速览

core/config.py —— 配置的唯一真相来源

```
class Settings(BaseSettings):
    var_dir: str = ""
    sqlite_path: str = ""
    upload_dir: str = ""
    ...
```

Settings 继承 pydantic_settings.BaseSettings，会自动从项目根目录的 .env 文件读取同名环境变量。关键设计是 _resolve_runtime_paths()（一个 @model_validator(mode="after")）：

严谨定义：model_validator(mode="after") 是 Pydantic v2 提供的钩子，在模型的所有字段完成常规校验、实例已经构造出来之后再执行一次自定义校验/加工逻辑，可以读取并修改多个字段之间的关联值。

大白话：先把每个字段“各自”校验通过，再统一“扫一遍全局”做加工。这里的加工逻辑是：如果 sqlite_path / upload_dir / music_dir / feeds_dir / harness_dir 这些字段留空，就用 var_dir 拼一个默认路径出来。这意味着 **只改一个 VAR_DIR 环境变量，就能把整个应用的所有状态数据搬到别的地方**——这正是 README 里强调的“单一旋钮”设计。

runtime_dirs 是一个 property，把上面几个目录汇总成一个列表， lifespan() 在应用启动时遍历它挨个 os.makedirs。给项目加一个新的运行时目录，只需要三步：在 Settings 加字段、在 _resolve_runtime_paths() 的默认值字典里加一条、在 runtime_dirs 里加进去——这是 CLAUDE.md 明确写出来的规范，体现了“配置的单一入

口”这个设计目标要靠代码约定持续维护，而不是加了字段就自动生效。

core/database.py —— 引擎与会话工厂

用 SQLAlchemy 2.0 的 `DeclarativeBase` 作为所有 ORM 模型的公共基类；对 SQLite 单独注册了一个 `connect` 事件监听器，每次新建连接都执行 `PRAGMA journal_mode=WAL; PRAGMA foreign_keys=ON;`。

大白话：SQLite 默认不强制外键约束，也不是“预写日志（WAL）”模式。WAL 模式能让读操作不被写操作阻塞（并行性更好），`foreign_keys=ON` 才能让 `ON DELETE CASCADE` 真正生效（比如删除一个会话，它的所有事件行会跟着自动删除）。这两行 PRAGMA 是 SQLite 项目里很容易被忽略、但生产环境几乎必配的细节。

core/security.py —— 认证的纯函数集合

这个模块完全不碰数据库、不碰 `Request`，只做三件事：

- **密码哈希：**`bcrypt` 对超过 72 字节的密码要么截断要么报错（版本相关），所以 `_clamp()` 先按 UTF-8 安全边界主动截断，`password_error()` 提前用“最多 24 个中文字符”这类人类可读的提示做校验，而不是让用户提交后才收到一个底层库抛出的晦涩异常。
- **JWT：**`create_access_token(user_id, role)` 用 HS256 签名 `{"sub", "role", "exp"}`；`decode_access_token()` 捕获所有异常统一返回 `None` ——“解析失败”和“没登录”是同一种语义，不需要在上层再分情况处理。
- **Cookie：**`set_auth_cookies()` 一次设两个 Cookie——JWT 本身是 `httponly=True`（JS 读不到，防 XSS 窃取），CSRF token 是 `httponly=False`（前端 JS 必须能读到它，才能在请求头里带回去做双提交校验）。

严谨定义：CSRF 双提交校验（Double Submit Cookie）是一种防跨站请求伪造的机制：服务端下发一个随机 token，同时写入一个非 `HttpOnly` Cookie 和期望前端在自定义请求头里回传；由于跨站页面能自动带上目标站点的 Cookie，却读不到该 Cookie 的值（浏览器同源策略），也就没法伪造出匹配的请求头，从而校验通过当且仅当请求确实来自能执行该站点 JS 的页面。

大白话：光靠 Cookie 防不住 CSRF，因为浏览器会“自动”带上 Cookie，哪怕请求是从别的恶意网站发起的。解决办法是“信息要分两路传”：一路走 Cookie（自动带），一路走请求头（只有真正加载了本站页面的 JS 才读得到 Cookie 里的值、才能手动塞进头里）。两路对得上，才说明请求是“知情”的。

core/deps.py —— FastAPI 依赖注入

`require_user()` 先从 Bearer Token 或 Cookie 里取 token（`_token_from_request`），如果走的是 Cookie 认证，还要额外做 CSRF 校验（`_check_csrf`，对 `GET / HEAD` 等“安全方法”跳过校验，对 Bearer 认证也跳过——因为浏览器不会自动附带 Bearer 头，跨站请求伪造不出来）。`require_admin()` 在 `require_user()` 基础上再叠加一层角色检查。`optional_user()` 则永远不抛异常，专门给“游客也能看，登录了才能看到更多”这种匿名友好场景用（比如笔记 Feed）。

首个注册账号即管理员：`routers/auth.py` 里注册逻辑是 `role="admin" if db.query(User).count() == 0 else "user"` ——谁第一个在一个全新数据库上注册，谁就是管理员，不需要单独的初始化脚本或者手动改数据库。密码用 `bcrypt` 哈希，登录成功后 `create_access_token()` + `set_auth_cookies()` 一次性发出 JWT Cookie 和 CSRF Cookie。注册逻辑本身还统一处理了 `multipart / form / JSON` 三种请求体格式，服务端二次校验密码强度和验证码，头像文件的校验和保存放在用户行已经建好之后，避免“头像被拒绝导致创建了一个孤儿账号”这种边界情况。

core/errors.py —— 领域异常词汇表

```
class AppError(Exception):
    status_code = 400
class ValidationError(AppError): status_code = 400
class NotFoundError(AppError): status_code = 404
class PermissionError(AppError): status_code = 403
class UpstreamError(AppError): status_code = 502
class ConfigurationError(AppError): status_code = 503
```

services/ 和 harness/ 只抛这几种异常，main.py 里唯一一个 @app.exception_handler(AppError) 负责把它们翻译成 HTTP 响应。这是“关注点 分离”的直接体现——业务代码完全不知道“HTTP 状态码”这个概念，它只知道“这是一个找不到资源的错误”，转换成 404 是路由层/框架层的事。

core/sse.py —— 不能“顺手整理”的一行代码

```
def sse(payload) -> str:
    return f"data: {json.dumps(payload, ensure_ascii=False)}\n\n"
```

这一行看起来可以“优化”，但 data: 后面那个空格是协议要求，前端 line.slice(6) 精确按 6 个字符（"data: " 的长度）切片，删掉空格会让 前端解析全部错位。这是一个很好的例子，说明“看起来啰嗦的代码”背后往往有一个跨文件、跨语言的隐性契约——改代码前先搜一下这行字符串在哪些地方被用到。SSE_HEADERS 里还设置了 X-Accel-Buffering: no。

core/providers.py —— LLM 供应商配置的统一入口

provider_config(name) 根据 AI_PROVIDER 环境变量返回 {url, key, model, format}，支持 deepseek/gemini/zipu/openai/ollama/custom 六种。ai_service.py（精灵聊天用）和 harness/llm/*（Agent 工作台用）共用这一份 provider 配置，避免两套“供应商地址怎么拼”的逻辑各写一份、日后改一个忘了改另一个。

core/paths.py：resolve() 保证相对路径永远相对一个固定的基准解析，不依赖进程当前工作目录；contained_path() 是整个项目唯一的路径收敛实现，Harness 工作区和公开上传服务共用它（详见 2.13 节沙箱一章）。

2.3 models/ 与迁移策略

models/__init__.py 把所有 ORM 类都 import 一遍，纯粹是为了触发 SQLAlchemy 的 mapper 注册——这是一个很多初学者会踩的坑：如果某个模型类 没被 import 过，SQLAlchemy 根本不知道它的存在，Base.metadata.create_all() 就不会为它建表。

数据模型包括：users、memos（+ attachments、comments）、messages（私信）、music、harness_sessions / harness_events（Agent 会话与事件日志，(session_id, seq) 唯一索引）。

models/migrations.py 里 init_database() 做两件事：

1. Base.metadata.create_all(bind=engine) ——处理全新的表，只要模型类 被正确 import，这一行就够了。
2. 遍历 _ADDED_COLUMNS（一个 {表名: {列名: DDL类型}} 的字典）——处理 已经部署到生产环境、后来又加了新列的表，用 ALTER TABLE ... ADD COLUMN 补齐。

大白话：这不是 Alembic 那种“版本化迁移”（生成一串 `upgrade()` / `downgrade()` 脚本，能精确回滚到任意历史版本），而是一个更轻量的“幂等补丁”——每次启动都检查一遍“这张表该有的列都有了没，没有就加上”。对个人项目/小团队来说，这种方案维护成本更低；代价是没法回滚、没法表达“删列”“改类型”这类复杂变更。面试时如果被问“为什么不用 Alembic”，可以诚实地说这是“够用就好”的取舍，而不是没有能力用。

`harness_events` 表里的 `parent_id` 字段故意没有加索引——注释解释这是因为它后来用 `ALTER TABLE` 补上去的列，如果在模型定义里声明索引，会和“这张表实际部署环境里的真实结构”（没索引）产生偏差描述。这是个很小但很真实的细节：代码里的声明应该反映数据库的真实状态，不能只反映“理想状态”。

2.4 `main.py`：应用装配

```
app.include_router(api_router)      # 先挂 API
app.mount("/", StaticFiles(...))    # 最后挂静态文件
```

顺序不能反：`Mount("/")` 会匹配一切路径，如果它注册在 API 路由之前，所有 `/api/...` 请求都会被静态文件服务器截胡，返回 404（因为静态目录下没有叫 `api` 的文件）。这是路由匹配顺序敏感性的典型例子。

`routers/__init__.py` 是唯一定义 URL 地图的地方：`api_router = APIRouter(prefix="/api")`，依次 `include_router` `auth/users/memos/comments/messages/music/uploads/feeds/ai/` `harness/admin`。新增一个路由 = 一个新文件 + 一行 `include_router`，`main.py` 本身从不列举任何一条路由。

`lifespan()`（FastAPI 的应用生命周期钩子）在启动时依次做：初始化数据库 → 创建所有运行时目录 → `reset_running_sessions()`（把所有还标记为“运行中”的 Harness 会话状态修正为“空闲”，因为“没有一次 Agent 对话能活得比启动它的进程还久”——上次进程被杀掉时，这些会话就被腰斩了）→ 若 Feed 缓存为空则触发一次异步抓取 → 启动定时任务调度器（`APScheduler`，定时刷新 GitHub Trending / HuggingFace 论文等外部聚合内容）。还挂了一个自定义 `NoCacheMiddleware`，给 `.js/.css/.html` 响应加不缓存头，避免前端改了代码用户还吃到浏览器缓存的旧版本。

2.5 知识空间的业务功能一览

天启除了 Harness 和 `rl/` 之外，本身是一个融合了博客/社交/知识管理的小型应用：

- **Memos**（`routers/memos.py`）——短帖，支持位置、公开/私密、匿名发布、置顶、图片/文件附件、完整 CRUD。
- **评论**（`routers/comments.py`）——挂在 memo 下，可带图片。
- **私信**（`routers/messages.py`）——一对一消息，会话列表、已读/未读、附件。
- **音乐**（`routers/music.py`）——个人歌单的上传与流式播放。
- **上传**（`routers/uploads.py`）——通用文件服务，同样走 `storage_service / contained_path` 收敛检查。
- **Feeds**（`routers/feeds.py`）——聚合外部内容（GitHub Trending、HuggingFace、arXiv/Google Scholar 论文、Tophub），带 AI 分类（`/github/classified`、`/papers/classified`）和跨类别的 `/focus` 汇总视图，定时缓存刷新。
- **AI 助手**（`routers/ai.py`）——“天启精灵”聊天，加上 `/summarize`、`/explain`（支持图片输入的解释功能）等一次性辅助接口，以及 `/providers` 列出当前配置的供应商。
- **Harness**（`routers/harness.py`）——本书的核心，一个 Agent 工作台（会话、分叉、子代理委派、工具审批、实时事件流），默认仅管理员可用。

- **用户/管理**（`routers/users.py`、`routers/admin.py`）——公开的用户主页、管理员专属的用户管理（改角色、启禁用、重置密码、删除），并强制保证系统里至少留一个管理员（`admin.py` 里的 `_admin_count` 守卫）。

2.6 精灵聊天：非 Harness 的对照组

在深入 Harness 之前，先看一条完全独立、更简单的 LLM 调用链路——“天启精灵”聊天，作为理解 Harness 的一个对照组。POST `/api/ai/chat`（`routers/ai.py`）的完整流程：

1. 认证走 `require_user`；请求体 `ChatIn` 是一个消息列表。
2. 历史消息被裁剪到最近 `MAX_HISTORY_MESSAGES`（20）条——这一步发生在人设注入之前。
3. `ai_service.sprite_system_prompt()` 每次调用都重新从磁盘读取 `backend/data/prompts/sprite.md`（不缓存，改了立刻生效），把它作为 `system` 消息在裁剪之后再插到最前面——这样人设永远不会因为对话过长而被历史裁剪机制误伤挤掉。
4. `ai_service.chat_stream()` 通过 `core/providers.py::provider_config()` / `require_configured()` 解析出当前配置的供应商（`deepseek/gemini/ zhipu/openai/ollama/custom`，除 Ollama 外全部是 OpenAI 兼容的 SSE 格式），拼好请求体，用 `httpx.AsyncClient.stream("POST", ...)` 发起一次流式请求。
5. 响应按行解析——OpenAI 兼容格式是 `data: {...}` 的 SSE 帧，Ollama 是自己的一套 JSON-Lines 格式——逐段产出文本增量。
6. `routers/ai.py` 的 `event_generator()` 把每个文本增量包成 `core.sse.sse({"delta": chunk})` 一帧，以 `SSE_DONE` 结束；流已经开始后出现的错误以 `sse({"error": ...})` 的形式在流内传递（因为响应头已经发出，HTTP 状态码不可能再改变）。
7. 前端 `js/widgets/sprite-chat.js` 手工解析这些帧。

“天启精灵”的人设定义在 `sprite.md` 里——一个终结者般话少、不谄媚、参照《红色警戒 2》苏军坦克单位风格设计的人格，其中明确写了一条规则：“风格永远不能凌驾于正确性之上”（不知道就说不不知道，不能为了保持人设而编造答案），以及“用户明显情绪低落或要求正常语气时，应主动放弃这套人设”。

和 Harness 的核心区别（高层对照，Harness 从 2.7 节开始详细展开）：Harness 是一个独立的子系统（`harness/` 包），驱动的是带工具调用的多步 Agent 循环，有持久化的 `HarnessSession` / `HarnessEvent` 数据库行，自己的模型适配器层（`harness/llm/registry.py::build_adapter`）——但这个适配器刻意复用和精灵聊天完全相同的 `core.providers.provider_config()` / `require_configured()`，可以单独配置一个更强的 `HARNESS_MODEL`，独立于精灵聊天用的供应商。也就是说：底层“怎么拼供应商地址”这份逻辑是共享的一份，但 Harness 把它包进了一个有状态、会调工具的 Agent 循环里，而不是一次系统提示词 + 一次流式回复就结束。

2.7 前端：没有框架，靠约定维持可维护性

核心脚本加载顺序：`utils` → `auth` → `api` → `ui`，这四个文件是每个页面的公共底座，顺序不能乱，因为存在依赖关系：

1. `utils.js`：纯工具函数（HTML 转义 `escHtml`、日期格式化 `parseServerDate()`——SQLite 序列化的 UTC 时间不带时区后缀，需要手动补一个 Z、骨架屏、toast 提示），零依赖，挂到 `window` 上供其他脚本直接用。
2. `auth.js`：`Auth` 对象管理登录状态。关键设计——`Auth.token()` 不返回真正的 JWT，而是返回一个哨兵字符串 `'__cookie__'`（当用户已登录时）：

```
token() { return this._user ? '__cookie__' : ''; }
```

严谨定义：哨兵值（Sentinel Value）是一个不携带真实业务含义、仅用于表示“某种状态”的特殊值，目的是复用已有的条件判断语法而不暴露真实数据。

大白话：JWT 是 HttpOnly Cookie，JS 从代码层面读不到它（这是故意的，防 XSS 偷 token）。但前端代码里到处都要写 `if (Auth.token()) { ... }` 这种“判断是否登录”的逻辑，总不能因为读不到 token 就把这些判断全改写。于是让 `token()` 返回一个“看起来像 token，其实只是个开关”的假值——代码读起来还是自然的 `if (Auth.token())`，但它根本不是凭证，泄露出去也没有任何危害。

`Auth.csrfToken()` 则是真的从 `document.cookie` 里读 `mw_csrf`（这个 Cookie 故意不是 HttpOnly，前端必须读得到才能塞进请求头）。

3. **api.js**：`apiFetch()` 是唯一和后端对话的函数——自动加 `Content-Type`（除非是 `FormData`，要保留浏览器自动生成的 `multipart` 边界）、非安全方法自动带上 `X-CSRF-Token`、始终 `credentials: 'include'`（带上 Cookie）、非 2xx 状态码抛出携带服务端错误信息的 `Error`（`describeError()`）、401 时清空 `Auth` 状态。它只返回解析好的 JSON——这个限制很关键，直接导致了流式接口不能用它。

4. **ui.js**：全站共用的界面装配——粒子背景（`AntigravityBackground`）、鼠标拖尾、滚动进度条、`IntersectionObserver` 驱动的滚动动效、导航栏（移动端折叠、根据登录态渲染头像或登录/注册按钮）、以及 `ensureSpriteAssistant()`——一个“懒加载”引导函数，按需注入精灵相关的样式表和容器、加载 `floating-panel.js` + `Three.js`（如果还没加载过）、再加载 `sprite-chat.js`。这个引导逻辑保证了即使某个页面没有显式接入精灵组件（比如登录/注册/管理页面），精灵助手依然会被自动挂载出现。

流式接口为什么不能用 `apiFetch`：`Harness` 对话流、AI 精灵聊天流都是 SSE，响应是“一边生成一边吐字节流”，而 `apiFetch()` 设计成“等响应完整返回后解析 JSON”，天生不兼容流式场景。这些地方绕开 `apiFetch`，直接用裸 `fetch()`，手动补回 `credentials: 'include'` 和 `X-CSRF-Token`，再自己用 `response.body.getReader()` 逐块读取、按 `\n\n` 切分 SSE 帧、按 `data:` 前缀（注意这个空格）解析出 JSON。

面试话术：这是一个“通用封装 vs 特殊场景”的典型权衡——不是每个网络请求都套用同一个封装函数就是“更工程化”，流式响应有它自己的消费模型，硬套统一封装反而会增加理解成本。知道什么时候该“破例”，也是工程判断力的一部分。

三个可拖拽悬浮组件（AI 精灵、音乐播放器、时钟）共享同一套拖拽/缩放引擎 `js/widgets/floating-panel.js`：

- **拖拽起始阈值 4px**：鼠标按下后移动超过 4 像素才判定为“拖拽”，否则判定为“点击”——如果没有这个阈值，音乐播放器的“播放”按钮会因为鼠标按下瞬间的微小抖动被误判成拖拽，导致点击失效（`floating-panel.js` 里的 `DRAG_THRESHOLD`）。
- **定位方式固定用 `left / top`，绝不用 `transform`**：因为精灵组件自己有“待机呼吸”动画、时钟有“指针跳动”动画，这些动画本身就用 `transform` 实现。如果拖拽逻辑也去改 `transform`，两者会互相覆盖打架。
- 每个组件通过 `onResize(width, height)` 回调自己决定“变大了该怎么办”（3D 精灵是重新计算渲染分辨率，文本类面板是重新排版）——引擎本身不关心“缩放意味着什么”，只负责测量和分发事件，这是一个小型的策略模式应用。
- 布局状态存到 `localStorage`（键名 `mw_panel_<id>`），页面加载和窗口 `resize` 时都会做一次“夹回可视区域内”的校正（`clampToViewport`，保留至少 32px 可见），避免拖到屏幕外后找不到；双击缩放手柄会调用 `reset()` 用保存的 `cssText` 快照恢复原始样式；一次拖拽结束后紧跟的合成 `click` 事件会被吞掉，避免“松手瞬

间又触发了一次按钮点击”。

精灵组件的“无文字气泡”设计：AI 精灵「天启」没有传统的对话气泡，靠 眼睛形状、瞳色、光晕（MOODS 对象里定义的几种状态）来表达情绪。这背后有个真实踩过的坑：早期版本有一个“悬浮问候语”气泡，靠计时器控制显示/隐藏，结果和鼠标悬停状态的计时器产生竞态（谁先谁后不确定），有时候气泡卡住不消失。最终选择直接删掉这个交互，用更简单的视觉状态代替——**有时候修 Bug 最好的办法是移除引入这个 Bug 的功能，而不是加更多状态去堵漏洞。**

另一个细节：对话框展开动画用了 `transform: scale()`，如果用 `getBoundingClientRect()` 测量对话框尺寸，动画播放过程中测到的是“正在 缩放中的临时尺寸”，不是最终尺寸。改用 `offsetWidth / offsetHeight`（不受 CSS transform 影响的布局尺寸）来定位。同时对话框是“从几乎空白 开始、随着流式回复变长”的，所以还挂了一个 `ResizeObserver` 持续重新 定位——如果只在打开那一刻定位一次，回复变长后底部内容和输入框会被推到 可视区域外面。

首页“时间裂隙”滚动劫持：`js/pages/index.js` 用 `wheel / keydown / touchstart` 事件驱动首页的全屏分屏切换动画（三个 `.rift-section` 之间 切换，`goTo(next)` 加一个 900ms 的动画锁防止重入，配一组动态生成、随进度高亮的导航圆点）。如果不做任何处理，用户在 AI 精灵回复框里滚动 查看长文本时，滚轮事件会同时被首页的全局监听器捕获，导致回复框内容和 背后的整个页面一起滚动/翻页。解决方式是维护一个 `OVERLAYS` 白名单（`.chat-dialog`, `#sprite-container`, `#sprite-clock`, `#music-player`），所有全局滚动/按键/触摸事件处理器在派发前先检查事件是否发生在某个悬浮层 内，是则直接放行、不做劫持——这个白名单同样应用在方向键（`ArrowUp/Down / PageUp/Down`）和触摸滑动（50px 阈值）的处理逻辑上。

THREE.js 精灵渲染的降级策略：`new THREE.WebGLRenderer()` 不仅在 THREE.js 库没加载成功时会抛异常，在浏览器/显卡不支持创建 WebGL 上下文 时也会抛异常（比如某些虚拟机、被禁用硬件加速的环境）。两种情况都会 fallback 到 `useFallbackSprite()`（一个更简单的 2D 精灵）。这里有个必须 小心处理的细节：如果这个 fallback 函数本身没有被 try/catch 包住就抛了 异常，会连带把点击处理器和 `toggleSpriteChat` 函数一起带崩，导致整个 AI 助手在这类环境下完全不可用、且没有任何错误提示——一个兜底方案本身 如果不够健壮，就不是真正的兜底。

Harness 检查器界面（三栏布局：会话列表 / 对话区 / 四页签检查器）会在 2.21 节详细展开，这里先建立整体印象：中间对话区靠一个简单的状态 对象 `{ sessionId, events, registry, tab, running, search }` + 手动 调用渲染函数重新构建 DOM 驱动，没有引入任何前端框架的响应式系统。

2.8 Harness 是什么：全书真正的核心

从这里开始是全书含金量最高的部分。**Harness（智能体工作台）**是部署在天启 网站上的一个独立子系统，访问路径 `/harness.html`。它参照了 `deepseek-ai/deepseek-harness` 的两个核心设计思想重新实现（不是照搬其 TypeScript 代码），本质上是一个**最小可用的 Agent Runtime**：给一个 LLM 配上工具调用能力、人工审批、沙箱执行环境、完整的可追溯日志、上下文压缩、多智能体委派。

严谨定义：Agent Runtime（智能体运行时）指一套支撑“LLM 反复思考-调用 工具-观察结果-再思考”这一循环（通常称为 ReAct 循环：Reasoning + Acting）稳定运行的工程基础设施，包括但不限于：消息拼装、工具调用解析与执行、权限控制、状态持久化、错误恢复。

大白话：ChatGPT 网页版你看到的是“一问一答”，但背后如果这个模型能 自己调用工具（搜索、写代码、跑命令），就需要一整套“脚手架”去处理：“模型 说要调用哪个工具？参数对不对？敢不敢真的执行？执行结果怎么喂回给模型？模型会不会陷入死循环？中途网页关了怎么办？”——这套脚手架就是 Harness，跟 Claude Code、Cursor Agent、Devin 背后的核心机制是同一类东西。

为什么这部分对求职最有价值：LLM Post-Train / Agent 开发岗位的面试，最怕的就是候选人只会说“我用 LangChain 搭了一个 Agent”——这句话信息量几乎 为零，因为 LangChain 把所有工程细节都封装掉了，面试官问不出你真正理解了什么。而这个项目是从裸的 HTTP 请求开始，自己实现了整套 Agent Runtime，这意味着你能回答面试官任何一个“往下再问一层”的问题——工具调用的流式响应 怎么解析、用户中途关掉浏览器 Agent 还在执行怎么办、上下文超长了怎么办、多个 Agent 互相调用会不会失控。这些问题的答案分布在接下来的 2.9 ~ 2.21 节。

2.9 设计原则一：可替换的能力接缝（Replaceable Seams）

严谨定义：接缝（Seam）在软件设计中指系统里“可以在不修改调用方代码的前提下，独立替换其行为”的一个点，通常通过面向接口编程（这里是 Python 的 Protocol，即结构化类型协议）实现。

大白话：给关键组件都套一层“插座”——用电器的時候你不用管电到底是 水电还是火电发的，只要插头规格（协议）对上就能用。Harness 里有四个 这样的“插座”：

接缝	协议定义在	默认实现	换成什么样才需要改代码
SessionStore	session/store.py	SqliteSessionStore	换成 Redis/Postgres 存储事件日志
ModelAdapter	llm/base.py	OpenAICompatibleAdapter	接入不兼容 OpenAI 协议的模型
Sandbox	sandbox/base.py	LocalSandbox	换成真正的容器级隔离（如 gVisor/Firecracker）
ToolRegistry	tools/registry.py	基于契约文件扫描	换成远程工具注册中心

这四个接缝全部在 `harness/context.py::build_context()` 一处被“组装”起来——这是整个系统唯一挑选具体实现的地方，其余所有代码只依赖协议类型（类型 注解写的是 `Any /Protocol`，不是具体类）。

```
# 大致形状
def build_context(session_id, preset) -> HarnessContext:
    return HarnessContext(
        store=SqliteSessionStore(),
        llm=build_adapter(model),
        tools=ToolRegistry(preset),
        sandbox=LocalSandbox(workspace),
        hooks=build_hooks(),
        ...
    )
```

这为什么重要：这是“依赖倒置原则（Dependency Inversion）”的教科书级实践——高层模块（Agent 循环）不依赖低层模块（具体的 SQLite 实现）的细节，两者都依赖抽象（Protocol）。面试被问“如果要把存储换成 PostgreSQL 你会怎么改”，答案应该是“只改 `build_context` 这一行，新写一个实现 `SessionStore` 协议的类”——这说明你理解这个设计的意图，而不是背答案。

`rl/` 部分（第三部分）会把这条原则再兑现两次：`MemorySessionStore` 替换 `SqliteSessionStore`、`EvalAdapter / PolicyAdapter` 替换 `OpenAICompatibleAdapter` ——同样的循环、同样的投影函数，只换了两个“插头”。

2.10 设计原则二：全链路可追溯（Everything the Model Sees Is Logged First）

这是比第一条更核心、更“反直觉”的设计约束：

不变量：发给模型的每一条消息，必须先作为一个事件写进 append-only（只追加）的会话日志，然后才能被用来构造下一次请求。`harness/session/projection.py::derive_messages()` 是唯一被允许把日志转换成模型请求消息的函数。

严谨定义：Append-Only Log（只追加日志）指一种只允许在末尾添加新记录、不允许修改或删除已有记录的数据结构；配合“当前状态由日志重放推导得出”，就是**事件溯源（Event Sourcing）**模式。

大白话：这条规则听起来像是“多此一举”——为什么不直接维护一个 `messages = [...]` 列表，模型说什么就往里 append，要发请求时直接拿去用？因为这样做会导致一个致命问题：“**模型实际看到的东西**”和“**你以为模型看到的东西**”可能会悄悄分叉。举个例子——如果系统提示词里嵌入了当天日期，你在“读取历史会话、重新渲染”的时候如果重新计算一遍系统提示词，得到的日期就变成了“今天”，而不是模型当时真正看到的那个日期。日志里没记下来的东西，永远无法准确复原。

这个不变量在代码里具体怎么落地——`harness/loop/agent.py` 里的循环先执行 `emit()`（写日志），再把这个事件 **yield 给上层**（用于 SSE 推送给前端）——顺序不能反，如果反过来，前端可能会看到一个“还没真正持久化”的事件，一旦这时候进程崩溃，前端展示过的东西和日志里实际存在的东西就对不上了。

系统提示词快照就是这条规则的直接后果：系统提示词本身会随 `config/change` 事件写进日志（仅在内容变化时才写一次，不是每条消息都重复记）。为什么连“系统提示词”这种看起来是“配置”而不是“对话内容”的东西也要进日志？正是因为它嵌入了当天日期，且由 `system.md` 文件拼出来，这个文件本身也会被改动。如果历史会话被重放时“实时重新计算”系统提示词，会出现两个问题：显示的日期变成了重放那天而不是对话发生那天；如果 `system.md` 后来被改过，所有历史会话的“系统提示词”会被整体篡改，而模型当时根本没看过这个新版本。所以 `derive_messages()` 的规则是：**优先用日志里记录的快照，只有旧版本（早于快照机制上线前）留下的会话，才回退用当前配置现算。**

2.11 SessionEvent：一切的最小单位

backend/harness/events.py 定义了这个系统里唯一的持久化数据结构：

```
@dataclass(frozen=True)
class SessionEvent:
    type: str      # 如 "user/message" "tool/call"
    seq: int       # 会话内严格递增的序号
    time: int      # 毫秒级 Unix 时间戳
    data: dict     # 该事件类型专属的数据
```

frozen=True 让实例不可变（Immutable）。

大白话：为什么要设成不可变？因为它对应的正是日志“只能追加、不能修改”这条业务规则。让数据结构本身在语言层面就“改不了”，比“大家记得别改它”这种口头约定可靠得多——这是“让非法状态无法表示（Make illegal states unrepresentable）”这条设计原则的具体应用。

19 种事件类型分两大阵营：

阵营	事件类型（举例）	作用
会投影进模型请求 (SURFACE_TYPES)	user/message 、 assistant/message 、 tool/result	这三种，也只有这三种，会被 derive_messages() 转换成发给模型 的消息
仅用于日志/重放/前端展示	session/start 、 turn/start 、 turn/end 、 step/start 、 step/end 、 assistant/chunk （原 始流式分片）、 tool/call 、 tool/approval 、 llm/usage 、 compaction/summary 、 subagent/start 、 subagent/end 、 agent/error 、 agent/interrupt 、 config/change	不占用模型上下文，但对调试、计费、轨 迹回放、断线恢复都是刚需

还有一个 IGNOREABLE_TYPES 集合，表示“一个不了解全部类型的读者可以安全 跳过它们”，但 config/change 被特意排除在这个集合之外——因为它携带着系统提示词快照，跳过它会导致重放丢失关键上下文。KNOWN_TYPES 是全部合法类型的封闭集合：遇到不认识的类型，重放逻辑要直接报错中止，而不是悄悄忽略——因为“悄悄丢弃未知数据”本身就违反了“全链路可追溯”的不变量。



图 2.2：事件日志到模型请求的投影关系——只有 `config/change`（系统提示词 快照）、`user/message`、`assistant/message`、`tool/result` 四类事件会 最终出现在发给模型的 `messages` 数组里，其余全部是“旁路信息”。

2.12 存储层：SessionStore 协议与 SQLite 实现

```
class SessionStore(Protocol):
    def append(self, session_id, type, data) -> SessionEvent: ...
    def append_many(self, session_id, events) -> list[SessionEvent]: ...
    def read(self, session_id, after_seq=-1) -> list[SessionEvent]: ...
    def next_seq(self, session_id) -> int: ...
```

默认实现 `SqliteSessionStore`：

- 每次调用都各自开关一次数据库会话，不持有长连接。为什么？因为一次 Agent 对话可能跑好几分钟，如果一直占着一个数据库连接不放，在 SQLite 这种“写操作互斥”的引擎上会长时间锁住其他会话的写入。
- seq 怎么保证递增不重复：查 `MAX(seq)+1` 作为下一个序号，写入时 靠数据库层面的 `UNIQUE(session_id, seq)` 索引兜底——如果两个并发请求 同时算出了同一个 `seq`，后写入的那个会触发 `IntegrityError`，代码 捕获后回滚重试（最多 5 次）。

严谨定义：这是一种乐观并发控制（Optimistic Concurrency Control）——不提前加锁阻止并发，而是允许冲突发生，靠数据库唯一约束 在写入时兜底检测冲突，检测到就重试。

大白话：不是“先派号再排队”，是“大家都猜自己该拿几号，撞了号就 有一个人重新猜”——在冲突概率不高的场景下，这比每次都先加锁再操作 效率更高。

- `append_many` 一次性认领一段连续的 `seq` 区间，在一个事务里写完—— 这正是流式回复分片批量落盘的优化基础（2.16 节）。
- 读取时如果某一行的 `data` 字段是损坏的 JSON，会捕获异常、用空字典 `{}` 代替，不会让一条脏数据搞垮整个会话的重放——这是“局部容错 优于全局崩溃”的工程直觉。

数据表结构：

```
harness_sessions
  id (uuid hex, PK) | user_id (FK) | title | preset | status
  forked_from | forked_at_seq | parent_id | agent | created_at | updated_at

harness_events
  id (自增PK) | session_id (FK, CASCADE) | seq | type | time | data(JSON文本)
  唯一索引 (session_id, seq)
```

2.13 投影函数：`derive_messages()`

这是“全链路可追溯”这条不变量在代码里唯一的落地入口，位于 `harness/session/projection.py`。

逻辑拆解：

1. 找系统提示词：`logged_system_prompt(log)` 从后往前扫描日志，找最近一条 `config/change` 事件里的 `system_prompt` 字段。`derive_messages()` 优先用这个快照，只有找不到（早期会话）才退回用传进来的 `system_prompt` 参数（当前配置现算的版本）。
2. 叠加压缩摘要（如果存在）：如果日志里有 `compaction/summary` 事件，把摘要文本追加到系统消息的一个固定中文小标题下面，同时跳过所有 `seq <= covered_to` 的事件——已经被摘要覆盖的原始事件不再参与投影（但原始事件本身一条都不删，只是不再参与“造消息”这一步）。
3. 逐条转换：
 - `user/message` → 一条 user 消息；
 - `assistant/message` → 一条 assistant 消息（带上 `content` 和 `tool_calls`，如果有的话）；紧接着，对这条消息里的每一个 `tool_call`，立刻在结果列表里查找并插入它对应的 `tool/result` 事件（按 `call_id` 匹配，而不是按这个 `tool/result` 事件在日志里出现的位置）——因为 OpenAI 协议要求“一个 assistant 消息如果带了 `tool_calls`，紧跟着的每个 tool 消息必须严格对应”。
 - 如果某个 `tool_call` 在日志里找不到匹配的结果（比如对话在审批环节被中断、或者被压缩切掉了），会插入一条占位内容：“[未完成：该工具调用被中断或取消]”——这是必须做的，因为大多数 provider 会直接拒绝一个“带了 `tool_calls` 但缺少对应 tool 结果”的请求，不补这个占位符会导致整个请求报错。

面试提示：`derive_messages()` 这个函数名字本身就体现了“投影（Projection）”这个词在事件溯源语境下的含义——当前请求要发的消息列表，是从历史事件“派生（derive）”出来的一个视图，而不是一份独立维护的状态。这意味着“历史消息”这个概念在系统里根本不单独存在一份，它每次都是现算的——这保证了“模型看到的历史”和“日志记录的历史”永远是同一个东西，不可能出现同步不一致。

`compaction_boundary(log, keep_recent_turns=2)` 返回倒数第 `keep_recent_turns` 条 `user/message` 的 `seq` 减一——为什么一定要切在紧挨着一条 user 消息之前？因为这是唯一不会把某个 `tool_call` 从它对应的 `tool_result` 中间切断的位置——一个 Turn 内部，`assistant/message`（带 `tool_calls`）和它的 `tool/result` 总是紧紧挨在一起，只有“两个 Turn 之间”（也就是一条新 user 消息发出之前）才是安全的切割点。

`estimate_tokens()`（`total_chars / 2.5`）只用来做决策，不用来做真实计费——真正的计费和“是否达到压缩阈值”的判断，用的是 2.24 节讲的 provider 真实返回的 token 数。

2.14 会话状态管理：`SessionManager`

`harness/session/manager.py` 负责会话的生命周期。

状态推导为什么不能只看“最后一条事件”：

```
STATUSES = (idle, running, awaiting_approval, error)
_TERMINAL_STATUS = {
    TOOL_APPROVAL: "awaiting_approval",
    AGENT_ERROR: "error",
    TURN_END: "idle",
    AGENT_INTERRUPT: "idle",
}
```

天真的做法是“看日志里最后一条事件的类型来判断当前状态”，但这在这个系统里 **是错的**——因为 2.15 节会讲到，循环里 step/end 事件是在 tool/approval **之后**才发出的（记录这一步因为等待审批而暂停”。如果只看最后一条，会把“正在等人审批”误判成“这一步已经正常结束”。

正确做法：`_turn_outcome()` 在“所有终态候选事件类型 + `turn/start`”里找 **时间最新的那一条**——因为同一个 Turn 内，`turn/start` 必然出现在它对应的终态事件之前，如果 `turn/start` 是最新的，说明这个 Turn 还没走到任何终态，仍然“进行中”。

断线保护：`reconcile_status` + 心跳窗口：

```
def reconcile_status(row):
    if row.status != "running":
        return row
    healed = _turn_outcome(row.id)
    if healed.status is None: # 日志里还没有终态事件
        if now_ms() - healed.last_time <= 180_000: # 3 分钟心跳窗口
            return row # 相信它还在正常运行
        else:
            row.status = "idle" # 判定为失联的僵尸会话，强制拉回空闲
```

大白话：如果一个会话标记为“运行中”，但日志里最后一条事件已经是 3 分钟前的了，大概率是后端进程重启、或者流式连接异常中断导致这次对话“烂尾”了，永远不会再有新事件写进来。与其让它在数据库里永远显示“运行中”、把用户卡在一个转圈的界面上，不如主动“体检”一次、拉回空闲状态。

为什么清理逻辑放在 `BackgroundTask` 而不是流式响应的 `finally` 里：这是一个极易被误解、但在真实生产系统里非常关键的坑：

反直觉但正确的做法：一个 `async def generator(): yield ...` 形式的流式响应生成器，如果客户端中途关闭了连接（比如用户直接关掉浏览器标签页），Python/Starlette **不保证**这个生成器的 `finally` 块会被立即执行、甚至 **不保证它一定会被执行**——挂起的异步生成器可能被垃圾回收器在任意延迟之后才清理，也可能因为某些实现细节永远悬挂在那里。

正确做法是把清理逻辑（`interrupt.finish()` + `manager.finalize_turn()`）作为 Starlette 的 `BackgroundTask` 传给 `StreamingResponse`——它会在响应流结束（不管是正常结束还是客户端断连导致异常结束）之后被调度执行，这是框架层面提供的保证，比依赖生成器自己的 `finally` 可靠得多。再叠加上面那层 `reconcile_status` 的心跳检测作为最后一道兜底，双保险确保“会话不会永远卡在运行中”。

子代理的费用汇总：`usage_summary()` 会递归汇总当前会话和所有 `parent_id` 指向自己的子会话的 `llm/usage` 事件——“实测一次派发里子代理花掉的 token 比主 Agent 还多，分开算就会严重低估”。

其他细节：`fork(session_id, user_id, seq)` 支持从任意事件序号“分叉”出一个新会话（复制历史日志 + `shutil.copytree` 复制整个工作区目录），天然支持“试了一条思路走错了，从某一步重新分叉再试另一条路”的调试场景；`list_for_user()` 排除所有 `parent_id` 非空的会话（子代理会话），避免侧边栏被大量子会话淹没。

2.15 主循环：`_drive()` 一步步拆解

`backend/harness/loop/agent.py` 是整个 Harness 的心脏。`run_turn()` 的入口很短：

```
async def run_turn(hctx, user_text):
    interrupt.begin(hctx.session_id)
    if user_text:
        hctx.emit(USER_MESSAGE, {"text": user_text})
        hctx.emit(TURN_START, {})
    try:
        async for event in _drive(hctx):
            yield event
    finally:
        interrupt.finish(hctx.session_id)
```

`resume_turn(hctx, call_id, approved)` 是另一个入口，用于某个工具调用之前卡在“等待人工审批”、现在人给出了批准/拒绝的答复之后继续跑下去：

```
if approved:
    await _execute(hctx, call)          # 跳过审批检查，直接执行——已经问过了
else:
    hctx.emit(TOOL_RESULT, {..., "denied": True, "is_error": True})
    await _run_pending_calls(hctx)      # 同一条 assistant 消息里的其他待处理调用
    async for event in _drive(hctx):    # 继续走主循环
        yield event
```

`_drive()` 是全文件最核心的函数，`for step in range(hctx.max_steps)` 循环体依次做以下事：

第 1 步：检查中断——`interrupt.is_set(hctx.session_id)`，是则 emit `agent/interrupt` 并 `break`。

第 2 步：PRE_STEP 钩子——一个可挂载的“步骤开始前”检查点，标准部署没有挂东西在这个点上，但它是一个天然的扩展位。

第 3 步：请求模型（流式）——`_request_model()` 内部先跑一次上下文压缩检查（2.24 节），再调用 `derive_messages()` 拿到要发的消息，然后调用 `ModelAdapter.stream()`。如果 `result is None`（流式过程中被打断），emit 一个 `step/end{stopped: true}` 然后 `break`。

第 4 步：落盘模型的回复——emit `assistant/message`（`content`、`reasoning`、`tool_calls`、`finish_reason`）和 `llm/usage`。

第 5 步：判断要不要继续——如果没有 `tool_calls`，emit `step/end` 然后 `break`：模型给出了不带工具调用的最终回复，Turn 结束。

第 6 步：执行工具调用——`_run_pending_calls(hctx)` 依次处理每一个待处理的调用，返回两个布尔标记：`awaiting`（这一步遇到了需要人工审批的调用）、`halted`（遇到了中断，或者某个工具结果标记了 `stops_turn=True`，比如 `exit_plan_mode`）。

第7步：step/end 的发出时机——注意：step/end 是在 tool/approval 事件之后才发出的。这不是随手写的顺序，而是刻意的——如果反过来，会给 2.14 节讲的会话状态推导逻辑造成误判风险。这也是 `SessionManager._turn_outcome()` 为什么不能简单地“只看最后一条事件”、而要在多种候选类型里找“时间最新”的那条的根本原因——两件事互为因果，理解了其中一个就理解了另一个。

第8步：三种收尾方式：

```
if awaiting:
    return # 直接 return——这轮对话还“开着”，等人来批
if halted:
    break # 跳出循环，走到下面统一的 turn/end
else:
    # for...else: 循环耗尽 max_steps 都没跳出
    hctx.emit(AGENT_ERROR, {"stage": "max-steps"})

hctx.emit(TURN_END, {}) # 唯一没有触发这行的路径是 awaiting 的 return
```

大白话：return 和 break 在这里承载了不同的业务语义——return 意味着“这轮对话还没死，只是卡在等人点头”，break 意味着“这轮对话该收尾了，不管是正常结束、被打断，还是跑满了步数上限”。只有走到收尾流程才会发 turn/end，所以前端只要看到没有 turn/end，就知道这个 Turn 处于“待审批”或者“仍在流式生成”的状态，不需要额外维护一个专门的“是否结束”标志位。




图 2.3：一次 Turn 内部的事件状态机——step/end 严格发生在 tool/approval 之后，awaiting 分支用 return 挂起而不发 turn/end，这是理解会话状态推导逻辑的关键。

2.16 `_request_model()`：流式分片的批量落盘

```
async def _request_model(hctx):
    log = maybe_compact(hctx, hctx.store.read(hctx.session_id), hctx.context_budget)
    _snapshot_prompt_if_changed(hctx, log) # config/change, 仅内容变化时才写
    messages = derive_messages(log, hctx.system_prompt)

    buffer = []
    async for delta in hctx.llm.stream(messages, tools=hctx.tools.schemas()):
        if interrupt.is_set(hctx.session_id):
            flush(buffer); hctx.emit(AGENT_INTERRUPT, {}); return
        buffer.append(delta)
        if len(buffer) >= CHUNK_FLUSH_SIZE or elapsed >= CHUNK_FLUSH_SECONDS:
            flush(buffer) # 批量写一次 assistant/chunk
        if delta.result is not None:
            flush(buffer) # 关键：必须先把缓冲区清空
            yield delta.result # 再把最终结果吐出去
```

为什么要“批量刷新”而不是每个 token 都落盘一次：代码注释给出了一个具体数字——如果每个 token 都单独触发一次数据库写入（append），实测这部分开销能占掉一次长对话总耗时的约五分之一。所以设置了两个刷新条件——攒够 `CHUNK_FLUSH_SIZE=32` 个分片，或者超过 `CHUNK_FLUSH_SECONDS=0.15` 秒，任一条件先满足就刷新一次（借助 `append_many` 一次事务写入一批事件的能力）。

面试话术：这是一个典型的“吞吐量 vs 实时性”权衡——完全不攒批，每个 token 都立即持久化，实时性最好但吞吐量最差；攒太大批次，吞吐量好但用户会感觉界面“卡顿式”地一大段一大段往外蹦字，体验变差。0.15 秒这个时间阈值就是“人眼感知不到延迟，但已经能攒下不少 token”的经验取舍点。

为什么最终结果必须在缓冲区清空之后才 yield：如果反过来，先把最终的 `assistant/message` 事件发出去，再补发缓冲区里剩下没刷新的分片，就会出现“完整消息已经落盘了，但拼出这条消息的部分原始分片还没落盘”的乱序——重放时时间线会自相矛盾。这是“全链路可追溯”这条系统级不变量，在一个具体函数内部的微观体现。

2.17 工具调用的执行链路与“状态完全从日志重建”

```
_run_pending_calls()
└─ 对每一个还没有 tool/result 或 tool/approval 的 tool_call:
    _run_call()
    emit(TOOL_CALL, ...)
    如果工具名不存在于 registry → 直接返回错误的 tool/result
    否则：跑 PRE_EXECUTE 钩子 (=审批策略)
        DENY → 直接返回错误的 tool/result
        ASK → emit(TOOL_APPROVAL, ...), 函数直接 return (还没结果)
        否则 → _execute()
            result = await hctx.tools.execute(...)
            emit(TOOL_RESULT, {..., "stops_turn": spec.stops_turn and not is_error})
```

`_run_pending_calls()` 一次只处理一个调用，处理到 `TOOL_APPROVAL` 就立刻停止——一条 assistant 消息可能带了多个并行的 `tool_calls`，如果其中第 2 个需要审批，第 3、4 个不会被抢跑执行，必须等第 2 个的审批结果出来之后（`resume_turn` 里的 `_run_pending_calls` 才会继续跑剩下的）。

```
def _pending_calls(log):
    settled_ids = {e.data["call_id"] for e in log if e.type in (TOOL_RESULT, TOOL_APPROVAL)}
    return [tc for tc in latest_assistant_message(log).tool_calls if tc.id not in settled_ids]
```

这一段也是“全链路可追溯”不变量的又一处体现——“哪些调用还没处理完”这个信息，不是维护一个内存里的 Python 变量去追踪，而是每次都从日志里现查。这意味着即使进程重启、即使是在 `resume_turn()`（一次全新的函数调用，没有任何跨调用共享的内存状态）里，逻辑也完全一致，不需要专门做“状态恢复”——日志本身就是唯一的状态。

2.18 钩子系统与中断机制

`harness/loop/hooks.py` 提供两个挂载点：`PRE_STEP`（每一步开始前）和 `PRE_EXECUTE`（每次真正执行一个工具调用前，审批策略就挂在这里）：

```
class HookBus:
    def on(self, point, name, listener): ...
    def emit(self, point, *args):
        for listener in self._listeners[point]:
            answer = listener(*args)
            if answer is not None:
                return answer      # 第一个给出明确答案的监听器胜出，短路后面的
        return None
```

单个监听器抛异常会被记录日志后跳过，不会让整个 Turn 崩掉——钩子系统被设计成“锦上添花”而不是“单点故障源”。

`harness/loop/interrupt.py` 用一个进程内字典 `{session_id: asyncio.Event}` 记录中断请求，故意不做成跨进程/持久化的：

```
def begin(session_id): _tokens[session_id] = asyncio.Event()
def request(session_id) -> bool:
    event = _tokens.get(session_id)
    if event is None: return False
    event.set(); return True
def is_set(session_id) -> bool: ...
def finish(session_id): _tokens.pop(session_id, None)
```

中断只在两个检查点生效：每一步开始前、流式过程中每收到一个分片时。这意味着中断不能打断一个“正在执行中的工具调用”——如果一个 `bash` 命令正在跑，用户点了停止，这次调用会跑完（或者被沙箱自己的超时机制杀掉），下一次到达检查点时才会真正停下来。

大白话：这不是偷懒，是诚实——“立即取消一个正在执行的系统调用”在通用场景下本来就很难做到干净（可能留下一半写完的文件、一个僵尸子进程），与其假装能做到“瞬间打断”，不如老老实实说清楚“中断信号会在下一个安全点生效”，把“这次调用到底该不该被强制杀掉”的责任交给沙箱自己的超时机制。

`finish()` 是“尽力而为”的清理——如果客户端直接断连，可能永远不会被调用到，这也是为什么 2.14 节讲的 `reconcile_status` 心跳检测必须作为独立的兜底存在，不能依赖 `interrupt.finish()` 一定会执行。

2.19 数据与代码分离：工具的“契约”和“实现”是两个文件

这一节和 2.20 节讲两件事：**Function Calling** 在这个项目里是怎么落地的，以及**Human-in-the-loop**（人工审批）机制怎么设计——这是 Agent Infra 面试里最常被追问细节的部分。

严谨定义：数据与代码分离（Data/Code Separation）指把“描述行为的元数据”（这里是工具名称、描述、JSON Schema、权限级别）与“真正执行行为的代码逻辑”拆到两个独立的文件/系统里维护，前者通常是配置文件或数据文件，后者是程序代码。

大白话：一个工具在这个系统里的“说明书”（给模型看的名字和描述、参数长什么样）和“怎么干活”（Python 函数体）是分开放的。好处很直接——**改一句工具描述、调一下参数命名，不需要碰任何 Python 代码，也就不需要重新部署。**这对“给模型调优提示词措辞”这种高频、低风险的操作特别友好。

一个工具由两个文件组成：

```
harness/data/tools/<模块>.json    ← 契约：name/description/parameters(JSON Schema)/permission
harness/tools/builtin/<模块>.py    ← 实现：导出一个 HANDLERS = {"工具名": 函数, ...}
```

ToolSpec（tools/base.py）是两者合体后的最终形态：

```
@dataclass(frozen=True)
class ToolSpec:
    name: str
    description: str
    parameters: dict          # 原样来自契约 JSON，直接就是 JSON Schema
    permission: str           # "read" | "write" | "exec"
    handler: Callable         # 绑定好的 Python 函数
    module: str
    stops_turn: bool = False

    def to_wire(self):
        # 渲染成 OpenAI 风格: {"type": "function", "function": {...}}
```

`.to_wire()` 就是真正塞进 `POST /chat/completions` 请求体 `tools` 字段里的那个 JSON——这也是“Function Calling”这个术语在工程上的真正含义：**不是模型自己会执行代码，而是模型被告知“你可以以某种结构化格式请求调用某个函数”，服务端解析这个请求、真正执行、把结果重新喂回去。**

两个具体例子：

- **current_time（时钟）**——最简单的工具。契约 `data/tools/clock.json` 声明一个可选的 `timezone` 字符串参数。处理函数 `tools/builtin/clock.py::current_time(ctx, timezone="")` 是一个纯函数，不做任何 I/O，格式化返回本地+UTC 时间文本；文件底部 `HANDLERS = {"current_time": current_time}` 就是注册表要读的绑定表。
- **corpus_search / corpus_open / corpus_answer**——为 Deep Research 预设准备的三工具“环境”，契约 `data/tools/corpus.json`，实现 `tools/builtin/corpus.py`。三个设计点：① `corpus_search` 只返回 标题+摘要，从不返回元数据，强迫模型必须再调一次 `corpus_open`——这一点对第三部分讲的“多跳问答难度”是承

重的；② `corpus_answer` 标记 `stops_turn: true`，返回一个不含正确性的固定确认串，专门用来防止模型把验证器变成一个免费的神谕；③ 它刻意绕开工作区/沙箱，直接读一份进程全局的只读语料（`harness.corpus.store.load_cached`）——因为这里根本没有“写”这回事，不需要写保护。

```
data/tools/*.json  (契约: name / description / JSON Schema / permission)
|
| 按契约目录 sorted() 扫描发现
▼
tools/builtin/*.py (实现: HANDLERS = {name: handler})

契约有 .json, 没有匹配 .py 里的 HANDLERS 项 → ValidationError (启动即报错)
.py 里有 HANDLERS, 但没有匹配的 .json 契约 → 仅记一条 info 日志 (死代码, 不报错)
```

图 2.4：工具契约与 handler 绑定关系——两种失配情形的处理方式完全不同，体现“打包错误立即失败、未引用代码静默忽略”的分级容错思路。

注册表：`load_specs()` 怎么发现所有工具：

```
def _discover():
    for path in sorted(TOOLS_DIR.glob("*.json")): # 按文件名排序
        module = import_module(f"harness.tools.builtin.{path.stem}")
        if path.stem not in loaded_modules and not hasattr(module, "HANDLERS"):
            raise ValidationError(...) # 契约有了, 实现没有 → 启动直接报错
```

三条硬规则：① 按契约目录扫描发现，新增工具只要放对两个文件，重启后自动生效（前提是没被 `_MODULE_GATES` 挡住）；② 契约没有匹配的 实现 → `ValidationError`，在应用启动时就报错——这是“快速失败（Fail Fast）”原则的典型应用：打包错误应该在部署阶段被发现，而不是留到用户真正触发它的那一刻；③ 实现有 `HANDLERS` 但没有匹配契约 → 只记一条 info 日志，这个模块被当成死代码，不加载也不报错——因为这不是“配置损坏”，只是“这份代码暂时没被引用”，不需要用错误级别去打扰。

为什么用 `sorted()`：Prompt 前缀缓存——这行 `sorted()` 表面上只是“让输出有确定性顺序”，但更深的理由是：扫描得到的顺序最终会变成请求里 `tools` 数组的顺序，而 LLM provider 的前缀缓存只有在请求前缀逐字节一致的情况下才能命中（第一部分 1.10 节）。`compose_prompt()`（`context.py`）拼系统提示词时也遵循同一个原则——把“稳定不变的部分”（工具目录说明、技能目录、子代理目录）放前面，把“易变的部分”（`runtime_context()`，只带日期）放在最后，最大化能命中缓存的前缀长度。

预设怎么选工具（`expand_tools()`）：预设文件（`data/presets/standard.json / minimal.json`）和子代理角色定义（`data/agents/*.json`）共享同一套 `tools` 字段语法——直接写工具名、`"*"`（全部可用工具）、`"<模块>:*"`（某个模块导出的全部工具）。`standard` 模式用 `"*"`（新工具丢进去、重启后立刻自动可用，不需要手动维护清单）；`minimal` 模式反过来保留一份显式清单——它的定位是“可复现的对照基准”，新加了什么工具都不该悄悄改变 `minimal` 模式的行为。

部署级“总闸”：`_MODULE_GATES`：

```
_MODULE_GATES = {
    "shell": lambda settings: settings.harness_shell_enabled,
    "subagent": lambda settings: settings.harness_subagent_enabled,
    "corpus": lambda settings: settings.harness_corpus_enabled,
}
```

这个逻辑在预设的 `"""` 通配符展开之后才应用——意味着即使某个预设写了 `"""`，如果部署方在 `.env` 里没打开对应开关，这些工具依然不会出现。这是一条很重要的“权限层级”设计：**用户/角色级别的配置（预设文件）永远不能覆盖部署级别的开关（环境变量）**——后者才是最终的安全边界。也正是这个机制，让 `corpus` 这三个 RL 专用工具能安全地存在于仓库里而不会平白出现在线上站点的 Agent 工具列表里、更不会打破线上 Agent 的前缀缓存。

工具失败是“值”，不是“异常”：

```
def execute(self, name, arguments_json, ctx):
    try:
        args = parse_arguments(arguments_json)
        _reject_unknown_arguments(handler, args) # inspect.signature 检查参数名
        return handler(ctx, **args), False      # (结果文本, is_error=False)
    except AppError as e:
        return f"错误: {e.message}", True
    except TypeError as e:
        return f"参数不匹配: ...", True
    except Exception:
        logger.exception(...)
        return "工具执行时发生未知错误", True
```

大白话：工具执行失败不会让整个 Turn 崩掉、也不会往上抛异常打断循环——而是把“失败”本身变成一段文本，正常走 `tool/result` 这条通路喂回给模型。这样模型能“看到”自己刚才这次调用失败了、失败原因是什么，然后**自己决定要不要换个方式重试**——这正是“让模型自己纠错”这种 Agent 常见模式的工程基础：错误信息本身也是模型推理链条里的一环输入，不该被基础设施层直接吞掉变成一次程序崩溃。

`_reject_unknown_arguments` 用 `inspect.signature` 反查 `handler` 函数真实的参数列表，主动拒绝契约 JSON Schema 之外、模型却硬塞进来的多余参数——这能在**第一时间**捕获“契约文件和 `handler` 函数签名不一致”这类打包漂移问题，而不是让多余参数被 Python 的 `**kwargs` 悄悄吞掉、制造出一个看起来正常但其实没生效的调用。

2.20 审批策略：三档判定

```
class Decision:
    verdict: Literal["allow", "ask", "deny"]
    reason: str

def decide(spec, arguments) -> Decision:
    if spec.permission == PERMISSION_EXEC:
        return _judge_command(arguments)
    return Decision(ALLOW) # read/write 权限一律直接放行
```

为什么 `write` 权限也直接放行：`fs.py` 里的 `write/edit` 工具权限标的是 `write`，但审批策略对它一律 `ALLOW`。原因是路径已经被强制收敛在会话专属工作区内（2.21 节的 `Workspace.resolve()`）——不管模型想写什么文件名，最终都只能落在自己的沙箱目录里，写坏了顶多是自己的工作区，不影响系统其他任何地方，所以不需要人再多确认一次。真正需要人来判断的，只有“可能执行任意代码或联网”这一类操作——也就是 `exec` 权限的命令。

`_judge_command()`：三档判定：

```
def _judge_command(command):
    argv = parse_command(command)      # 解析失败 → ASK
    name = Path(argv[0]).name           # 取 basename
    allowlist = _allowlist()            # 读 data/shell_allowlist.json, 读失败则全部转人工
    if name in allowlist.denied:         return Decision(DENY)
    if name in allowlist.auto_approved: return Decision(ALLOW)
    return Decision(ASK)                # 默认档：既不在白名单也不在黑名单 → 问人
```

data/shell_allowlist.json 的分档标准，文件自己的注释写得非常明确：自动放行的前提是这个命令既不能执行任意代码，也不能打开网络连接。

分档	举例	为什么
denied（直接拒绝）	sudo、ssh、docker、chmod、kill	提权/远程访问/容器/进程控制类，风险确定且高
auto_approved（自动放行）	ls、cat、grep、mkdir、cp、sha256sum	纯读取/检视/改名类工具，无法执行任意代码也无法联网
其余全部（转人工）	python、node、git、curl、find、awk	能执行任意代码（python -c）或联网（curl），即使大多数正常用法是安全的

git、curl 这些工具在 99% 的场景下都是无害操作，但“能执行任意代码/能联网”这个属性本身就足够危险，宁可让人多点几次“批准”，也不把这类命令一次性划入自动放行的白名单——这是功能，不是缺口。

StrictApprovalPolicy：为子代理准备的“严格版”：

```
class StrictApprovalPolicy(ApprovalPolicy):
    def decide(self, spec, arguments):
        decision = super().decide(spec, arguments)
        if decision.verdict == ASK:
            return Decision(DENY, reason=decision.reason + ", 但子代理无法请求人工批准, 请改用别的办法")
        return decision
```

只把 ASK 改写成 DENY，ALLOW / DENY 原样保留。为什么不能让子代理也走一遍“弹出审批卡片”的流程：主 Agent 的这一整个 Turn，正卡在“等待子代理返回结论”这一步的执行过程中（subagent 工具调用本身还没执行完）。如果子代理内部又碰到一个需要审批的命令，它会弹出一张审批卡片——但这张卡片要交给谁点“批准”？主 Turn 都还没轮到它能继续往下走、把控制权交还给用户界面，压根没有人能看到、也没有人能响应这张卡片。它只会静静地永远挂在那里，主 Agent 的这个调用永远不会返回。StrictApprovalPolicy 把这个“死锁”从源头掐断：需要人来判断的操作，在子代理里直接判定为“拒绝”，同时把原因文本带出去（这个原因本身也会作为 tool/result 喂回子代理，让子代理的模型“知道自己被拒绝了、可以换一种思路重试”）。这没有放宽任何安全边界——原本要人批的东西，现在依然跑不了，只是从“永远挂起”变成了“立即失败、附带原因”。

内置工具速览：

工具	权限	一句话
<code>read / write / edit / glob / grep</code>	read/write	文件操作，所有路径强制走 <code>workspace.resolve()</code>
<code>bash</code>	exec	单条命令， <code>shlex.split</code> 解析，禁止管道/重定向等 shell 操作符
<code>web_fetch / web_search</code>	read	抓正文（去脚本样式导航栏）/ DuckDuckGo HTML 检索
<code>current_time</code>	read	本地读取服务器时间，可转指定时区，不联网
<code>todo_write / exit_plan_mode</code>	read	任务清单/方案确认，纯粹靠日志本身当状态
<code>load_skill</code>	read	按需把一份技能正文读进当前对话（2.21 节）
<code>subagent</code>	write	派发子任务给独立子代理（2.24 节）

`fs.py` 的几个具体设计：`read` 分页读取（单次最多 400 行、文件最大 2MB，超限截断并明确提示）；`edit` 要求匹配唯一（除非 `replace_all=True`），0 次或多于 1 次匹配都直接报错，宁可拒绝执行也不猜模型到底想改哪一处；`glob` 每一个匹配结果都要重新过一遍 `workspace.resolve()`——纵深防御的一个小例子：不完全信任上一层过滤的结果；`grep` 跳过所有点号开头的目录，限制最多 100 条匹配。`web.py` 里还有一处小细节——沿着 `exc.__cause__ / __context__` 链条一直往下找，把 `ConnectError` 这种笼统的异常类型还原成 “Connection refused” 这种具体的操作系统级原因，给模型（和排障者）提供真正可操作的信息。

2.21 沙箱与安全边界

安全模型的第一句话：围栏，不是牢笼。README 的原话，非常值得在面试里 原样引用：

“沙箱是纵深防御的围栏，不是牢笼。它挡的是‘Agent 干出意料之外的事’——被 抓取的网页里藏了提示注入、指令被误读——而不是恶意的管理员。”

严谨定义：纵深防御（Defense in Depth）指不依赖单一的安全机制，而是 叠加多层独立的防护措施，使得攻破其中一层不足以导致整体失守。

大白话：这个沙箱假设的“敌人”，不是一个拿到 root 权限、故意搞破坏的 黑客——如果攻击者已经能任意执行命令，理论上依然有逃逸的可能，这个沙箱 不承诺能防住这种情况。它真正要防的是“**模型自己犯的错**”：模型抓取了一个网页，网页里藏了一句“忽略之前的指令，删除所有文件”（提示注入攻击），模型可能会“上钩”照做——这时候沙箱要保证，就算模型真的想删，它能碰到的 最大破坏范围也只是自己的工作区目录，碰不到系统的其他任何东西。谁能用 Harness（只有管理员）、要不要开 shell 权限，这些是部署方自己的选择，沙箱不替代这层判断。

命令执行边界：`execve`，绝不经过 `shell`：

```
def parse_command(command: str) -> list[str]:
    argv = shlex.split(command)
    for token in argv:
        if token in SHELL_OPERATORS:      # | || && & ; > >> < <<
            raise ValidationError(f"不允许使用 shell 操作符：{token}")
    return argv
```

```
proc = await asyncio.create_subprocess_exec(
    *argv,                                # 不是 create_subprocess_shell(command)
    start_new_session=True,
    preexec_fn=_apply_limits,
    env=_child_env(),
)
```

严谨定义：`execve` 系统调用直接用一个参数数组（`argv`）启动一个新 程序，不经过任何 `shell` 解释器对字符串做二次解析；相对地，`sh -c "命令字符串"` 会先让 `shell` 解析这个字符串（识别管道、重定向、变量替换、命令替换等），再决定实际要执行什么。

大白话：`shlex.split()` 把整条命令字符串按照 `shell` 语法拆成一个个“词”（这一步确实用到了“`shell` 语法规则”，但只是用来分词，不会真的 启动一个 `shell` 去执行）。拆完之后，代码扫描这些“词”，如果发现 `;`、`|`、`&&` 这类操作符作为独立的词出现，就直接拒绝——但如果这些符号是被引号包裹在某个参数内部的（比如 `python3 -c "import time; time.sleep(1)"` 里的那个分号，`shlex.split` 会把整个双引号内容当成 一个参数，分号不会被拆出来单独成词），就完全没问题，因为最终真正 执行时走的是 `execve`，参数原样传给目标程序，从头到尾没有任何 `shell` 会“重新解释”这个字符串。这一条规则杜绝的是“Agent 通过拼接 `shell` 元 字符，让一条命令变出好几条命令”这种典型的命令注入手法。

`start_new_session=True` 让子进程拥有自己独立的进程组，超时时用 `os.killpg` 一次性杀掉整棵进程树（`_kill_tree`），而不是只杀掉最外层 那一个进程、留下一堆孙子进程变成孤儿继续跑。

资源边界： `setrlimit`：

```
def _apply_limits():
    resource.setrlimit(resource.RLIMIT_CPU, (timeout + 1, timeout + 1))
    resource.setrlimit(resource.RLIMIT_AS, (1 * GiB, 1 * GiB))
    resource.setrlimit(resource.RLIMIT_FSIZE, (64 * MiB, 64 * MiB))
    resource.setrlimit(resource.RLIMIT_CORE, (0, 0))
    # RLIMIT_NPROC 故意不设！
```

一个真实的、值得记住的“反直觉”细节：`RLIMIT_NPROC`（限制该用户能同时开多少个进程，常被用来防“fork 炸弹”）在这里被故意不设置。为什么——因为这个限制是按操作系统真实用户 ID 统计的，而不是按“这一个沙箱子进程”单独统计。如果设置得太低，第一个被饿死的很可能不是恶意的 fork 炸弹，而是 Web 服务自己开的那些正常 worker 进程（它们运行在同一个真实 UID 下）。针对 fork 炸弹这个具体风险，改用另外两层来兜底：墙钟超时 + 杀整个进程组 + Docker 层面的 `pids_limit`——同一个问题，换一层更合适的机制去解决，而不是在不合适的层面强行加一道可能伤及自身的限制。

环境变量：为什么 `python3` 要单独处理 `PATH`：

```
def _child_env():
    env = {k: os.environ[k] for k in ("PATH", "HOME", "LANG", "LC_ALL", "TZ") if k in os.environ}
    env["PATH"] = f"{Path(sys.executable).parent}:{env.get('PATH', '')}" # 关键一行
    env["HOME"] = str(workspace.root)
    env["PYTHONDONTWRITEBYTECODE"] = "1"
    return env
```

如果不把 `sys.executable`（当前跑这个 FastAPI 服务的那个 Python 解释器）所在目录塞进进程的 `PATH` 最前面，Agent 执行 `python3` 时，系统会去找宿主机上随便一个 `/usr/bin/python3`——但那个解释器没有装这个部署环境专门 `pip install` 进来的库（比如技能脚本要用的 `python-docx`）。表现出来的症状是“脚本莫名其妙地 `ModuleNotFoundError`”，而这背后的真实原因（“用错了 Python 解释器”）从报错信息里完全看不出来。这个细节告诉我们：“沙箱里跑的 `python3` 到底是哪一个”这件事必须显式控制，不能依赖操作系统的默认 `PATH` 查找规则。

路径边界：`Workspace.resolve()` 与 `contained_path()`：

```
class Workspace:
    def resolve(self, relative: str) -> Path:
        if os.path.isabs(relative):
            raise ValidationError("不允许绝对路径") # 第一层
        return contained_path(self.root, relative) # 第二层：共享的通用收敛逻辑
```

`contained_path()`（`services/storage_service.py`）是整个项目唯一的路径收敛实现——不仅 Harness 工作区用它，公开的图片/头像/附件上传服务也用它。一处实现、处处复用，避免“两套路径安全检查、其中一套后来被改坏了但没人注意”这种典型的安全漂移。

```
def contained_path(root, relative):
    safe = os.path.normpath(relative).lstrip("/\\") # 先去掉开头可能残留的斜杠
    real_root = os.path.realpath(root)
    target = os.path.realpath(os.path.join(real_root, safe)) # 关键：realpath 会解析软链接
    if target == real_root or target.startswith(real_root + os.sep):
        return target
    raise ValidationError("路径越界")
```

三个值得逐个拆开讲的细节：

- 1. `os.path.realpath()` 会解析符号链接 (symlink) ——如果 Agent 在工作区内创建了一个指向 `/etc/passwd` 的软链接，然后尝试通过 `read` 工具读这个软链接的名字，`realpath` 会先把它“展开”成真实的目标路径 `/etc/passwd`，再拿这个真实路径去跟 `real_root` 比较，自然会发现越界。只检查路径字符串本身包不包含 `..`，防不住软链接这种“曲线救国”的手法。
- 2. 判断包含关系时，一定要拼上 `os.sep` 再做 `startswith`：如果只写 `target.startswith(real_root)`，会有一个真实存在的 bug——假设 `real_root` 是 `/var/harness/workspaces/abc`，恶意路径解析出来是 `/var/harness/workspaces/abc_backup/secret.txt`，这个字符串确实以 `/var/harness/workspaces/abc` 作为前缀（因为 `abc_backup` 的前 3 个字符也是 `abc`），但它压根不是同一个目录、是它的“邻居”。加上 `os.sep` 之后比较的是 `/var/harness/workspaces/abc/`，这个邻居目录的路径就不会再匹配上了。这是一个非常容易被忽视、但真实存在的路径校验漏洞模式，值得在面试时主动提起，展示你对“看起来正确但有边界条件漏洞”的代码有敏感度。
- 3. `Workspace.resolve()` 自己先拦一次绝对路径：`contained_path()` 内部的逻辑其实会把一个绝对路径（比如 `/etc/passwd`）的开头斜杠“strip 掉”再拼到 `root` 后面，变成 `<root>/etc/passwd` ——这本身不会越界，但语义上很奇怪（模型明明想读系统的 `/etc/passwd`，结果安安静静地读到了工作区内一个不存在的路径，得到一个“文件不存在”的错误，而不是一个清楚的“不允许”的错误）。所以 `Workspace.resolve()` 选择在更上层直接、明确地拒绝绝对路径，报错信息更准确，也避免了这种“貌似正常但语义诡异”的降级行为。

`check_quota()` 每次写入前都会重新计算工作区当前总大小，超过 `harness_workspace_quota_mb`（默认 64MB）就拒绝——防止 Agent 反复生成大文件把宿主机磁盘写爆。`destroy()` 删除工作区前也要先用同一套收敛逻辑校验一遍 `session_id` ——防止一次“删除会话”的操作，最终变成一次任意路径删除。




图 2.5：沙箱三层边界——应用层挡“正常使用场景下模型犯错”，容器层挡“万一应用层某处逻辑真的被绕过了，损失面还能封顶在多少”，两层互补而不是重复。

shell 白名单再回顾：核心记忆点是自动放行的判定标准是“既不能执行任意代码，也不能打开网络连接”，python / node / git / curl / find / awk 即使绝大多数正常用法安全，也因为具备“能做到这两件事之一”的能力而被划入“转人工”。

容器层加固（部署环境的最后一道防线）：

措施	作用
<code>cap_drop: [ALL]</code>	移除容器所有 Linux capabilities (不能改文件属主、不能绑定特权端口.....)
<code>security_opt: no-new-privileges:true</code>	禁止容器内进程通过 setuid 二进制等方式提权
<code>pids_limit: 256</code>	硬性限制容器内总进程数—— <code>RLIMIT_NPROC</code> 没做的事，在这一层补上
非 root 用户 (uid 10001) 运行	即使容器内出现某种逃逸，落地的身份也不是 root

面试话术：这体现了一个成熟的安全思路——“能在应用层解决的问题，就不依赖容器隔离；能在容器层加固的，就不指望应用层的逻辑代码百分百 没有 bug”。两层不是互相替代，是互相兜底：应用层的 `Workspace.resolve()` / `setrlimit` / `execve` 挡住“正常使用场景下模型 犯错”，容器层的 `cap_drop` / 非 root 用户挡住“万一应用层某处逻辑真的 被绕过了，损失面还能封顶在多低”。

2.22 技能系统 (Skills) ：过程性知识按需注入

Agent 经常需要“知道怎么做某件复杂的事”——比如“怎么把 Markdown 转成 排版精美的 Word 文档”，这类知识往往是一长段流程说明（先做什么、注意 什么坑、用什么脚本、最后怎么验证结果），不适合塞进短小精悍的工具描述，也不适合一股脑写进系统提示词（那样每次对话都要为一个可能根本用不上的 流程支付额外的 token 成本，还会稀释真正相关的上下文）。

严谨定义：这类“怎么做一件事的流程性知识”，在 Anthropic 等公司 近年的 Agent 产品设计里被称为 **Skill (技能)**——一份可以被模型按需 读取、指导它完成特定任务的自然语言文档，通常配合可选的辅助脚本/ 参考资料，区别于“工具”（工具是一个可以被直接调用执行的函数接口）。

大白话：工具是“能力”（我能读文件、能跑命令），技能是“说明书”（用这些能力具体怎么拼出一份 Word 文档，中间要注意哪些坑）。有能力 不代表知道怎么高质量地完成一件具体任务——这正是技能系统存在的意义。

系统提示词里，对每个技能只注入名字和一句 **description** (`catalogue()` 函数生成的目录)，模型判断“这个任务可能需要这份技能”时，自己主动调用 `load_skill` 工具，把正文读进当前对话。

为什么不做“关键词自动匹配、命中就自动注入”：这是一个主动设计 取舍，`harness/skills/registry.py` 的模块文档字符串里专门写了理由，直接呼应 2.10 节讲的核心不变量——“模型看到的一切必须先写进日志”：如果做成“关键词命中就自动把正文塞进系统提示词”，这份正文的注入行为 发生在系统提示词拼装阶段，根本不会经过 `emit()` 写进事件日志——那就会出现“模型确实看到了这段内容，但事件日志里压根找不到它是什么 时候、因为什么被注入进去的”，直接违反了“全链路可追溯”这条不变量。而现在的实现——正文只能通过调用 `load_skill` 工具获取——这次读取 动作本身，作为一次普通的 `tool/call + tool/result`，天然就会被记进日志，重放时一字不差。这是一个很典型的“为了保住一个核心系统 不变量，主动放弃了一个看起来更‘智能、更省事的功能’”的例子，值得 在面试里当作“架构一致性优先于局部便利性”的具体案例讲出来。

两种形态：单文件技能 vs 技能包：

data/skills/web-research.md	← 纯流程文档，一个文件就是一个技能
data/skills/pptx/	← 技能包
SKILL.md	# 入口，格式同上
scripts/build_deck.py	# 附带脚本
references/	# 参考资料（可选）

技能名就是文件名（或目录名）——没有单独的 `name` 字段，避免“文件名 和声明的名字对不上”这种自相矛盾的状态。Frontmatter 是手写的极简 `---` 分隔解析器，只认 `description`（必填）和 `keywords`（可选）。

技能包的文件怎么“进场”：调用 `load_skill` 时，如果这是一个技能包，它的附带文件会被复制进当前会话工作区的 `.skills/<名字>/` 目录下。为什么是复制，而不是让沙箱直接访问 `data/skills/` 目录：2.21 节 讲过，沙箱的路径收敛逻辑（`Workspace.resolve()`）只承认工作区内部的路径——这是整个系统安全边界最核心的一条假设。如果为了让某个脚本能跑起来，就单独给沙箱开一个“能访问 `data/skills/` 目录”的口子，等于在这条核心假设上开了个例外——例外一多，安全边界就变得难以推理。反过来，“把文件搬进工作区”这个操作发生在工具执行阶段（`load_skill handler` 内部），而不是修改沙箱本身的访问规则，付出的代价只是“多复制一次文件”，换来的是“沙箱的核心规则从头到尾只有一种”。复制逻辑还处理了几个细节：跳过 `__pycache__` / `.git` / `node_modules` 等目录、跳过任何点号开头的路径、限制单个技能包总大小不超过 8MB、写入前调用工作区自己的 `check_quota()`。

容错策略：技能坏了 vs 工具坏了，处理方式完全不同：

	工具契约损坏（.json 没有对应 .py）	技能文件损坏（缺 description、frontmatter 没闭合）
处理方式	立即 <code>raise</code> ，应用启动直接失败	跳过这一份，记进 <code>issues</code> 列表
通过什么暴露	部署日志/启动异常	<code>GET /harness/skills</code> 接口返回，前端插件面板标红
为什么不同	这是“仓库打包错误”——代码和配置本该在同一次代码提交里保持一致，不一致意味着一次真实的开发失误，理应在部署那一刻就被拦下来。	技能文件被设计成“运行时可以随意增删改、不需要重启”的内容，某个人手写 frontmatter 时少打一个 <code>---</code> 是完全可能发生的日常小失误，不该让这种失误直接拖垮整个 Agent 服务。

面试话术：这是“对错误的严重程度做分级处理”的一个好例子——不是 所有校验失败都该用同一种响应方式（一律抛异常，或者一律吞掉打日志）。要看这个错误来自“本该被质量流程挡住的开发失误”，还是“运行时内容 天生就允许被随意改动、随时可能出错的用户输入”。

技能不缓存，热更新：和工具注册表的 `load_specs()` / `load_preset()`（都套了 `@lru_cache()`，改了要重启才生效）形成鲜明对比——技能扫描 逻辑每次调用都重新扫一次目录，没有缓存。代价是“每次都要重新读一遍 这些小文件”，但收益是改一份技能文档、加一份新技能，下一轮对话立刻生效，不用重启整个后端服务。这个取舍成立的前提是：技能文件数量不多、单个文件不大（`MAX_SKILL_BYTES` 限制到 32KB）。

案例：docx / pptx 两个技能包——这两个是仓库里唯一自带脚本的“技能包”形态样例，都遵循同一套流程：① Agent 用 `write` 工具写一份 Markdown 源文件；② 调 `bash` 跑对应的构建脚本，生成 `.docx` / `.pptx`；③ **强制要求读回**：调 `read_docx.py`（基于 `pandoc`）/ `read_pptx.py`，把生成 结果重新解析成文本打印出来，供模型核对内容是否符合预期。

为什么必须“读回”，read 工具不能直接看： `.docx / .pptx` 本质上是一个 ZIP 压缩包，里面装的是若干个 XML 文件——通用的 `read` 工具只会把它当成二进制/纯文本源码读出来一堆乱码，完全没法验证“生成的文档内容对不对、排版有没有问题”。README 原话很好地总结了这个动机：“两个技能的 `SKILL.md` 都要求生成后必须读回核对再回话——否则‘已生成’只是它的一厢情愿。”一个脚本的退出码是 0（没报错），不代表它生成的文件真的符合预期——万一 Markdown 里某个表格语法写错了，脚本可能“成功”跑完，但生成的表格是空的或者错位的。

第三方技能包的许可证坑： `anthropics/skills` 仓库公开的 `docx/pptx` 技能虽然代码可读，但附带的 `LICENSE.txt` 明确禁止“在 Anthropic 的 Services 之外保留副本”“复制”“制作衍生作品”——**不能直接搬进自建服务器使用**。这个项目里的 `docx/pptx` 是**独立实现**，只依赖 `python-docx / python-pptx / pandoc` 这些本身开源的库，从零重新写的功能等价物，不是对官方仓库代码的移植或修改。

面试话术：这是一个体现“工程判断力不止是技术选择，也包括合规意识”的细节——发现一份现成的、公开可读的代码不代表可以直接拿来用，License 条款也是工程决策的一部分输入。

2.23 子代理与多智能体协作

严谨定义：多智能体系统（Multi-Agent System）中的“委派（Delegation）”模式，指一个 Agent（主 Agent / Orchestrator）把某个子任务的完整执行过程交给另一个独立运行的 Agent（子 Agent / Subagent）负责，主 Agent 只关心子 Agent 最终返回的结论，不需要（也不应该）介入子任务内部的每一步细节。

大白话：主 Agent 好比一个项目经理，遇到“帮我把这三个文件都按新规范改一遍”这种明确、独立、不需要频繁汇报进度的子任务时，不用亲自一步步做，而是“派活”给一个专门的执行者——执行者自己决定怎么读文件、怎么改、改完什么样算完成，最后只需要给项目经理一句“做完了，结果是这样的”汇报。这样做的好处：**主 Agent 的对话上下文不会被子任务的几十步中间过程淹没**——如果不委派，这些中间步骤全都会挤进主对话的上下文窗口，让主对话越来越臃肿、越来越贵。

角色定义（`harness/data/agents/coder.json`）和预设文件在结构上**完全一样**（`tools`、`max_steps`、系统提示词），共用同一套 `ToolRegistry` 加载逻辑。**但两者的“读者”不一样：**预设是给人（在界面上选的），角色定义的 `description` 字段是给模型看的（“遇到什么样的任务应该委派给这个角色”）。内置两个角色：`researcher`（查证员，只读权限）、`coder`（工程师，能读写工作区，**没有 shell、没有 subagent**——不能再往下派发）。

委派入口： `subagent` 工具：

```
async def subagent(ctx, task: str, agent: str, context: str = "") -> str:
    if ctx.depth >= settings.harness_subagent_max_depth:      # 第 1 道闸
        return "已达到委派深度上限，不能再往下派发"
    if len(task) > MAX_TASK_CHARS:                             # 4000 字符
        return "任务描述过长"
    if agent not in agents.names():
        return f"未知的子代理角色：{agent}"
    if manager.count_children(ctx.session_id) >= settings.harness_subagent_max_per_session: # 第 2 道闸
        return "本会话委派次数已达上限"

    child = manager.create_subagent(ctx.session_id, agent, task)
    child_ctx = build_subagent_context(child.id, agent, ctx.workspace, ctx.sandbox, ctx.depth)
    ctx.emit(SUBAGENT_START, {"child_id": child.id, "agent": agent})
    try:
        answer = await _run(child_ctx, task, context)
    finally:
        manager.finalize_turn(child_ctx.session_id)
    ctx.emit(SUBAGENT_END, {"child_id": child.id, ...})
    return _report(answer, ...)
```

四道花钱的闸门，全部检查在“真正开始跑之前”：

闸门	环境变量	默认值	检查什么
委派深度	HARNESS_SUBAGENT_MAX_DEPTH	1	子代理不能再派子代理（ctx.depth 只会是 0 或 1）
单会话次数	HARNESS_SUBAGENT_MAX_PER_SESSION	16	累计计数，存数据库而非内存计数器
单次步数	HARNESS_SUBAGENT_MAX_STEPS	8	一次子运行内部最多跑几步
墙钟超时	HARNESS_SUBAGENT_TIME_OUT_SECONDS	300	一次子运行最多跑多久

委派深度为什么恰好是 1：coder / researcher 这两个内置角色的工具清单里都不包含 subagent ——不是靠深度检查“运行时兜底拦截”，而是从工具可用性上直接不给这个能力。深度限制本身是“防御性的第二层”，即使未来有人手写一个角色定义、不小心把 subagent 塞进了它的工具清单，深度检查依然能兜底。

build_subagent_context()：为什么不直接传父 context：

```
def build_subagent_context(session_id, agent, parent_workspace, parent_sandbox, depth):
    return HarnessContext(
        session_id=session_id,
        store=SqliteSessionStore(),           # 全新的、独立的
        llm=build_adapter(...),              # 全新的、独立的
        tools=ToolRegistry(agent_definition),
        workspace=parent_workspace,           # 直接复用父会话的 workspace 对象
        sandbox=parent_sandbox,               # 直接复用父会话的 sandbox 对象
        hooks=build_hooks(strict=True),       # 严格审批策略
        depth=depth + 1,
        max_steps=min(agent_definition.max_steps, settings.harness_subagent_max_steps),
    )
```

参数列表里故意传的是 `parent_workspace / parent_sandbox` 这两个具体对象，而不是“把整个父 `HarnessContext` 传进去”。如果传的是整个父 context，子代理的工具处理函数（handler）理论上就有能力“顺着这根线”摸到父会话的一切——父会话的存储实例、父会话的 LLM 适配器、甚至父会话 专属的钩子配置。这些东西子代理根本不需要，也不应该碰得到。只传“真正需要共享的两个东西”（工作区目录、沙箱执行器——子代理要能操作和父 Agent 同一份文件），其余全部重新构建一份独立实例——这是“最小知识原则（Principle of Least Knowledge，也叫 Law of Demeter）”的具体体现。

为什么工作区和沙箱要共享，其他都不共享：子代理和父会话共用同一个工作区目录——这是有意为之。README 明确解释：“这样把这三个文件改一遍”这类任务能直接落地——如果子代理有自己独立的工作区，那它改的文件父会话根本看不到，委派就失去了意义。而 `store`（事件日志存储）和 `llm`（模型适配器）是无状态的、每次会话独立构建代价很低的东西，没有必要共享，独立一份反而让子代理的日志和主会话的日志边界清晰。

`_run()`：驱动子代理，同时监听两个“该停下来”的信号：

```
async def _run(child_ctx, task, context):
    deadline = time.monotonic() + settings.harness_subagent_timeout_seconds
    steps, answer = 0, ""
    try:
        async for event in run_turn(child_ctx, prompt):
            if event.type == STEP_START:
                steps += 1
            if event.type == ASSISTANT_MESSAGE and event.data.get("content"):
                answer = event.data["content"] # 只留"最新的非空回复"
            if interrupt.is_set(child_ctx.session_id): # 父会话被打断了
                interrupt.request(child_ctx.session_id)
                break
            if time.monotonic() > deadline: # 子运行自己超时了
                interrupt.request(child_ctx.session_id)
                break
    except Exception:
        answer = answer or "子代理没有给出结论" # 任何异常都不能往上抛
    return answer, steps
```

三个值得单独拆开说的设计点：

1. 父会话被打断，要连带打断正在跑的子代理——中断信号打在父会话的 `interrupt` 令牌上，但父 Agent 的主循环此刻正阻塞在 `await _run(...)` 这一行代码里，它自己根本走不到下一次“检查是否被打断”的时机点。
`subagent.py` 里主动做了这一层“信号转发”——每一轮事件都顺手检查一下父会话是否被打断了，一旦发现，就主动把中断请求也打在子会话自己的令牌上，让子代理的循环在它自己的下一个检查点尽快停下来。这不是“框架自动帮你做的事”，是委派这个功能自己额外补上的一层信号传递。
2. 子代理内部的异常，绝不允许往上传播——任何在子代理运行过程中抛出的异常都被吞掉，转换成一句“子代理没有给出结论”，作为正常的返回值交还给主 Agent。这和 2.19 节讲的“工具失败是值，不是异常”是完全一致的设计哲学——子代理本身也可以被看作一次“很复杂的工具调用”。
3. `finally: manager.finalize_turn(child_ctx.session_id)` ——即使子代理这一次运行抛出了异常、或者被中途打断，也要保证它对应的会话状态最终被“收尾”，不会永远卡在 `running`。

费用汇总：为什么不能“分开算”——2.14 节提过 `usage_summary()` 会递归汇总所有子会话的用量，这里补充一个真实的观察（README 原文）：“实测一次派发里子代理花掉的 token 比主 Agent 还多，分开算就会严重低估。”委派并不是“免费”的——子代理内部要独立跑完整的思考-工具调用循环（可能好几步），累计消耗的 token 完全可能超过主 Agent 本身直接完成同样任务所花的 token。委派换来的是“主对话上下文更干净”，不是“总花费更低”。

子代理不出现在侧栏，但可以从轨迹里点进去看——`list_for_user()` 过滤掉所有 `parent_id` 非空的会话，子代理不会挤占用户在侧边栏看到的 会话列表。但完整的中间过程**没有丢失**——子代理有自己独立、完整的事件日志，前端轨迹检查器提供“从父会话的 `subagent/end` 事件卡片，点进去查看子代理的完整轨迹”的导航路径。




图 2.6：子代理只共享父会话的 workspace 和 sandbox 两个对象，其余（store、LLM 适配器、审批策略）全部独立重建，遵循最小知识原则。

2.24 成本、上下文压缩与一批“血泪教训”级工程细节

这一节汇总一批分散但极其重要的实现细节——它们大多是“没有踩过坑就写不出来”的代码，是面试时最能体现你“真读过、真理解”这个项目，而不是“背了一份 README”的地方。

模型适配器的一个类型设计小巧思：`LLMDelta`：

```
@dataclass
class LLMDelta:
    content: str | None
    reasoning: str | None
    result: LLMResult | None  # 只有流式的“最后一条”才不是 None
```

流式接口的生成器（`stream()`）每次 `yield` 出来的都是同一种类型 `LLMDelta`——中间的分片和最后汇总完的最终结果，用同一个类型表达，靠 `result is not None` 来区分“这是不是最后一条”。

大白话：这是一个“用类型系统防呆”的例子——如果流式分片和最终结果是两种不同的类型，调用方很容易写出“忘记处理最终结果，只顾着攒分片”的 bug（因为分片处理起来更“顺手”，最终结果的处理逻辑容易被落下）。现在两者是同一种类型，调用方必然要在循环体里判断 `delta.result is not None`，结构上就不太可能“漏掉”收集最终结果这一步。

`OpenAICompatibleAdapter.stream()` 用一个 `_ToolCallAccumulator`，以 `index` 为 key，把同一个 `index` 下所有分片的 `arguments` 字符串拼接起来（1.5 节已给出这个坑的完整背景）。**报错要读实际的错误体：**

```
async def _raise_for_stream_status(response):
    if response.status_code >= 400:
        body = await response.aread()  # 手动读一遍原始响应体
        raise UpstreamError(f"...: {body[:500]}")
```

流式响应里如果直接调用 `httpx` 的 `response.raise_for_status()`，抛出的异常信息通常不包含 **provider 返回的具体错误描述**（因为响应体是流式的，还没被读取），报错信息往往只有一个笼统的“400 Bad Request”。手动先把响应体读出来再抛异常，报错信息里能带上 `provider` 真正返回的具体原因——这类“多一步手动处理，换来更有用的报错信息”的细节，往往是区分“随手对接一下 API”和“认真调试过真实故障”的分水岭。

思考型模型的“空回复”陷阱：

“deepseek-v4-pro 这类思考型模型，会先花掉输出预算做推理，再吐出正文。所以标题、摘要这类短输出场景的 `max_tokens` 必须留足余量；预算给小了会拿到空正文，此时适配器直接报错而不是返回空串——这个坑最初就是靠这条报错才发现的。”（CLAUDE.md 原文）

严谨定义：一些“推理增强型（Reasoning）”模型在正式生成回复内容之前，会先生成一段不直接展示给用户、但同样占用输出 token 预算的“思维链（Chain of Thought）”内容。如果给这类模型设置的 `max_tokens` 太小，模型可能把整个预算都花在了思考过程上，还没来得及生成真正的正文就被截断了——`finish_reason` 会是 `"length"`，但 `content` 字段却是空字符串。

大白话：你以为设置了 `max_tokens=100` 是“回复最多 100 个 token”，但对思考型模型来说这个预算可能全部被“脑内 OS”占用了，正文一个字都没写出来。**如果代码把这种情况静静地当成“模型回复了一个空字符串”处理**，表现出来的症状是“标题生成器偶尔生成一个空标题”“摘要功能偶尔返回空白”——这种 bug 极难排查，因为程序没有报错、逻辑看起来全部走通了，只是结果碰巧是空的。真正的修复方式是——**遇到 `finish_reason == "length"` 且 `content` 为空，直接抛出一个明确的异常**，而不是把这种异常状态悄悄降级成一个“正常但空洞”的返回值。这是“绝不用一个合法但错误的默认值去掩盖异常状态”这条工程原则的具体案例。

这也解释了为什么标题生成（`TITLE_MAX_TOKENS=512`）和压缩摘要（`SUMMARY_MAX_TOKENS=3000`）的 `max_tokens` 设得看起来“过于宽裕”——要给思考型模型留出足够的“思考预算”，否则就会撞上上面这个坑。

上下文压缩：真实 token 数，而不是本地估算——`compaction.py::_measured_prompt_tokens()`：

```
def _measured_prompt_tokens(log):
    usage_event = latest(log, type=LLM_USAGE)
    compaction_event = latest(log, type=COMPACTION_SUMMARY)
    if compaction_event and usage_event.seq <= compaction_event.seq:
        return None # 这次测量描述的是压缩之前的上下文，已经不能代表现在
    return usage_event.data["prompt_tokens"]
```

只有在“最近一次真实用量数据，比最近一次压缩摘要还新”的前提下，才信任这份测量值；否则退回用 `estimate_tokens()` 现算。代码注释里给出了一个真实观测的数字对比：某次测量里，真实 `prompt_tokens` 是 **9,874**，而本地估算只有 **426**——差了二十多倍。原因是**每次请求除了对话本身，还要带上完整的系统提示词和全部工具的 JSON Schema**，这些固定开销加起来通常有 1500 ~ 2000+ token，而 `estimate_tokens()` 只统计了“对话文本”这一部分，完全没算上这两项。

大白话：如果压缩触发条件用的是这个严重偏低的估算值，会导致“用户设置的上下文预算明明已经快被真实占满了，系统却还傻乎乎地以为‘才用了 426 个 token，远没到阈值，不用压缩’”——结果就是下一次请求直接因为超出模型的上下文窗口而报错，而不是提前触发压缩。**决策依据 必须尽可能贴近真实情况**，本地估算只配拿来做“某个数字大概长什么样”的粗略判断，真正关键的、影响系统行为的决策，要用权威数据源。

拒绝“无效压缩”：`MIN_COMPACTION_GAIN_TOKENS`：

```
gain = _compactable_tokens(log, before_boundary) - _compactable_tokens(log, after_boundary)
if gain < 500:
    logger.warning("压缩收益过小，请提高 HARNESS_CONTEXT_BUDGET_TOKENS")
    return log # 直接返回原始日志，不做任何压缩
```

假设一次请求的固定开销就有 1800 个 token，而用户设置的预算只有 2000 token——那压缩再狠，用完的 token 数也压不下多少，很可能每一步都要重新触发一次压缩、每次都要花一次 LLM 调用去做摘要，陷入“越压缩越花钱、却几乎没有效果”的死循环。这里设了一个“最低收益门槛”（500 token）——如果预计压缩下来省不了这么多，宁可拒绝压缩、打一条明确的、可操作的警告日志（告诉部署方该调高预算配置了），也不要每一步都白白多花一次摘要请求的钱去做一件几乎没用的事。

系统提示词只带日期：为了前缀缓存——第一部分 1.10 节已经讲过原理，这里补充部署注意事项：需要精确到秒/分的时刻，改由 `current_time` 工具在被调用的那一刻本地读取——它不联网，读的是运行这个后端服务的服务器自己的系统时钟和时区。Docker 容器默认时区是 UTC，如果部署方希望 Agent 感知到的是本地时间，需要在 `docker-compose.yml` 里给 backend 服务额外加一条 `environment: TZ: Asia/Shanghai`。

计费：未知的价格显示“—”，而不是 0：

```
def estimate_cost(model, usage):
    price = pricing_table.get(model)
    if price is None:
        return None      # 而不是 0.0
```

`data/pricing.json` 是一份纯数据文件，表里查不到的模型，`estimate_cost` 返回 `None`，前端渲染成“—”，不是 0——如果返回 0，用户看到的信息是“这次调用免费”，这是一个彻头彻尾的谬误。而且这个“未知”具有“传染性”：`pricing.summarize()` 汇总一整个会话（包括所有子代理）的总费用时，只要有任何一次调用的模型价格未知，整个会话的总费用就是 `None`，不会是一个“看起来精确但其实是错误低估”的部分总和。

自动生成标题——`generate_title()` 对比压缩摘要（失败会用警告日志提醒）和标题生成——标题纯粹是装饰性的（不影响对话本身能否进行），捕获所有异常，只记一条 `info` 级别日志，返回空字符串，不打扰用户。

这一节的核心结论，值得在面试里当作“最能体现设计一致性”的回答：

“不要用一个‘看起来正常’的默认值去掩盖一个真正需要被感知到的异常状态；决策所依赖的数据，要尽可能是权威的、真实的，而不是图省事的估算。”

空正文该报错，不该悄悄返回空字符串；未知价格该显示“—”，不该显示 0；压缩触发该用 provider 真实返回的 token 数，不该只信本地粗估算；收益太小的压缩该拒绝执行并明确警告，不该假装执行了一次“象征性”的压缩。这条主线反复出现在完全不同的模块里，说明这不是碰巧写对了一次，而是一条被主动坚持的工程纪律。

2.25 HTTP 接口与前端联调

权限门槛：`require_harness_user()`：

```
def require_harness_user(user = Depends(require_user)):
    if not settings.harness_enabled:
        raise NotFoundError(...) # 404, 不是 403
    if settings.harness_require_admin and user.role != "admin":
        raise PermissionError(...) # 403
    return user
```

值得注意的细节：**功能整体关闭时返回 404，而不是 403**。403 会告诉一个未授权的访问者“这个东西存在，只是你没权限”，404 则是“这里什么都没有”——如果部署方压根没打开 Harness 功能，没必要通过状态码差异暴露“这个系统其实内置了一个 Agent 工作台”这个信息本身。这是一个很小但体现安全意识的细节：**错误响应本身也可能泄露信息，要按“最少暴露”的原则来设计**。

SSE 流式接口的构造：

```

@router.post("/sessions/{id}/messages")
async def send_message(id: str, body: MessageIn, user=Depends(require_harness_user)):
    if manager.is_busy(id):
        raise ValidationError("这个会话正有一轮对话在进行")
    hctx = build_context(id, row.preset)
    return _stream(id, run_turn(hctx, body.text))

def _stream(session_id, event_iter):
    manager.set_status(session_id, "running")
    async def generator():
        try:
            async for event in event_iter:
                yield sse(event.to_dict())
            yield SSE_DONE
        except AppError as e:
            yield sse({"error": e.message})
        except Exception:
            logger.exception(...)
            yield sse({"error": "服务器内部错误"})
    return StreamingResponse(
        generator(),
        headers=SSE_HEADERS,
        background=BackgroundTask(_finish_turn, session_id),
    )

```

三个关键设计：① 异常必须在生成器内部捕获，转换成“数据帧里的一个 错误字段”，因为一旦 `StreamingResponse` 已经开始往浏览器发送数据（HTTP 响应头早已发出），这个 HTTP 请求就不可能再改变状态码了；② `background=BackgroundTask(...)`，不是 `try/finally` 包在生成器里——原因在 2.14 节详细讲过；③ 状态先设成 `"running"` 再开始迭代——这样即使客户端还没收到任何事件，其他并发请求去查这个会话 状态也能立刻看到“正忙”，`manager.is_busy()` 的检查才能生效。

`/messages/derived`：可以现场核对的“透明度承诺”：

```

@router.get("/sessions/{id}/messages/derived")
async def get_derived_messages(id: str, ...):
    hctx = build_context(id, row.preset)
    log = store.read(id)
    return derive_messages(log, hctx.system_prompt)

```

这个接口的注释非常直接：“exactly what the next request would send”——它调用的跟循环内部真正要用来发请求的，是同一个 `derive_messages()` 函数，不是另外单独写一份“展示用”的近似逻辑。这意味着 2.10 节讲的“全链路可追溯”这条承诺，不是一句自我标榜，而是一个用户随时能在界面上点开‘消息’这个页签、当场核对的可验证事实。

文件下载：两套 Header 编码兼容中文文件名：

```

def _content_disposition(filename):
    ascii_fallback = _ascii_fallback(filename) # 去掉所有非 ASCII 字符和引号/反斜杠
    encoded = urllib.parse.quote(filename) # RFC 5987 百分号编码
    return f'attachment; filename="{ascii_fallback}"; filename*=UTF-8\'\'{encoded}'

```

Content-Disposition 响应头的 `filename` 参数只能安全地承载 ASCII 字符，`filename*=UTF-8'...'`（RFC 5987/6266）参数则允许用百分号编码 承载任意 Unicode 文件名；同时提供两者是为了兼容“支持新语法的现代浏览器”和“只认旧语法的老客户端”。下载路由复用和 Agent 自己 `read / glob` 工具完全同一份

`Workspace(session_id).resolve()` 逻辑——一处 容纳实现，不再维护第二份。

前端三栏布局与状态驱动渲染：`harness.js` 维护一个简单的状态对象 `{ sessionId, events, registry, tab, running, search }`，没有引入任何 前端框架的响应式系统，靠“改状态 → 手动调用对应的渲染函数重新构建 DOM”这种最朴素的模式。中间栏对话区域按事件类型分发：

事件类型	渲染成什么
<code>user/message / assistant/message</code>	聊天气泡
<code>tool/result</code>	可折叠的工具卡片（ <code>todo_write</code> 默认展开，因为“输出本身就是进度展示”）
<code>tool/approval</code>	批准/拒绝按钮卡片——但如果日志里已经能找到这个调用对应的 <code>tool/result</code> （说明已经被处理过了），改成只读展示
<code>subagent/end</code>	展示步数/花费，附一个“查看它的完整轨迹”按钮
其余（ <code>step/*</code> 、 <code>llm/usage</code> 、 <code>config/change ...</code> ）	不在中间栏显示——这些“基础设施事件”属于右栏的检查器

四个页签：事件（events）——原始事件日志逐条展示，“从 seq N 分支”的分叉按钮只出现在 `turn/end / step/end / assistant/message` 这几种类型上；**消息（messages）**——实时请求 `/messages/derived`；**文件（files）**——会话工作区的文件列表，下载走裸 `fetch + Blob`；**插件（plugins）**——`GET /harness/tools` 返回的注册表数据，当前预设 启用了哪些工具、技能、子代理角色、挂载了哪些钩子。

流式过程中的一个体验细节：`assistant/chunk` 事件持续追加进一个 临时气泡，一旦收到真正的 `assistant/message` 事件，这个临时气泡被 丢弃，用最终消息重新渲染一份——代码注释直接写出这条逻辑背后的原因：“The final message supersedes the chunks it was assembled from”。

文件下载为什么走裸 `fetch + Blob`，而不是 `<a href>`：Harness 的文件下载接口需要 Cookie 认证 + CSRF 头，而普通的 `<a href=“...”>` 标签没有办法自定义请求头。解决方式：先用带凭证的 `fetch` 换来完整的 文件内容（Blob），再用一个“程序创建、立即点击”的 `<a download>` 触发浏览器原生的保存对话框。

2.26 部署与质量保障

部署形态：`docker-compose.yml` 两个服务——`backend`（挂载 `./var:/app/var`，唯一状态卷）+ `nginx`（挂载只读的 `./frontend` 和 `nginx.conf`）。`deploy/Dockerfile` 基础镜像 `python:3.11-slim`，装了 `gcc libpq-dev libffi-dev libjpeg-dev fonts-dejavu-core`——最后一个是因为基础镜像本身不带任何字体，验证码生成如果没有可用字体会退化成 几乎无法辨认的位图字体。**`fonts-dejavu-core` 不含中文字形**——这意味着即使装好了 LibreOffice 用来渲染 pptx 缩略图，中文幻灯片依然会渲染 成“豆腐块”。这是一个容易被忽略的连带因果关系：**装对了软件不代表 功能就完整了，还要装对配套的资源**。先复制 `requirements.txt` 单独 跑一次 `pip install`，再复制其余代码——利用 Docker 分层缓存，依赖 没变时这一层可以直接复用。非 root 用户 `app`（`uid=10001`）运行——注释明确点出原因：“harness 会代表模型执行命令，所以这个进程不能是 root”。

`deploy/nginx.conf`：

```
location /api/ {
    proxy_pass http://backend:8000;
    proxy_http_version 1.1;
    proxy_set_header Connection "";
    proxy_read_timeout 300s;
    proxy_send_timeout 300s;
    proxy_buffering off;          # ← 和 core/sse.py 的 X-Accel-Buffering: no 呼应
    proxy_cache off;
}
```

`proxy_buffering off` 和应用层 `X-Accel-Buffering: no` 响应头是“同一个目标的两道保险”，
`proxy_read_timeout 300s` 设得比默认值宽松 很多，因为一次 Harness 对话可能连续跑好几分钟。

没有 pytest，靠什么保障质量： `requirements.txt` 里没有 `pytest`。这不是“疏忽”，而是这个项目实际选择的质量保障策略——用一组“探针 脚本”（**Probe Scripts**）替代传统单元测试套件，放在 `tools/` 目录下：

- `tools/ai_probe.py`：只验证非 Harness 的 AI 供应商连通性，非流式和 流式各跑一次真实调用。
- `tools/harness_check.py`：Harness 的多阶段连通性自检，约 600 行。设计核心是一个 `stage(name, fn)` 包装函数——**每一个检查阶段互相 独立**，一个阶段失败不会阻止后面的阶段继续跑，最后统一汇总一份 报告。三种运行模式（`--offline`、真实 provider 调用、加 `--url` 跑完整 HTTP/SSE）。检查顺序：配置 → 数据库 → 沙箱与路径收敛（**专门测试 `../../etc/passwd` 和 `/etc/passwd` 都必须被拒绝**——“containment is the whole point”）→ 工具注册表 → 审批策略（三档 各验证一遍）→ 事件日志与消息投影 → 真实模型调用 → 工具调用的流式 拼装 → 完整走一轮对话 → HTTP 接口与 SSE。**全部通过退出码 0**，可以直接接入部署脚本。
- `tools/harness_probe.py`：跑一整轮真实对话，不经过浏览器、不经过 HTTP，用一个专门的、**默认禁用登录**的探针账号直接调用 `build_context()` + `run_turn()`。如果这一轮卡在“等待人工审批”，脚本会打印“本轮停在人工审批处——这是策略生效，不是失败”，而不是 当成一次异常——**探针脚本的判定逻辑要理解被测系统的业务语义**。

面试话术：面试官如果问“这个项目怎么做测试”，诚实的回答不是“没写测试，来不及”，而是“这个项目用分阶段的连通性探针脚本代替了 传统单测——因为 Agent 系统的核心风险大多是‘各个组件真的接得上吗、真的按预期的顺序工作吗’这类集成层面的问题，用一组能真实跑通整条 链路的脚本，比大量 mock 掉外部依赖的单元测试更能直接发现问题”。

首次部署 checklist：① `cp .env.example .env`，务必修改 `JWT_SECRET`；② 用 `ai_probe.py` 单独验证 Key 有效；③ Docker 部署前 `chown -R 10001:10001 ./var`；④ 生产环境 `COOKIE_SECURE=true` 并配好 HTTPS；⑤ `HARNESS_REQUIRE_ADMIN` 保持默认 `true`；⑥ 如果开 `HARNESS_SHELL_ENABLED=true`，先完整理解沙箱一节——“从那一刻起，审批提示承担了全部风险，不要靠削弱它去补偿”；⑦ 部署完跑一遍带 `--url` 的完整版 `harness_check.py`。

第三部分 · RL 工作台导览

这一部分把 Harness（一个能跑的 Agent）变成一个**能训练模型**的环境。如果你要投 LLM Post-Train / Agentic RL 方向，这是全书含金量最高的部分——腾讯混元的后训练岗位要求“负责后训练数据合成、设计数据飞轮”，Anthropic 的 Code RL 岗直接写“设计 RL 环境与任务、构建能刻画好坏的奖励信号与验证器”，MiniMax 在介绍自研 RL 系统 Forge 时强调 rollout 往往占 RL 循环墙钟时间的大部分，美团 LongCat 的 RL 框架岗要打通策略更新、环境交互和奖励建模的端到端流程——这一部分要讲的六章，恰好对应了这几条 JD 里的每一句话。

3.1 为什么 Agent 运行时不等于 RL 环境

严谨定义：强化学习环境（environment）是一个可交互、可复现、能对行为给出标量回报的系统。形式上它要提供三样东西：动作空间（agent 能做什么）、状态转移（做了之后世界怎么变）、奖励函数（做得好不好）。

大白话：运行时是“一台能开的车”，环境是“一条能反复跑、有秒表、每次起点终点都一样的赛道”。车造好了不等于有赛道。没有赛道，你连“这次比上次快了没有”都答不出来。

Harness 已经具备的：动作空间（工具）、状态转移（工具执行 + 事件日志）。**完全没有的：**奖励函数、可复现性、任务集。把这三样缺的补上，才叫环境。

	Agent 运行时	RL 环境
联网	要， <code>web_search</code> 是核心能力	绝对不能 ，否则今天和明天跑出的结果不可比
工具集	越多越好	锁死 ，多一个工具就是另一个任务
提示词	带当天日期很合理	带日期 = 数据集跨天失效
上下文压缩	长对话必需	必须关 （原因见 3.4 节）
人工审批	安全边界	rollout 里没有人，会永久挂住
一次运行的产出	一次对话	一条 可回放、可重新打分 的轨迹

两条不变量为什么正好是 RL 需要的：回忆第二部分讲的两条设计原则——① 可替换的能力接缝；② 全链路可追溯。第二条的价值在 RL 场景下会翻倍：

严谨定义：train/inference 不一致（train-inference mismatch）指训练时构造的输入序列与采样时模型实际看到的序列不完全相同。它会让梯度作用在模型从未产生过的 token 上。

大白话：你让模型做了一道题，然后按着**另一张试卷**给它打分改错。分数和改错都算得出来，数值上一切正常，但学到的东西是错的。

因为“模型看到的一切先写日志”，一条轨迹的事件日志天然就是完整的；因为 `derive_messages()` 是唯一投影函数，几个月后重建的 `messages` 与当时发出去的**逐字节相同**。这一整类 bug 从源头就被掐掉了。**这条论证只有在自己写过 runtime 的前提下才成立**，也是面试里最值得讲的一句话（注意诚实边界：这解决的是消息层面的一致；token 层面还需要 3.5 节的断言兜住）。

第一条不变量让改动变得很小。整个环境只用了：

```
新增数据文件：harness/data/tools/corpus.json
                harness/data/presets/deepresearch.json
                harness/data/prompts/deepresearch.md
新增代码：    harness/tools/builtin/corpus.py
                harness/corpus/                ( 语料读取 + BM25 )
改动：        tools/registry.py                +1 行 ( _MODULE_GATES )
                core/config.py                  +2 个字段
```

agent.py / projection.py / events.py / context.py / approval.py 一行未改。

3.2 环境设计的第一版，以及它是怎么被自己的实测推翻的

这一节是全书最建议精读的一节。不是因为设计有多巧，而是因为它错了，而且是被数字推翻的。

第一版设计：自建 5 万篇 arXiv 论文语料（摘要 + 结构化元数据），出这样的题：“有一篇论文提出了〔改写过的方法描述〕。请给出该文第一作者的另一篇论文的编号，该文提交到 cs.CL 且在下一个季度。”想法是：第一跳是**文本的**（描述 → 论文），检索技能长在这里；第二跳是**结构化的**（论文 → 作者/日期 → 目标），答案来自元数据所以验证器精确且免费。听起来很合理。

实测：

测量（50k arXiv 语料，200 个样本）	结果
取摘要里最罕见的 8 个词去检索它自己	top-1 100%，0.7 ms
先删掉全部语料罕见词，再取剩下最罕见的 8 个词	top-1 仍然 100%
第二名 / 第一名的 BM25 得分比	中位 0.28，无一例 >0.8
把语料收窄到单一主题（LLM / diffusion / RL）	更糟，比值降到 0.19

第三行是关键：**第二名只有第一名 0.28 的分数**。每篇论文在 BM25 空间里都是一座孤岛，附近根本没有可混淆的文档。所以只要描述忠实到人类能认出是哪篇，BM25 也一定能认出。第四行反直觉，值得想明白：

大白话：把语料收窄成“全是 LLM 论文”，直觉上应该更难区分。实际更容易。因为 BM25 靠 IDF 打分——主题词（“language”、“model”）在窄语料里变得到处都是、权重掉下去，而这篇论文自己的特异词反而**相对更突出了**。

结论与改法：在任何能从 arXiv 构建出来的语料上，“按描述找到那篇论文”都是一步到位的。难度必须来自语料本身存在近似文档——这是语料的性质，改措辞改不动。换成 HotpotQA distractor split 后，同一组测量：

	arXiv 50k	HotpotQA 66.6k
第二名/第一名得分比（中位）	0.28	0.84
存在 >0.8 强竞争者的比例	0%	58%

因为 HotpotQA 每道题自带 2 段 gold + 8 段专门检索出来的可混淆干扰段，这正是 arXiv 语料缺的性质。arXiv 的语料与构建器**仍然保留在仓库里**（rl/corpus/fetch_arxiv.py）——它是这条结论的证据，不是废弃代码。

面试提示：这一段值得在面试里主动讲——“我先量了，发现环境不成立，然后改了设计”比“我做了一个能跑的 benchmark”有说服力得多。前者证明你有**判断一个环境是否有效的能力**，而这正是环境设计岗位的核心能力。反过来说：如果没量过这些数字，你根本不会知道自己的环境是空的。

3.3 环境的最终形态与 rollout 期装配

语料：HotpotQA distractor dev split 的 66,581 个去重维基段落，`sha256` 写进清单，rollout 期零网络。BM25 索引手写在 `harness/corpus/index.py`。为什么不用 `bm25s` 或 `Pyserini`？因为**索引是环境定义的一部分**。一次库升级悄悄改掉分词或打分，就会悄悄改掉任务，让之前所有数字失效。一百行钉在仓库里，是更便宜的保证。

三个动作（`harness/data/tools/corpus.json`），全部 `permission: "read"`：

动作	返回
<code>corpus_search(query, k≤10)</code>	编号 + 标题 + 正文前 200 字， 不含 meta
<code>corpus_open(doc_id)</code>	标题、meta、正文全文
<code>corpus_answer(answer, citations[])</code>	<code>stops_turn</code> ，返回 不含正确性 的固定串

三个细节各自解决一个问题：① **全部 read**——`ApprovalPolicy.decide()` 对 `read` 无条件放行，rollout 不会停下来等人，审批策略一行都不用改；② **search 不返回 meta**——`search` 与 `open` 的信息分割**就是第二跳**，把元数据索引进正文，两跳就会塌成一次查询；③ **corpus_answer 的回执不透露对错**——否则模型可以反复调用，把验证器变成一个免费的神谕，这是反作弊的第一道，成本是零。

`stops_turn` 沿用 `exit_plan_mode` 的现成机制，注意 `agent.py` 里 `stops_turn` 只在工具**没报错**时才生效——所以一条轨迹里可能有多次 `corpus_answer` 尝试，验证器要按“最后一次成功的”算分，并对失败尝试扣分（3.6 节展开）。

门禁：`_MODULE_GATES` 加一行 `"corpus": "harness_corpus_enabled"`，默认 `false`。不加的话，`standard` 预设是 `tools: ["*"]`，线上站点的 Agent 会平白多出三个工具，`provider` 的前缀缓存还会失效一次。

rollout 期怎么装配环境：`rl/env/build.py::build_env_context()` 直接构造 `HarnessContext` 这个普通 `dataclass`，**不走 `build_context()`**。每一处差异都是训练的硬需求：

差异	为什么
提示词钉死，不含运行时块	<code>runtime_context()</code> 带当天日期，跨天重新分词就不一致
<code>context_budget</code> 设成不可达（ <code>1<<30</code> ）	关掉 <code>compaction</code> ，它会在轨迹中途改写 <code>system</code> 消息（3.5 节）
<code>store</code> 换成内存实现（ <code>MemorySessionStore</code> ）	循环每步都重读整个日志， <code>SQLite</code> 是一次查询、 <code>list</code> 是一次切片
所有 rollout 共用一个工作区（ <code>__rl_rollout__</code> ）	<code>corpus</code> 工具从不写文件；每条轨迹建一个目录会留下十万个空目录

另外两个自检断言把上面两条钉住：`assert_no_compaction()` 查日志里有没有 `compaction/summary`，`assert_single_system_prompt()` 查提示词快照是不是恰好一个。**查日志而不是信配置**——配置写对了但被别处覆盖，是很常见的事。




图 3.1：RL 数据管线全貌——从语料构建到 GRPO 训练循环闭环，每一段都在对应小节里有实测数字支撑。

3.4 任务集与泄漏过滤：题目本身可能是假的

这一章的内容是本项目里最容易被跳过、跳过代价最大的一环。

严谨定义：数据泄漏 (leakage) 指模型能通过训练语料以外的途径 获得答案。在检索环境里，最常见的形式是答案已经存在于模型的参数 记忆中。

大白话：你出了一道“查资料题”，结果模型早就背过答案。它不查也能答对，于是学会了**跳过工具**。你训出来的不是检索能力，是背书 能力——而且你的所有数字都还在涨。

这为什么致命：① 模型不检索也拿满奖励 → 梯度在奖励“不检索”这个行为；② 于是它越来越不检索 → 工具变成装饰；③ 但 **pass@1 曲线一路上涨**，reward 曲线一路上涨，格式合法率一路上涨；④ 没有任何下游指标会告警，轨迹看起来干净漂亮。这是唯一一种“所有仪表都正常、但训出来的东西完全不是你要的”的失败，所以它在项目风险表里排第一。

HotpotQA 问的是维基 百科实体，而每个现代 LLM 都读过维基百科，所以这个风险不是理论上的。

怎么测：闭卷问答——把题目原样问模型，不给任何工具、不给任何上下文，再用和**真实 rollout** 完全相同的验证器打分。rl/tasks/leakage.py 里两个刻意的选择，让这个测量成为上界：① **提示词鼓励猜，不鼓励拒答**——如果鼓励“不知道”，测出来的泄漏率会偏低，评估风险时宁可高估；② **用强模型测，不用待训练的 1.5B 测**——强模型都答不出的题，对小模型是安全的。

实测结果：

模型	有效判定	泄漏率	bridge	comparison
deepseek-chat	7404	34.7%	27.2%	64.8%
deepseek-v4-flash	3937	28.3%	27.7%	29.6%
并集	—	49.8%	—	—

近一半的 HotpotQA dev 能被其中一个模型闭卷答对。 `comparison` 题（“A 和 B 哪个是 X？”）尤其严重——题面就把两个候选都写出来了，模型只要有一点常识就能选对。真实例子：Who set Nietzsche's philosophical novel to music? → Richard Strauss ✓；What country is home to both Guadarrama National Park and Doñana National Park? → Spain ✓。这两道纯靠世界知识就能答，和检索能力毫无关系。

一个模型不够：泄漏是 (题目, 模型) 的性质——拿同样 300 道题对比两个模型：两者一致率只有 **76.7%**，弱模型覆盖强模型的比例 (recall) 只有 58.2%，且弱模型的泄漏集不是强模型的子集——它知道 19 道对方不知道的。

严谨定义：泄漏不是题目的固有属性，而是 (题目, 模型) 这个二元组的属性。

大白话：“这题会不会被背出来”取决于问谁。所以“用一个模型筛一遍”在方法上是不完整的，正确做法是**取并集**——只要有任何一个模型能闭卷答对，这题就不算检索题。

只用弱模型筛，会漏掉 17% 真正泄漏的题留在数据集里白送奖励。 `rl/cli.py` 的 `tasks split --leakage-file A -leakage-file B` 支持多清单取并集。省钱细节：第二个模型跑的时候加 `--skip-leaked-from A.jsonl` ——第一个模型已经判为泄漏的题，并集里无论如何都要丢，再问一遍是白花钱，7,405 题于是只需要跑 4,834 题。

两个容易做错的处理：

空回复是“没有结论”，不是“答不出来”——思考型模型会把输出预算全烧在推理上。实测 `deepseek-v4-flash` 平均每题 **1,291 个 completion token**（一个单词的答案！），尾部超过 4,096 上限，**18.6% 的题拿不到任何正文**。第一版把这些算成“模型不知道”是错的：

大白话：模型没说话，不等于它说“我不知道”。这是**测量失败**，不是否定结论。按否定算，就等于把一批可能泄漏的题放进了数据集——正是这道过滤器要防的事。

现在它们记为“未知”：既不计入泄漏率的分母，也不进入覆盖集。这个坑踩了两次，第一次更贵：`ANSWER_MAX_TOKENS` 一开始按**均值**（515）定成 1200，结果 22% 的题撞到上限返回空。**按均值定尾部参数**是个通用错误，值得记住（改大几乎免费：按实际生成的 token 计费）。

覆盖不全就丢弃——一部分题被两个模型复核过，一部分只被一个复核过。另一半更可能藏着泄漏题，而在它上面测出的任何指标都会被抬高。`--require-coverage` 只保留所有过滤器都实际复核过的题：`covered = (泄漏并集) ∪ (各过滤器有效集的交集)`。代价是少 897 道题，换来过滤强度一致。

“一次检索即可解”：只打标签，不丢弃——另一道纯本地、零成本的过滤器：把问题原文直接塞进 BM25，看 gold 文档会不会一次全出来。实测：**48.3% 的题一次检索就能拿到全部 gold**，而 95.7% 能拿到至少一篇。但这些题只打标签，不丢弃：

大白话：它们是简单，不是空洞。一次检索能找到证据，但仍然需要构造查询、读结果、综合作答——这些都是真实能力。丢掉会白扔四成数据。

而且静态丢弃在 GRPO 下没必要：一道题变得太简单，组内奖励方差就会归零，`advantage` 恒为 0，它自动停止贡献梯度（3.6 节的在线难度课程）。让算法自己淘汰，比一次性拍死更准。

最终漏斗：

原始题目	7405
泄漏过滤器	chat u v4-flash
- 闭卷可答（泄漏）丢弃	3684 (49.8%)
- 覆盖不全丢弃	897 (12.1%)
= 保留	2824
其中「一次检索即可解」	1158 (41.0%) — 只打标签，不丢弃
train 1908 · dev 457 · test 459 按 qtype 分层，各自记 sha256	

这张漏斗表是本项目最该拿出去的单一产出物。它同时证明三件事：你知道数据可能是假的、你去量了、你按量出来的数字做了取舍。几乎没有人在简历项目里做这一步。

一个必须解释的副作用：`comparison` 题从原始的 20.1% 降到切分后的 12.0%。这不是分层的 bug——是因为 `comparison` 的泄漏率（64.8%）远高于 `bridge`（27.2%），所以被过滤掉的比例更大，这是过滤器的正确后果。能预见并解释这种副作用，和“发现分布变了但不知道为什么”，是两个层级。

切分本身两个细节：按 `qtype` 分层，不按 `level` ——因为 HotpotQA dev 的 7,405 道题全部是 `level=hard`，真正有变化的轴是 `bridge`(5,918) vs `comparison`(1,487)；三个 `split` 各自记 `sha256`，理由和语料一样：一个数字只在“某个具体切分”上有意义。

3.5 奖励与验证器：怎么把“做得好不好”变成一个不会被刷的数

结果奖励：为什么不用 LLM judge——本项目的结果奖励是精确匹配，用 SQuAD/HotpotQA 的标准归一化：小写、去标点、去冠词、压空白。不用 LLM judge 的三个理由：① 答案形态适合——都是短跨度、年份、人名或 yes/no，精确匹配几乎不会判错；② 确定且免费——同一条轨迹今天和半年后打出同一个分；③ judge 会漂移——引入第二个模型，它一次版本升级就悄悄移动你所有历史数字。F1 一并报告但不进入训练信号：

大白话：部分给分等于鼓励对冲。答案里多塞几个可能相关的词，期望 F1 会上升，但答案本身变差了。用 EM 当奖励、F1 当诊断指标，是两者各归其位。

两个必须处理的细节：**yes/no 题**（约 7%）按首词匹配，不做整串相等（“Yes, both are American.” 应判对）；**Unicode 标点**——官方脚本剥的是 `string.punctuation`，只含 ASCII，而语料是维基百科，到处是 en-dash（Trenton-Mercer Airport），ASCII 剥完 U+2013 还在，打了连字符的模型被判错。改成按 Unicode 类别剥，但先量了再改：0.49% 的 gold 答案含非 ASCII 标点，300 个判定里只有 1 个会翻转——偏离参考实现是有代价的，选择改是因为这是奖励函数、系统性偏差方向总是对模型不利，但必须在文档里写清楚偏离了什么。

反作弊：命中即作废——三条规则（`rl/verifiers/process.py`）：

规则	抓什么
编号出处校验	引用的编号必须在此前某条 <code>tool/result</code> 里真的出现过
记忆作答	答案在任何含它的文档返回之前，就被写进了检索词
引用灌水	引用条数超过阈值（两跳题不需要引 6 篇以上）

为什么是作废而不是打折：打折的话，只要 outcome 那一项比折扣大，刷分依然有利可图。作废让它的期望收益变成零，这是唯一能真正关掉这条路的做法。最有力也最便宜的是编号出处校验——编号只通过工具输出到达模型，“引用了一个从没出现过的编号”只能是凭空编的或从记忆里抄的。

一个在 $n=3$ 就抓到的假阳性——“记忆作答”规则在真实轨迹上立刻误判了：“Which is a flowering plant, Pueraria or Pleiospilos?”——答案 `Pleiospilos` 就写在题面上，模型检索它是完全正确的行为，不是记忆，但这条引用完全正确（ $\text{grounding F1} = 1.0$ ）的轨迹却被判作废。后果有多严重：**comparison 题占 HotpotQA 的 20%**。这条规则会在训练里悄悄把五分之一的任务分布判成零分——而且表面上看起来像“策略就是不会做对比题”，你会去调提示词、调超参、怀疑模型能力，而真正的原因在验证器里。修法是豁免题面里已出现的答案，并写成固定用例钉死。

值得复述的一点：是在 $n=3$ 的时候抓到的——因为真的去看了那三条轨迹的逐条判定，而不是只看汇总数字。汇总数字当时显示“33% 被判作弊”，看起来像个合理的比例。

塑形项必须门控在正确性之后——这是整个奖励设计里最容易毁掉一次训练的地方。朴素做法： $\text{reward} = \text{outcome} + w_1 * \text{引用扎实度} - w_2 * \text{效率惩罚}$ 。为什么这样会崩：

大白话：训练早期，1.5B 策略几乎从不答对，所以 `outcome` 恒为 0。此时效率惩罚就成了唯一有梯度的项，而最省力的最大化办法是——立刻空答，一次检索都不做。策略会飞快地学会放弃，而且不可逆：它从此再也不会探索到足够远的地方去拿到那个稀疏的正奖励。

所以所有塑形项乘在 `outcome` 上：

```
if total > 0:
    # 只在答对的轨迹之间做区分
    total += w.grounding * grounding.score
    total -= w.efficiency * redundant
    total -= w.failed_attempt_penalty * fmt.failed_attempts
```

答错的轨迹精确得 0，无论它过程多整齐。权重之和刻意远小于 1：答对值 1.0，塑形只能在 $[1.0, 1.0 + \sum w]$ 之间移动，塑形永远不能盖过正确性本身。`Weights.outcome_only()` 提供纯稀疏基线，消融实验从一条代码路径切换配置。

免费拿到的过程信号：`supporting_facts`——HotpotQA 自带人工标注的支撑证据，等于白送一个过程奖励（ $\text{grounding.recall/precision/ f1}$ ）——这是选择 HotpotQA 相对于自建 arXiv 语料的额外收益之一。

一份轨迹怎么变成一个分数——`rl/verifiers/trace.py` 是唯一被允许读事件词汇表的模块，把日志摊平成一个 `dataclass`，其他验证器只读字段：四个验证器各自解析一遍日志，就会对“一次失败的 `corpus_answer` 算不算作答”产生四种略有不同的意见。一条轨迹里可能有多次 `corpus_answer`（因为 `stops_turn` 只在工具没报错时才生效），规则是按最后一次成功的算分，并对失败尝试逐次扣分——否则“格式报错”就成了免费重试。

验证器 vs 人工：那个几乎没人做的一步——手工标 100 条轨迹的对错，和验证器的判定比一致率，目标 >98%。一个下午的事，但它是“我写了个 `reward function`”和“我验证了我的 `reward function`”之间的全部差别。`voided` 比例是这项审计的入口指标：它上升就意味着策略在学绕过验证器。

3.6 分词对齐与 Loss Mask：多轮 RL 最难发现的一类 bug

这是全书技术含量最高、也最该在面试里主动讲的一节。它解决的问题只有一句话：训练时算梯度的那些 token，必须和采样时模型真正生成的那些 token 逐一对应。听起来像废话。实际上在多轮 Agent RL 里，这件事默认是不成立的，而且不成立的时候没有任何报错。

	普通 bug	分词不一致
报错	有	没有
loss	NaN / 爆炸	正常范围
曲线	明显异常	平滑下降
发现方式	看日志	只能主动断言

根因一：`arguments` 是字符串，模板以为它是对象——Qwen2.5 的 chat template 渲染工具调用时：

```
{{- '\n<tool_call>\n{"name": "' }}{{- tool_call.name }}
{{- '"', "arguments": ' }}{{- tool_call.arguments | tojson }}
```

而 `derive_messages()` 交出的 `arguments` 是模型写的原始 JSON 字符串。对一个字符串做 `tojson`，得到的是一个 JSON 字符串，不是对象：

```
按存储形态（字符串）-> "arguments": "{\\"query\\": \\"nietzsche\\"}"
解析成对象后      -> "arguments": {"query": "nietzsche"}
```

而 vLLM 的服务端会先归一化再套模板。于是 rollout 产出第二种，本地重建产出第一种——每一次工具调用都差若干 token，不报错、不告警。一条 3-4 步的轨迹有 3-4 次工具调用，每次都错。修法：

`rl/eval/template.py::normalize()` 在套模板前把 `arguments` 从 JSON 文本解析成对象：

```
if isinstance(raw, str):
    try:
        fn["arguments"] = json.loads(raw or "{}")
    except json.JSONDecodeError:
        pass # 模型真的写了坏 JSON，保持原样才是忠实的
```

注意那个 `except` 里的 `pass`：模型确实会写出不合法的 JSON，registry 也确实把它当错误返回了。轨迹应该分词成“当时发生的事”，而不是分词成修好的样子。用一个 golden fixture 钉死：渲染结果里必须出现 `"arguments": {"query": ...}`，且必须不出现 `"arguments": "{}`。

根因二：停止符不在 mask 里——`add_generation_prompt=True` 渲染出的 prompt 结尾是

`<|im_start|>assistant\n`，而 `finish_reason == "stop"` 时，vLLM 默认不把 `<|im_end|>` 放进 completion。

大白话：如果 loss mask 不覆盖停止符，模型就永远学不到“该在这里停”。训出来的结果是它不停地说下去，直到撞上 max_tokens。这个 bug 安静、昂贵，而且很经典。

`template.pack()` 把 span 的右边界往回收回到 `<|im_end|>` 那一格为止（含）。

方案：让服务端彻底不碰模板——两条路：A. rollout 走 `/chat/completions`，训练时本地重建（问题是模板在服务端套用，你没有任何办法检查两边是否一致）；B. 把服务端从“套模板”这件事里彻底摘出去（本项目的选择）：①

`derive_messages()` 构造消息列表；② `template.encode()` 用入库的模板在本地套，拿到 `prompt_token_ids`；③ 把这串整数发给 vLLM 的 `/v1/completions`——它不做任何模板处理；④ `logprobs` 把采样到的 token id 和对数概率一起带回来，所以 `logp_old` 是采样那一刻记录的；⑤ 工具调用由我们自己按 `<tool_call>{...}</tool_call>` 解析。

大白话：一个分词器、一个模板、一条代码路径，两边共用。不一致就不再是“要小心的事”，而是结构上不可能发生的事。

代价是要自己写工具调用解析（约 30 行）——这是这个项目里每行代码价值最高的一段。两条配套的钳制：**chat template 作为文件入库**（`qwen2.5_tool.jinja`，2507 字符，sha256 记录），因为 HF 会原地更新模板文件；**关掉 compaction**——`maybe_compact` 一旦触发会改写 system 消息，破坏前缀性质，做法是把 `context_budget` 设成不可达，再用 `assert_no_compaction()` 查日志。

真正需要成立的前缀性质——这一节是“犯错又改对”的过程，比结论更有价值。最初的断言是：每个消息边界处，前缀都稳定——在六条真实轨迹上全部失败。原因不是 bug：Qwen2.5 的模板会把连续的 **tool 响应合并进同一个**

`<|im_start|>user` 块，加上第二条 tool 消息，**第一条的收尾标记被移动了**——这是模板的正常行为。正确的条件更弱：

每个 assistant 轮的 prompt，是完整序列的 token 前缀。

而没有任何 assistant 轮落在 tool 块内部，所以这条精确成立，实测六条轨迹全绿。

教训：断言太强和断言太弱一样危险。太弱抓不到 bug；太强会在正确的代码上报警，把人引去修不该修的地方。想清楚“构造真正依赖什么”，再写断言。

顺带说：Qwen3 会删掉除最后一轮以外所有 assistant 消息里的 `<think>` 块，那会破坏真正的前缀性质——本项目的断言能抓住这种情况，这也是为什么断言要留在自检里，而不是验证一次就删掉。

mask 怎么建（`template.py::pack()`）：

```
full = encode(messages) # 整条对话一次分词
for i, message in enumerate(messages):
    if message["role"] != "assistant": continue
    prompt = encode(messages[:i], add_generation_prompt=True) # 当时的 prompt
    through = encode(messages[:i+1]) # 加上这一轮
    assert full[:len(prompt)] == prompt
    assert full[:len(through)] == through
    start, end = len(prompt), len(through)
    while end > start and full[end-1] != eos_id: end -= 1 # 收到 EOS 为止
    mask[start:end] = 1
```

系统提示词、用户轮、工具观测全部 **mask = 0**——模仿工具返回的内容等于教模型凭空编造检索结果，而不是教它去请求检索结果，这是多轮 RL 里另一个经典错误。实测：每条轨迹只有 7-12% 的 token 是可训练的，这个数字直接推出下一节必须用 token 级归一化。

位移约定：`logp_old[b, t]` 是谁的概率——`logits[b, t]` 预测的是 token `t+1`，所以 token `t` 自身的对数概率来自 `logits[b, t-1]`。约定：`logp_old[b, t]` 是 `input_ids[b, t]` 自身的对数概率（token 对齐，不是 logit 对齐），位置 0 不用。搞反一格的后果：ratio 算在错误的 token 上，loss 有限、梯度有限、模型学噪声——这个约定被连着搞反三次，最后收进了一个有名字的函数（`rl/train/grpo.py::token_logprobs`），并用“策略与采样者相同时，ratio 必须精确等于 1”这条断言钉死。

3.7 GRPO 与训练循环

为什么不需要 critic——PPO 用一个学出来的 value network 当基线，GRPO (Group Relative Policy Optimization) 改用同一道题的 G 条 rollout 的平均奖励当基线：

```
for gid in torch.unique(group_ids):
    group = rewards[group_ids == gid]
    std = group.std(unbiased=False)
    if std < min_group_std:           # 退化组
        keep[members] = False
        continue
    advantages[members] = (group - group.mean()) / (std + eps)
```

大白话：PPO 请了个教练，专门预测“这道题一般能考多少分”，然后看你超没超过预测。GRPO 不请教练——直接让你把同一道题做 8 遍，用你自己这 8 遍的平均分当参照。省掉了训练、调参和怀疑一个额外模型。

退化组：最重要的健康指标——如果一道题的 G 条 rollout 奖励全一样（全对或全错），组内标准差为 0，每条的 advantage 精确为 0，这一组贡献的梯度精确为零——但它照样花掉了 G 条完整 rollout。reward 曲线看不出这件事——reward 走平，loss 正常，而损失函数里一切正常。这就是 all_zero_groups 这个指标存在的理由，也是它在告警表里排第一的理由。配套动作：退化组在 loss 里被跳过（不是乘零——乘零还会稀释 token 级分母），以及冷启动 SFT（见下）。

token 级归一化：一个可以被算出来的选择——两种写法：按序列取平均（每条轨迹算一个 loss，再对轨迹取平均），或 token 级归一化（把 batch 里所有未 mask 的 token 的 loss 加起来除以总数）。轨迹长 1,800–3,300 token，可训练部分只占 7–12%，且长度差异很大。实测：

```
一条 5 token 的轨迹 (advantage +1) + 一条 1 token 的轨迹 (advantage -1)
token 级归一化 : -0.667
按序列取平均   : +0.000      ← 两条完全抵消
```

多轮场景下这个偏差是系统性的：它一直在低估长轨迹，而长程行为正是这个环境要训练的东西，所以选 token 级（DAPO 的做法）。

```
轨迹 A: 5 个可训练 token, advantage = +1      轨迹 B: 1 个可训练 token, advantage = -1

按序列取平均:  (+1 + (-1)) / 2 = 0.000  ← 两条"抵消", 看起来什么都没学到

token 级归一化: (5×(+1) + 1×(-1)) / (5+1) = -0.667  ← 正确反映"更长的正确行为该被强化"
```

图 3.2：token 级归一化 vs 按序列取平均的具体数值对比——按序列平均会系统性低估长轨迹，而长程多步行为正是这个环境要训练的能力。

面试提示：面试时这条可以直接给数字：-0.667 vs +0.000。能算出来的选择，比“我看论文这么写的”强一个量级。

logp_old 必须在采样时记录——`ratio = torch.exp(logp - logp_old)`，`logp_old` 是采样那一刻策略给出的对数概率。如果事后用当前策略重算，得到的是当前策略自己的数字，`ratio` 恒等于 1，裁剪永远不触发，现象是“clip_fraction 一直是 0”——看起来还像“训练很稳”。并发 rollout 的完成顺序是乱的，所以不能按记录顺序配对，做法是按 prompt 前缀匹配：每条记录都带着它当时的 `prompt_token_ids`，匹配不上的整条丢弃，让训练回退到冻结

前向（宁可退化成“第一步 on-policy”，也不要真假 ratio 混用）。配套的工程决定：`engine.run_many` 收的是**策略工厂**而不是适配器实例——因为适配器的类本身也有 `stream` 属性，鸭子类型区分不出“实例”和“工厂”，改成显式的 `engine.shared(adapter)` 之后，立刻暴露出一处过时调用点，这就是显式的好处。

一步训练的七件事（`rl/train/loop.py::run()`）：① 从课程池的活跃子集采题；② 每题 rollout G 条；③ 验证器打分，结果回灌课程池；④ 打包成带 loss mask 的 token 序列；⑤ 组内归一化成 advantage，退化组跳过；⑥ 一步裁剪的 token 级损失；⑦ 存 LoRA adapter 并换进服务。**第七步是最贵的静默故障**——漏掉它：训练照常进行、loss 照常下降，但**第 1 步之后的每一条 rollout 都来自基座模型**——数据变成离策略的，reward 曲线不会动，会以为是算法不行。`lora_serve.check_runtime_lora()` 在循环开始之前就问一次服务器，没开 `VLLM_ALLOW_RUNTIME_LORA_UPDATING=1` 的话热插拔端点返回 404，直接报错退出。需要 GPU 的只有三个 hook（`forward_backward / publish / evaluate`），采样、课程更新、指标累积、告警全是纯 Python，没有卡的机器上用 stub 就能把编排逻辑完整跑一遍。

冷启动 SFT：不是可选项——让一个 1.5B 模型直接上手多跳检索 + 工具调用，它几乎一条都做不对，于是每组 8 条 rollout 全是 0 分，advantage 全 0，**梯度精确为零**——会烧掉几个小时 GPU，reward 曲线一条直线，loss 曲线看起来很平静。所以先做一轮**拒绝采样 SFT**：① 用强模型走**同一个 run_turn、同一套工具、同一个 preset** 采样；② **只保留通过验证器的轨迹**——过滤器就是 GRPO 的奖励函数本身；③ 按（题目，工具调用名序列）去重，每题最多留 2 条；④ 用**和 GRPO 完全相同的 mask 构造**做交叉熵微调。同一个验证器既当 RL 奖励、又当 SFT 过滤器，两个阶段不可能在优化不同的东西。**去重比看起来重要**：不去重的话，几道容易题会有很多条成功轨迹，梯度被它们主导，模型学的是那几道题的措辞而不是行为。**SFT 还是 mask 的金丝雀**——因为它和 GRPO 共用 `template.pack()` 和 `grpo.masked_cross_entropy`，如果 span 错一个 token、或者停止符在 mask 外，SFT 要么不收敛、要么产出乱码——**在一次比 RL 便宜得多的运行上、响亮而且早**。闸门：SFT 之后 dev pass@1 没有大致翻倍、格式合法率没上 95%，就停下来查，别碰 GRPO。

在线难度课程——静态过滤错两次：① **标定错了模型**——教师 4/8 能解的题，Qwen2.5-1.5B 可能 0/8，难度必须对着**待训练的策略**标定；② **只标定一次**——今天 0/8 明天变 3/8 的题正是那时最该练的，而今天 4/8 明天变 8/8 就不再教任何东西，一次性过滤**扔掉了自己最好的未来数据，留下了最差的**。所以通过率用运行中已有的 rollout 持续重估——奖励是现成的，重估**免费**。退休也是可逆的。`MIN_OBSERVATIONS` 不是保守，是必需：训练最初策略最差，凭一组 8 条就退休会在前几步把训练集扔掉大半。

权重怎么进 rollout 服务——本项目的做法：**vLLM 独立进程 + LoRA 热插拔**。trainer 存下 adapter，服务自己去读。基座权重从不动，所以**没有任何东西需要同步**——省掉的正是那一整块权重同步代码。两个容易静默出错的点：忘了 `VLLM_ALLOW_RUNTIME_LORA_UPDATING=1` → 端点 404，换权重静默失效；换权重必须先卸后装 → 装一个服务已知的名字在 某些版本会报错，半完成的交换会留下旧 adapter 继续服务，自检直接断言调用顺序是 `unload` → `load`。adapter 按步号命名（`policy-step-000123`）并盖进轨迹的 `stamp`。

必须盯的曲线——reward 曲线单独看不出健康与否：

指标	它的失败长什么样
<code>all_zero_groups</code>	完全没有梯度；reward 走平而损失函数里一切正常
<code>clip_fraction</code>	≈ 0 说明这一步啥也没更新； ≈ 1 说明策略已跑离采样分布
<code>kl</code>	持续上升 = 正在漂离参考模型，通常是崩塌前兆
<code>entropy</code>	快速下降 = 探索已死，reward 随后必然见顶
<code>format_valid</code>	下降 = 策略在丢掉工具协议，不是在变聪明
<code>gave_up</code>	上升 = 它学会了“不答比检索更省”
<code>voided</code>	上升 = 它找到了刷验证器的办法

最后两个对这个环境最要紧，因为 reward hacking 和奖励崩塌就是这样显形的——而且它们可以和平均 reward 同时上升。参考模型用 peft 的 `disable_adapter()` 上下文管理器：LoRA 本来就不动基座权重，所以参考策略已经在显存里，不需要第二份权重——24 GB 卡上这是装得下 和装不下的差别。

3.8 Rollout 引擎与系统指标

这一章是整个项目里最容易被算法向的人跳过、但最容易量化出成果的一块。

先看一个数字——第一次跑 6 条轨迹时的实测：`p50_seconds` 9.06，`p95_seconds` 235.71。中位数 9 秒，p95 是 236 秒——一条轨迹跑了 4 分钟，而一半的轨迹 9 秒就结束了。轨迹长度天然差异巨大：一道题 三步就解出来，另一道题把 `max_steps=12` 全烧完，两者的墙钟差一个数量级是常态，不是异常。

批同步 vs 连续补位：

严谨定义：批同步（batch-synchronous）调度指启动 N 个任务、等全部完成、再启动下一批。连续补位（continuous refill）指始终保持 N 个任务在飞，任何一个结束就立刻补进下一个。

大白话：批同步像一起过红灯——最快的那辆车也得等最慢的那辆。连续补位像车位管理——空出一个立刻放一辆进来。

批同步是 `asyncio.gather` 套在分块上，很自然会写出来，它的上界是 每批最慢那条——一批 16 条里只要有一条跑 236 秒，其余 15 条在 9 秒就做完了，剩下 227 秒里只有 1/16 的并发在工作。连续补位是一个信号量加一个 per-episode 的 task，大约三十行：

```
semaphore = asyncio.Semaphore(concurrency)
async def guarded(task):
    async with semaphore:
        return await run_episode(task, policy, stamp, weights)
pending = [asyncio.create_task(guarded(t)) for t in tasks]
for coro in asyncio.as_completed(pending):
    results.append(await coro)
```

`--schedule batch` 被刻意保留下来，专门用来产出对照数字。

面试话术：不要只实现好的那个方案。把差的那个也留着、用同一套指标量出来，你就有了“优化前后”而不是“我认为这样更好”。

`RunStats.to_dict()` 输出的几个数字，每一个都对应一个能采取的行动：`throughput_per_min`（最终成果数字）、`p50/p95/p99`（分布形状）、`slowest_5pct_share`（最慢 5% 占了总 episode 时长的多大比例）、`utilisation`（并发占用率 = 总 episode 时长 /（墙钟 × 并发）——实测那次 6 条轨迹的 `utilisation` 是 0.33，因为 `concurrency=6`、任务只有 6 条，根本没有补位的机会，说明补位的收益需要任务数远大于并发数才体现）。

一条轨迹失败，不能带走一整轮：

```
except Exception as e:      # noqa: BLE001 - one episode must not kill a run
    trajectory.error = f"{type(e).__name__}: {e}"
```

`run_episode` 永不抛出。跑 500 条轨迹跑到第 300 条挂了，不能让前 299 条白费，而且失败的那条要留下来、算进分母，不能悄悄消失，否则失败率会伪装成“样本量少一点”。实测里立刻救过场：第一次 smoke rollout 时 `ToolRegistry object is not iterable` 让三条轨迹全失败，但引擎照常跑完、照常出报告、错误照常被记下来。

一个便宜的吞吐优化：分组相邻——GRPO 要每题 G 条 rollout，`run_many` 把任务列表展开成 `[a,a,a,a,b,b,b,b]`，同一道题的 G 份刻意相邻：provider 的前缀缓存按共享前缀计费，而这 G 条共享从 system prompt 到第一个采样 token 之前的全部内容（回顾第一部分 1.10 节量过的效果：约省下 8000/9900 的输入 token）——这里是同一个机制，只是免费，只需要把展开顺序写对。

为什么 rollout 走非流式——`EvalAdapter.stream` 只 yield 一个带组装好 `LLMResult` 的 delta 是完全合法的，循环第一个 delta 的 `result is not None`，chunk 缓冲区排空、直接 return，结果是轨迹里零条 assistant/chunk 事件，循环不做逐 token 的生成器跳转——rollout 要的是“说完的那一整段话”，不是打字机效果。这是“可替换接缝”在 RL 场景下的第三次兑现（前两次是 store 和 adapter）——改一个实现，不动循环。

内存 store 为什么是必需的，不只是方便——`agent.py` 的循环有两个地方会重读整个日志（`_request_model` 每步一次投影、`_run_pending_calls` 每个待处理工具调用一次），一条 12 步的轨迹会有几十次完整读取。SQLite 每次读取是一次 DB 查询，还需要真实的 `users.id` 外键——一条 rollout 没有用户，这是硬阻塞。`rl/env/memory_store.py` 实现 `SessionStore` 的四个方法就解决了。代价是必须证明两者等价：自检里有一个阶段断言两种 store 产生的 `derive_messages()` 结果逐字节相同。

3.9 这一部分的整体产出（给面试用）

RL 这六节合起来能拿出去的东西——**环境与数据**：语料 66,581 段、`sha256` 可校验；任务漏斗 7405 → 泄漏丢 3684 → 覆盖不全丢 897 → **2824**；arXiv → HotpotQA 的实测推翻（BM25 第二名/第一名 0.28 → 0.84）。**奖励与验证器**：精确匹配 + 三条反作弊，命中即作废；塑形 项门控在正确性之后；n=3 抓到的 comparison 假阳性。**分词与算法**：`arguments | tojson` 双重编码，本地套模板 + 传 token id 的解法；可训练 token 只占 7-12%；token 级 vs 按序列归一化：`-0.667` vs `+0.000`。**系统**：p50/p95 长尾、`utilisation`、连续补位 vs 批同步；LoRA 热插拔省掉全部权重同步代码。**验证**：`rl_check` 20 个阶段，含前缀性质、EOS、两种 store 投影一致、两份 advantage 实现一致。

不要背，确保每一条你能用自己的话说出为什么这样做，以及不这样做会怎么错——这一部分的每一章都刻意把“错法”写在了“对法”旁边，就是为了这个。

第四部分 · 面试官视角 QA

这一部分不是“背答案”，是模拟一场真实面试里面试官会怎么一路追问下去。每一题给出：面试官可能的开场问法、几层追问、一份“及格线回答”长什么样、一份“能让人眼前一亮”的加分回答长什么样，以及一个常见的“踩坑式”回答（说明它哪里薄弱）。这个设计参照了对 2026 年真实招聘市场的调研结论（见前言）——大厂大模型/Agent 岗面试常见两种风格：“全程问项目”（围绕项目的每个设计决策深挖）和“八股 + 项目混合”，本部分的多层追问结构对两种风格都能接得住。

4.1 开场：项目介绍与整体设计

Q：介绍一下这个项目，重点讲讲你觉得最有技术含量的部分。

三十秒自我介绍模板：“我做了一个部署在个人网站上的开源项目，里面自己实现了一个 Agent 工作台，参照了 DeepSeek Harness 的设计思想重写。它不是简单调用一个 API 拼 Demo，而是从裸的 HTTP 请求开始，自己实现了完整的事件溯源式会话存储、Function Calling 的流式解析、基于命令白名单的人工审批机制、进程级沙箱隔离、按需读取的技能系统，以及带四道限制闸门的多智能体委派。在这个基础上我又搭了一套 Deep Research 的 Agentic RL 环境，跑通了从环境设计、数据泄漏过滤、奖励设计到 GRPO 训练的完整闭环。”

- 追问 1：“你说的‘自己实现了 Agent Runtime’，具体是相对什么而言的？如果用 LangChain 能做到同样的效果吗？”
- 追问 2：“两条设计原则里，如果只能留一条，你会留哪条，为什么？”

及格线回答：能说出“Function Calling 循环 + 事件溯源存储 + 沙箱 + 审批”这几个组件名字，能大致描述它们各自干什么。

加分回答：能讲清楚“可替换接缝”和“全链路可追溯”这两条原则互相独立、但共同支撑同一个目标——前者是“系统内部各组件怎么互相解耦”，后者是“系统对外的行为承诺（模型看到的和日志记录的永远一致）怎么被工程上保证”。能举出“如果只有 LangChain 帮你封装好 Function Calling 解析，你答不出‘流式场景下 tool_call 的 name 字段只在第一个分片出现’这种问题”作为对比，说明自己写和调包的区别在于能不能被继续往下追问。

常见踩坑：只会说“我用了 XX 框架搭了一个 Agent”——这句话信息量几乎为零，因为框架把所有细节封装掉了，面试官追问不出候选人真正理解了什么。

4.2 Function Calling 与流式解析

Q：Function Calling 具体是怎么工作的？如果我现在让你手写一个（不用任何 SDK），你要处理哪些边界情况？

- 追问 1：“流式响应下，工具调用是怎么一步步拼出来的？”
- 追问 2：“如果 provider 没有返回工具调用的 id 字段怎么办？”
- 追问 3：“模型的工具调用参数是合法 JSON 吗？如果不是呢？”
- 追问 4（2026 年 Agent 面经高频）：“各厂商的 Function Call 格式有什么区别？Function Calling 和 Tool Calling 是一回事吗？”

及格线回答：能画出“请求 1（带 tools）→ 模型返回 tool_calls → 服务端执行 → 请求 2（带 tool 结果）→ 模型给出最终回复”这个两轮往返图。

加分回答：能讲清楚流式场景下 `index` 是唯一保证每个分片都带的 字段，`function.name` 往往只在第一个分片出现，需要一个按 `index` 聚合的累加器把 `arguments` 字符串分片拼接起来；能讲到“如果没有 `id` 就自己生成一个兜底 `id`”；能讲到“参数字符串解析失败要当成工具执行 失败处理、把错误信息作为文本喂回模型，而不是让整个请求崩掉”（工具 失败是值，不是异常）；能区分“Function Calling”是 OpenAI 命名强调“函数”，“Tool Calling”是更宽泛的行业通用术语（涵盖 API、数据库查询、代码执行）。

踩坑回答：“我用官方 SDK，它帮我处理好了”——这句话在这个方向的 面试里几乎等于交白卷，因为它证明候选人从未真正深入过这一层。

4.3 安全与沙箱

Q：你怎么让一个 Agent 敢用 shell 又不会把系统搞坏？

- 追问 1：“为什么不直接把整个 Agent 跑在一个 Docker 容器里就完事，还要在应用层做这么多事？”
- 追问 2：“你刚才提到路径收敛要处理软链接，能具体讲讲怎么判断‘越界’吗？”
- 追问 3：“`RLIMIT_NPROC` 为什么不设？这不是应该设得越严格越好吗？”
- 追问 4（2026 年 Agent 面经高频）：“什么是 Prompt Injection？你的 项目怎么防？Agent 系统的安全防御分几个层级？”

及格线回答：能说出“`execve` 不走 shell，防命令注入”“白名单三档 判定”这两点。

加分回答：能讲清楚为什么审批策略的判定标准是“能不能执行任意 代码或联网”而不是“看起来危不危险”——`git / curl` 在 99% 场景下 无害，但因为具备这个能力属性，宁可多问人一次也不自动放行。能讲清楚 路径收敛的具体漏洞模式：只查 `target.startswith(root)` 会被 “`/root/abc_backup`” 这种“邻居目录”字符串前缀匹配骗过，必须拼上 `os.sep` 再比较；`os.path.realpath()` 解析软链接防止“建一个指向 `/etc/passwd` 的软链接再读它”这种曲线救国。能给出 `RLIMIT_NPROC` 反直觉的原因——它按真实操作系统用户 ID 统计，如果这个沙箱子进程 和 Web 服务本身共享同一个真实用户，设低了会先饿死服务自己的正常 worker 进程，针对 fork 炸弹应该换一层更合适的机制（墙钟超时+杀 进程组+容器 `pids_limit`）去处理。关于 Prompt Injection：能讲清楚 这个项目的核心防线不是“检测注入文本”，而是“限制被注入后能造成的 损失”——沙箱假设模型可能被网页里的恶意指令带偏，纵深防御的三层（应用层审批、进程级沙箱、容器加固）保证即使模型“上钩”，破坏范围 也封顶在自己的工作区。

踩坑回答：只会笼统地说“用了 Docker 隔离”——这没有回答“应用层 为什么还要做这么多事”，说明候选人没有理解“纵深防御”不是“选一层 做到位”，而是“每一层各自挡住不同的风险”。

4.4 可靠性与状态管理

Q：如果用户中途把浏览器关了，Agent 还在执行怎么办？

- 追问 1：“为什么不能直接在流式响应生成器的 `finally` 里做清理？”
- 追问 2：“如果后端进程本身崩溃重启了呢？”
- 追问 3：“会话的‘当前状态’是怎么判断出来的？”

及格线回答：能提到“要有一个兜底机制把状态改回空闲”。

加分回答：能讲清楚 Python 异步生成器在客户端断连时不保证 `finally` 块一定会被执行（可能被垃圾回收器延迟很久甚至永不清理），必须用 Starlette 的 `BackgroundTask`（框架保证在响应流结束后一定被 调度）；再补一层 `reconcile_status` 的心跳窗口兜底（3 分钟没新事件 就判定为僵尸会话）；再补进程重启时

`reset_running_sessions()` ——“没有一次 Agent 对话能活得比启动它的进程还久”。能指出这是三层 独立的保护叠加，而不是依赖其中任何一层单独生效。能讲清楚状态推导 不能只看“最后一条事件”——因为 `step/end` 是在 `tool/approval` 之后 才发出的，要在多种终态候选事件里找“时间最新”的那条。

踩坑回答：认为“加个 `try/finally` 就够了”——这是一个真实存在、 容易被想当然认为“肯定没问题”的坑，能主动指出这个反直觉的事实本身 就是加分项。

4.5 上下文管理

Q：对话长了、超出模型上下文窗口了怎么处理？

- 追问 1：“你怎么判断‘什么时候该压缩’？”
- 追问 2：“压缩的时候，切在哪个位置合适？为什么？”
- 追问 3：“如果压缩本身没什么收益怎么办？”

及格线回答：知道“上下文太长要做摘要压缩”这个基本思路。

加分回答：讲清楚触发条件用 `provider` 返回的 **真实** `prompt_tokens`，不是本地估算——给出真实数字对比（9874 vs 426，差二十多倍，因为本地估算漏算了系统提示词和工具 `schema` 的固定开销）。压缩边界只能切在紧邻一条 `user` 消息之前，避免把 `tool_call` 和它的结果 切断。还有一个“拒绝无效压缩”的细节——收益低于阈值（500 token）时 直接拒绝压缩并打警告，避免陷入“越压缩越花钱却没效果”的死循环。能 把这条和“系统提示词只带日期不带精确时间戳”（为了前缀缓存）串起来 讲——两者都是“上下文/成本工程”里的具体优化。

踩坑回答：只会说“设置一个最大长度，超过了就截断前面的对话”—— 这会把 `tool_call` 和它对应的 `tool_result` 硬生生切断，破坏协议要求，说明没有理解会话内部的结构约束。

4.6 Harness 设计原则（可替换接缝 / 全链路可追溯）

Q：如果要把存储从 SQLite 换成别的数据库/让沙箱支持真正的容器 隔离，你会怎么改？

- 追问 1：“为什么要把这四个组件设计成协议而不是直接写死实现？”
- 追问 2：“全链路可追溯这条原则，在 RL 场景下发挥了什么额外的 价值？”

及格线回答：能说出“用接口/协议解耦，理论上是可以换的”。

加分回答：正确答案是“只改 `harness/context.py::build_context()` 这一处装配点，新写一个实现对应 Protocol（`SessionStore` / `Sandbox`）的类，其余所有代码因为只依赖协议类型、不依赖具体实现，完全不用 改”——这是依赖倒置原则的教科书级实践。能举出 `rl/` 部分复用这条 原则的具体例子：`MemorySessionStore` 替换 `SqliteSessionStore`、`EvalAdapter` / `PolicyAdapter` 替换 `OpenAICompatibleAdapter`，Agent 循环和投影函数一行没改。全链路可追溯在 RL 场景下的额外价值：一条轨迹的事件日志天然完整，`derive_messages()` 是唯一投影函数，几个月后重建的消息序列与当时发出去的逐字节相同，从源头掐掉了 `train/inference` 不一致这一整类 bug。

踩坑回答：泛泛地说“这是好的架构设计”而说不出具体改哪一个文件、改动范围有多小——说明只是记住了结论，没有理解这条原则真正体现在 代码的哪一处。

4.7 技能系统与多智能体委派

Q：为什么需要“技能”这个概念？和“工具”有什么区别？

- 追问：“为什么不做成‘关键词命中就自动注入’，那样不是更智能吗？”

及格线回答：工具是能力，技能是“怎么用好这些能力”的说明书。

加分回答：能讲清楚“系统提示词只放目录、正文按需通过 `load_skill` 工具读取”这个设计不是为了省 token 这么简单，而是为了保住“全链路可追溯”这条核心不变量——如果做成关键词自动注入，这次注入根本不会经过 `emit()` 写进日志，就会出现“模型确实看到了这段内容，但日志里查不到它是怎么来的”这种违反不变量的情况。能讲出“技能损坏 vs 工具契约损坏走两条完全不同的容错路径”——前者是“运行时可以随意改动的内容，允许小错，跳过即可”，后者是“仓库打包错误，必须启动即报错”。

Q：多智能体委派会不会失控？怎么控制风险和成本？

- 追问 1：“子代理内部如果也需要人工审批怎么办？”
- 追问 2：“为什么子代理不直接拿到父 context？”

及格线回答：能说出“有一些限制，比如次数、步数上限”。

加分回答：四道闸门（深度/次数/步数/墙钟），全部在真正发起前检查，深度限制同时体现在内置角色的工具清单里（不给 `subagent` 这个能力）；子代理内部审批策略是严格版——本该转人工的直接拒绝，因为主 Turn 正阻塞在这次调用上，没人能响应子代理弹出的审批卡片，这不是放宽安全边界，是把“永远挂起”变成“立即失败、附带原因”；子代理只共享工作区和沙箱，其余组件独立重建，遵循最小知识原则；一次委派消耗的 token 经常超过主 Agent 本身，费用汇总必须递归包含所有子会话。

踩坑回答：认为“多智能体系统就是多开几个 Agent 实例互相调用”，答不出任何一道具体的花费/风险控制机制。

4.8 这个项目里最值得讲的一条工程原则

Q：这个项目里你觉得最有技术含量/最值得讲的设计是什么？

加分回答：不要只讲某一个孤立功能，讲一条贯穿全书的设计原则——“不要用一个‘看起来正常’的默认值掩盖一个真正的异常状态”：思考型模型空正文该报错不该返回空字符串，未知价格该显示“—”不该显示 0，收益太小的压缩该拒绝不该假装执行。这条原则在完全不同的模块里反复出现，说明这不是碰巧写对了一次，而是一条被主动坚持的工程纪律。

Q：为什么系统提示词只带日期，不带精确时间？

加分回答：Prompt 前缀缓存——只要请求开头一段内容逐字节一致，provider 就能复用之前算过的中间状态，按更低价格计费；带秒级时间戳意味着每次请求都不同，缓存立刻失效。给出实测数字（约省 8000~9900 输入 token）。精确时刻改由一个不联网、本地读取的 `current_time` 工具按需提供。能联系到 RL 部分同一个机制的第三次应用：

`rl/rollout/engine.py::run_many` 把同一道题的 G 条 rollout 刻意排相邻，是同一个前缀缓存原理的零成本吞吐优化。

4.9 质量保障与工程判断力

Q：这个项目为什么没有 pytest？你怎么保证质量？

加分回答：诚实说明这是主动选择而不是缺失——Agent 系统的核心风险大多是“组件间集成是否真的按预期工作”，用分阶段、可独立失败、能接入部署脚本的探针脚本（`harness_check.py`）验证整条真实链路，比 mock 掉外部依赖的单元测试更贴近真实故障面。能讲出探针脚本设计的细节——每个阶段互相独立，一个失败不阻塞后面继续跑，全部通过退出码 0，可以直接接入部署脚本作为健康闸门。

4.10 RL 方向的追问：环境有效性

投 Post-Train / Agentic RL 岗的话，从这里开始的追问比 4.1 ~ 4.9 更 可能被问到。

Q：你的 RL 环境是自己设计的还是用现成 benchmark？

加分回答：两个都讲，而且按时间顺序讲。先说第一版是自建 arXiv 语料 + 元数据推导答案，然后说它是怎么被自己的实测推翻的——“摘要最罕见 8 个词检索自身 top-1 100%，第二名只有第一名 0.28 分，收窄语料反而更糟（IDF 的缘故）”。结论是难度必须来自**语料本身存在 近似文档**，这是语料的性质而非措辞能改的。然后说换成 HotpotQA distractor 之后同一测量变成 0.84、58% 有强竞争者。**这个顺序很重要**：它展示的是“判断一个环境是否有效”的能力，而不是“我跑通了一个 benchmark”。

4.11 怎么保证模型是在学检索，而不是在背答案

Q：怎么知道模型真的在用工具，而不是靠记忆蒙对的？

加分回答：讲闭卷测量。做法是把题原样问模型、不给工具，用同一个 验证器 打分；提示词刻意鼓励猜不鼓励拒答，并且用强模型测，让结果成为 **上界**。实测近一半 HotpotQA dev 泄漏（comparison 题 64.8%，因为 题面就写了两个候选）。然后讲一个**模型不够**：两个模型一致率只有 76.7% 且互不包含，所以泄漏是（题目，模型）的性质，必须取并集。再补 两个易错处理：空回复是“没有结论”不是“答不出来”；覆盖不全的题要丢，否则过滤强度不一致会抬高在它上面测出的指标。

4.12 奖励函数设计

Q：奖励函数怎么设计的？塑形项怎么加？

加分回答：结果奖励用精确匹配不用 LLM judge（确定、免费、不 漂移），F1 只报告不训练（部分给分鼓励对冲）。**重点讲塑形必须门控 在正确性之后**：稀疏奖励下 1.5B 早期 outcome 恒为 0，效率惩罚就成了 唯一有梯度的项，而最省力的最大化办法是“立刻空答”，策略会飞快学会 放弃且不可逆。再讲反作弊命中即**作废**而不是打折（打折时只要 outcome 比折扣大就仍然有利可图），最有力的一条是编号出处校验。如果面试官追问“有没有踩过验证器本身设计有问题的坑”，讲那个 n=3 就抓到的 comparison 题假阳性案例。

4.13 分词对齐与 loss mask

Q：多轮场景下 loss mask 怎么算？踩过什么坑？

这是最该主动展开的一题。三个具体的坑：① `derive_messages` 交出的 `arguments` 是**原始 JSON 字符串**，而 Qwen 模板里是 `| tojson |`，对字符串做 tojson 会双重编码；vLLM 服务端会先归一化，所以 rollout 和本地重建每次工具调用都差若干 token，**不报错**。② 停止符 `<|im_end|>` 必须进 mask，否则模型学会永不停止。③ 最初断言“每个 消息边界前缀都稳定”，六条真实轨迹全失败——原因是 Qwen 把连续 tool 响应合并进一个块，中间前缀确实会移动；真正需要的是更弱的条件“每个 assistant 轮的 prompt 是完整序列的前缀”。解法是让服务端彻底 不碰模板：本地套入库的模板、传 token id 给 `/v1/completions`、自己 解析工具调用——不一致从“要小心”变成“结构上不可能”。顺带一个数字：**可训练 token 只占 7-12%**。

4.14 GRPO 与归一化

Q：为什么用 GRPO？token 级归一化和按序列平均有什么区别？

加分回答：GRPO 用问题 G 条 rollout 的均值当基线，省掉 critic。归一化那一问**直接给数字**：一条 5 token (advantage +1) 加一条 1 token (advantage -1)，token 级是 `-0.667`，按序列平均是 `+0.000`（恰好抵消）。多轮场景下这个偏差是系统性的，一直在低估长轨迹，而长程行为正是要训练的东西。再补 `logp_old` 必须采样时记录——事后重算得到的是当前策略的数字，ratio 恒为 1、裁剪静默失效，而现象看起来像“训练很稳”。

Q：怎么知道一次 GRPO 训练是健康的？

加分回答：先说 **reward 曲线单独看不出来**，然后给指标表。最重要的是 `all_zero_groups`——组内奖励全相同时 advantage 精确为 0、梯度精确为 0，但照样花掉 G 条完整 rollout，而**损失函数里一切正常**。然后讲 `gave_up` 和 `voided` 这两个对本环境最要紧的：它们**可以和平均 reward 同时上升**，分别对应奖励崩塌和 reward hacking。再讲冷启动 SFT 不是可选项（全零组 $\Rightarrow$ 零梯度）以及它顺便是 mask 的金丝雀。

4.15 Rollout 系统工程

Q：rollout 的吞吐怎么优化的？

加分回答：先给实测的长尾数字 **p50=9s、p95=236s**，说明多轮 Agent rollout 长度天然差一个数量级。批同步调度的上界是每批最慢那条，于是大部分时间并发都在空转；连续补位是一个信号量加三十行。**关键是把批同步也留在代码里**（`-schedule batch`），专门用来产出对照数字——这样有的是“优化前后”，而不是“我认为这样更好”。再补两个能直接对应行动的指标：`slowest_5pct_share` 和 `utilisation`（并发占用率），以及零成本的前缀缓存优化（问题 G 份刻意相邻）。

4.16 项目的诚实边界

Q：你这个项目有哪些地方是没做完的？

这题要老实答，而且老实答是加分的。照实说：环境、数据、奖励、分词对齐、GRPO 目标函数、训练循环编排都已验证，正式训练与消融实验待 GPU；`rl_check` 20 个阶段全绿但其中训练那几个是 stub hooks 跑的编排逻辑，不是真实的 forward/backward。然后说清楚**为什么按这个顺序**：分词对齐是唯一一种“看起来在训练、其实在学噪声”的失败模式，所以它必须在没有 GPU 的机器上先绿再租卡；不需要 GPU 的事全部做完，租卡后只做已调通的实验。这比含糊说“训练还在跑”要好得多。

4.17 可以反问面试官的问题

体现你真的在思考 Agent Infra / Post-Train 这个方向，而不是刚看了项目 README 临时准备的：

- “贵司的 Agent 系统里，审批/人工介入的粒度是怎么设计的？是像这个项目一样按命令白名单判定，还是有更细的风险评分机制？”
- “上下文压缩策略是基于本地估算还是 provider 真实返回的 token 数？有没有遇到过因为估算偏差导致压缩时机不准的问题？”
- “多智能体委派场景下，子 Agent 的权限边界是怎么划的？有没有专门处理过‘子 Agent 内部需要人工审批但没人能响应’这类结构性死锁？”

- “训练环境里怎么处理 rollout 和训练时分词不一致这类问题？有没有 类似的自检机制？”

4.18 最后的建议

- **不要试图记住所有细节**，挑 3~4 个你觉得最能体现深度的点，准备 到能画图、能举反例的程度。
 - 投 **Agent / Harness** 开发方向建议挑：`step/end` 在 `tool/approval` 之后发出的顺序细节、子代理严格审批策略解决的 死锁问题、真实 token 数驱动压缩触发、`contained_path()` 里 `startswith` 边界条件的坑。
 - 投 **Post-Train / RL** 方向建议挑：arXiv→HotpotQA 的实测推翻、`arguments | tojson` 双重编码、塑形门控在正确性之后、token 级 vs 按序列归一化的那两个数字。
- **RL 这部分的每一章都刻意把“错法”写在“对法”旁边**，因为面试官 真正在考的是“你知不知道不这样做会怎么错”。能说出失败机制，比能 说出正确做法更有说服力。
- 被问到不知道/记不清的细节时，**诚实说“这个我记不太清具体实现，但设计意图应该是 XXX”**，比硬编一个错误答案要好得多——特别是对着 一个懂这个方向的面试官，编造细节很容易被追问戳破。
- 如果时间允许，建议真的跑一遍这两个：`cd backend && python ../tools/harness_probe.py` ——看一遍完整事件序列长什么样；`python -m rl.checks.rl_check --offline` ——20 个阶段的输出本身 就是一份“我验证了哪些不变量”的清单。

祝面试顺利。

A.1 术语速查表

术语	一句话解释	首次出现
自回归生成	模型逐 token 猜“下一个是什么”，猜一个吐一个	1.1
上下文窗口	单次请求能塞进去的最大 token 数（输入+输出）	1.2
System/User/Assistant/Tool	Chat Completions 协议的四种消息角色	1.3
温度 / Top-p	采样时控制“确定 vs 随机”的两个旋钮	1.4
Function Calling	模型输出结构化调用请求，服务端真正执行并喂回结果	1.5
SSE	基于长连接 HTTP 的服务端单向流式推送协议	1.6
RAG	先检索、再让模型基于检索结果作答	1.7
BM25	基于词频/逆文档频率的经典检索排序算法	1.7
SFT / RLHF	监督微调 / 基于人类反馈的强化学习，预训练之后的两个对齐阶段	1.8
策略 / 奖励 / 优势函数	RL 三要素：怎么选动作、动作好不好、比平均水平好多少	1.9
GRPO	用同题多条 rollout 的均值当基线，省掉价值网络的 RL 算法	1.9 / 3.7
KV Cache / 前缀缓存	复用请求里未变化前缀的注意力中间结果，降本增速	1.10
接缝（Seam）	一个协议 + 一份默认实现，可独立替换的组件边界	2.9
事件溯源（Event Sourcing）	只存变化过程（事件日志），当前状态靠重放推导	2.10
Append-Only Log	只能追加、不能修改删除的日志结构	2.10/2.11
投影函数 <code>derive_messages()</code>	把事件日志转换成发给模型的消息列表的唯一函数	2.13
乐观并发控制	不预先加锁，靠唯一约束检测并发冲突再重试	2.12
CSRF 双提交校验	一份数据走 Cookie，一份走请求头，两者对得上才放行	2.2
纵深防御	多层独立防护叠加，攻破一层不等于整体失守	2.21

术语	一句话解释	首次出现
execve	直接用参数数组启动新进程，不经过 shell 二次解析	2.21
数据与代码分离	工具的契约（JSON）和实现（Python）拆成两个文件	2.19
Skill（技能）	按需读取的过程性知识文档，区别于可直接调用的工具	2.22
多智能体委派	主 Agent 把子任务连同执行细节整体交给子 Agent	2.23
数据泄漏（leakage）	模型不靠检索、单凭记忆就能答对题目	3.4
reward hacking	策略找到“提高奖励但不完成任务”的路径	3.5
train/inference 不一致	训练时重建的序列与采样时真实序列不同，梯度作用在错误 token 上	3.1 / 3.6
loss mask	标记序列里哪些 token 参与损失计算（只有模型自己生成的 token）	3.6
批同步 / 连续补位	两种并发调度：等齐一批 vs 随时补位空出的槽	3.8

A.2 章节索引对照表

本书内容大部分取材、扩写自 `course/` 目录下的 22 篇原始教程。如果你想找某个知识点最原始、最聚焦的出处，可以按下表查找：

本书章节	对应 course/ 文件
第一部分（全部）	21-全景教程-从LLM小白到面试官.md 第一部分
2.1 ~ 2.7	01-技术栈总览.md 、 02-后端分层架构.md 、 03-前端架构.md
2.8 ~ 2.10	04-harness-总览与两大设计原则.md
2.11 ~ 2.14	05-harness-事件系统与会话存储.md
2.15 ~ 2.18	06-harness-Agent执行循环.md
2.19 ~ 2.20	07-harness-工具系统与审批.md
2.21	08-harness-沙箱与安全边界.md
2.22	09-harness-技能系统.md
2.23	10-harness-子代理多智能体.md
2.24	11-harness-成本上下文压缩与工程细节.md
2.25	12-harness-HTTP接口与前端联调.md
2.26	13-部署与验证.md
第三部分 3.1 ~ 3.3	15-rl-从Agent运行时到RL环境.md
3.4	16-rl-任务集与泄漏过滤.md
3.5	17-rl-奖励与验证器.md
3.6	18-rl-分词对齐与loss-mask.md
3.7	19-rl-GRPO与训练循环.md
3.8 ~ 3.9	20-rl-Rollout引擎与系统指标.md
第四部分（全部）	14-面试准备指南.md + 21-全景教程-从LLM小白到面试官.md 第四部分

A.3 命令速查

```
# 本地跑起整个 Web 应用
cd backend && pip install -r requirements.txt && python main.py

# 验证 AI 供应商连通性 / Harness 离线自检 / 完整自检
cd backend
python ../tools/ai_probe.py
python ../tools/harness_check.py --offline
python ../tools/harness_check.py
python ../tools/harness_check.py --url http://localhost:8000 --token <管理员JWT>

# 跑一整轮真实 Agent 对话（不经过浏览器）
python ../tools/harness_probe.py --prompt "在工作区建一个 hello.txt 写入当前时间，然后读回来"

# RL 工作台（从仓库根目录运行）
python -m rl.checks.rl_check --offline
python -m rl.cli corpus hotpot --split validation && python -m rl.cli corpus index
python -m rl.cli tasks leakage --all --model deepseek-chat --resume --out data/leak.jsonl
python -m rl.cli tasks split --require-coverage --leakage-file A.jsonl --leakage-file B.jsonl
python -m rl.cli rollout --split dev -n 50 --out data/traj.jsonl --report out.md
python -m rl.cli export data/traj.jsonl --format tokens --out data/verl.jsonl
```

A.4 一句话读完全书

如果只能用一句话总结这本书想让你记住什么：

一个真正理解 Agent Runtime 的人，不是会背“事件溯源”“Function Calling”“GRPO”这些名词的人，而是能讲出“如果不这样做，具体会在什么场景下、以什么症状坏掉”的人。本书里几乎每一个设计决策旁边，都配了一个“如果不这样做会怎样”的反例——这不是巧合，这正是这个 项目、以及这本书，想教给你的思维方式。